Universidad Católica de Córdoba

Facultad de Ingeniería

Proyecto:

NexusAI

Asistente académico con inteligencia artificial integrado en Moodle

[insertar logo UCC]

Informe Final de Grado

Alumnos:

- Santiago Tricherri
- Marcos Bugliotti
- Delfina Salinas

Directores:

- Ignacio Luciano Carreño
- Federico Eduardo Porrini
- Leandro Juarez

[COMPLETAR: día] de [mes] de 2026

Córdoba — Argentina

Índice

1. Resumen **4**

1.1. Abstract 4

2. Presentación del tema **6**

3. Glosario **7**

4. Diagnóstico (problemática) **8**

4.1. Estado actual (contexto) 8

4.2. Impacto sobre los interesados 8

4.3. Oportunidades 8

5. Relevamiento y metodología de investigación **10**

5.1. Metodología 10

5.2. Encuesta a estudiantes (N = 166) 10

5.3. Encuesta a docentes (N = 17) 11

5.4. Contexto institucional relevado 12

5.5. Síntesis 12

6. Objetivos **14**

6.1. Objetivo general 14

6.2. Objetivos específicos 14

6.3. Tabla de trazabilidad 14

7. Marco teórico **16**

7.1. Contexto general del problema 16

7.2. Técnicas investigadas 16

7.3. Tecnologías investigadas 16

7.3.1. Base de datos vectorial 17

7.3.2. Modelos de lenguaje y *embeddings* 17

7.3.3. Arquitectura de plugin Moodle 17

7.3.4. Extracción y fragmentación de documentos 18

7.3.5. Estilos de arquitectura del backend 18

7.3.6. Autenticación servicio-a-servicio 18

7.3.7. Transporte de respuestas en tiempo real 19

7.3.8. Infraestructura de despliegue 19

7.3.9. Validación de datos en los límites del sistema 19

7.4. Opciones similares en el mercado 20

7.4.1. Asistentes académicos generales 20

7.4.2. Plugins de Moodle con inteligencia artificial 21

8. Propuesta de solución **23**

8.1. Alcance funcional 23

8.2. Diseño . . . 24
8.2.1. Arquitectura del software . . . 24
8.2.2. Patrones de diseño . . . 25
8.2.3. Interfaz de usuario . . . 25
8.2.4. Proceso de diseño de la interfaz . . . 27
8.3. Implementación . . . 28
8.3.1. Funcionalidades post-MVP . . . 31
8.4. Arquitectura técnica del backend . . . 34
8.4.1. Autenticación HMAC en tres capas . . . 34
8.4.2. Esquema de base de datos: alcance vigente y migración de dimensión . . . 35
8.4.3. Streaming de respuestas: *Server-Sent Events* . . . 35
8.4.4. Contratos de datos: *schemas* Pydantic . . . 36
8.4.5. Ciclo de vida y estado de la aplicación . . . 36
8.5. Arquitectura técnica del plugin Moodle . . . 36
8.5.1. Inyección del widget: Hook API y *callback* legado . . . 37
8.5.2. Capabilities y control de acceso . . . 37
8.5.3. *Web services*: el patrón de tres métodos . . . 38
8.5.4. React como módulo AMD . . . 38
8.5.5. Empaquetado con Webpack . . . 39
8.6. Pruebas . . . 39
8.6.1. Pruebas unitarias y de integración (backend) . . . 39
8.6.2. Pruebas automatizadas del frontend (Vitest) . . . 40
8.6.3. Evaluación de calidad del asistente: dos campañas . . . 40
8.6.4. Pruebas de aceptación, usuarios reales y rendimiento . . . 41

9. Seguridad y cumplimiento **42**
9.1. Auditoría de seguridad: OWASP Top 10 y análisis de dependencias . . . 42
9.2. Estrategia de privacidad y cumplimiento normativo . . . 43
9.3. Prácticas de seguridad del plugin . . . 44

10. Despliegue e infraestructura **45**
10.1. Topología: del plan original a las dos VMs reales . . . 45
10.2. El proceso de despliegue manual . . . 46
10.3. Operación, mantenimiento y brechas pendientes . . . 47

11. Publicación en Moodle Marketplace **49**
11.1. Por qué separar el repositorio . . . 49
11.2. Proceso de envío y primera revisión . . . 49
11.3. Correcciones de la primera ronda . . . 50
11.4. Auditoría propia y cierre de los últimos gaps . . . 50
11.5. Sincronización automática y una lección operativa . . . 51
11.6. Estado actual . . . 51

12. Gestión del proyecto y metodología ágil **52**

12.1. Metodología adoptada . . . 52
12.2. Cierre de Fase 1 — Setup e Investigación . . . 52
12.3. Cierre de Sprint 2 — RAG completo . . . 53
12.4. Un pivote real de infraestructura . . . 54
12.5. Cierre . . . 54

13. Beneficios post-implementación **55**

14. Impacto económico (estudio de costos) **56**
14.1. Costos de infraestructura y servicios de IA . . . 56
14.2. Costos de personal (valoración teórica) . . . 56
14.3. Análisis costo-beneficio . . . 56

15. Impacto social **57**

16. Impacto medioambiental (opcional) **58**

17. Conclusión **59**
17.1. Reflexiones personales del equipo . . . 59

18. Bibliografía / Referencias **61**

19. Anexos **63**
19.1. Anexo A — Requerimientos detallados . . . 63
19.1.1. Requerimientos funcionales . . . 63
19.1.2. Requerimientos no funcionales . . . 66
19.2. Anexo B — Modelo de datos . . . 68
19.3. Anexo C — Métricas del proyecto . . . 70
19.4. Anexo D — Repositorio y evidencias . . . 71
19.5. Anexo E — Registro de decisiones de arquitectura (ADRs) . . . 71

1. Resumen

El presente informe documenta el desarrollo de **NexusAI**, un asistente académico basado en inteligencia artificial integrado como plugin en la plataforma Moodle.

Las plataformas de gestión del aprendizaje (LMS) como Moodle se utilizan mayoritariamente como repositorios documentales estáticos, mientras que los estudiantes recurren a asistentes de IA generales —ajenos al material de cada materia— para resolver sus dudas. Esto produce respuestas genéricas, dispersión de la información y pérdida de visibilidad del docente sobre las consultas del alumnado.

Para abordar esta situación se diseñó e implementó un plugin de tipo `local` para Moodle, acompañado de un backend que aplica la técnica de *Retrieval-Augmented Generation* (RAG) sobre el material indexado de cada curso, almacenado en una base de datos vectorial. La solución recupera los fragmentos más relevantes del material y los provee como contexto a un modelo de lenguaje de gran escala, que responde citando explícitamente la fuente.

El producto mínimo viable (MVP), entregado en junio de 2026, alcanzó siete funcionalidades en producción —buscador semántico, chat conversacional multi-curso, respuesta en *streaming*, citas trazables, historial, generador de cuestionarios y detección de vacíos de contenido— con una cobertura de pruebas automatizadas cercana al 80 % en el backend. En los meses posteriores el desarrollo continuó de forma sostenida, incorporando foros con detección de posts similares y asistencia de IA, un panel de analítica para el docente, generación de exámenes exportables al formato nativo de Moodle, un plan de estudio personalizado que combina errores de práctica y vacíos detectados, y soporte para formatos de material adicionales al PDF.

Los resultados muestran que es posible ofrecer asistencia académica contextualizada y auditable dentro del LMS institucional, preservando la soberanía de los datos y mitigando la alucinación de los modelos de lenguaje mediante la trazabilidad de las respuestas.

Palabras clave: Moodle, inteligencia artificial, RAG, asistente académico, educación, soberanía de datos.

1.1. Abstract

This report documents the development of **NexusAI**, an artificial-intelligence academic assistant integrated as a plugin into the Moodle platform.

Learning Management Systems (LMS) such as Moodle are mostly used as static document repositories, while students rely on general-purpose AI assistants —unaware of each subject's material— to solve their doubts. This leads to generic answers, information dispersion, and a loss of teacher visibility over student queries.

To address this, a Moodle `local` plugin was designed and implemented, together with a backend that applies Retrieval-Augmented Generation (RAG) over each course's indexed material, stored in a vector database. The solution retrieves the most relevant fragments and provides them as context to a large language model, which answers by explicitly citing its source.

The minimum viable product (MVP), delivered in June 2026, reached seven production features —semantic search, multi-course conversational chat, response streaming, traceable citations, history, quiz generation, and content-gap detection— with automated test coverage close to 80 % in the backend. Development continued steadily in the following months, adding forums with similar-post detection and AI assistance, a teacher analytics panel, exam generation exportable to Moodle's native format, a personalized study plan combining practice errors and detected gaps, and support for additional material formats beyond PDF.

Results show that contextualized and auditable academic assistance can be delivered within the institutional LMS while preserving data sovereignty and mitigating large language model hallucination through answer traceability.

Keywords: Moodle, artificial intelligence, RAG, academic assistant, education, data sovereignty.

2. Presentación del tema

La adopción de la inteligencia artificial generativa en la educación universitaria avanza más rápido que la integración formal de estas herramientas en las plataformas educativas. Mientras los estudiantes utilizan asistentes generales para resolver dudas académicas, las plataformas LMS institucionales como Moodle continúan funcionando como repositorios documentales, sin integración con la inteligencia artificial.

El proyecto NexusAI surge de esta brecha. Su propósito es incorporar, dentro del propio campus virtual, un asistente académico capaz de responder consultas en lenguaje natural sobre el material real de cada materia, generar ejercicios de práctica y proveer información accionable al docente. La relevancia del tema radica en que la solución no compite con el docente ni reemplaza a la plataforma existente: agrega una capa de inteligencia sobre Moodle, manteniendo a los estudiantes en el entorno donde reside el material académico validado.

El problema que motiva el proyecto se desarrolla en detalle en la sección *Diagnóstico*, y constituye el eje central sobre el cual se articula el resto del informe. El relevamiento formal realizado para este proyecto (166 estudiantes y 17 docentes de la UCC) confirma la brecha: el 100 % de quienes respondieron ya usa un asistente de IA generalista para estudiar, y el 80,7 % de los estudiantes percibe dispersión de la información entre el material del curso y esas herramientas externas. NexusAI responde a esa brecha con tres capacidades concretas dentro del propio Moodle: un asistente conversacional que cita la fuente exacta del material, un generador de ejercicios de práctica a partir de ese mismo material, y la detección automática de los vacíos de contenido que quedan sin responder.

3. Glosario

Se definen a continuación los términos específicos del dominio del proyecto, necesarios para comprender el informe por parte de un lector no especializado en el área.

- **LMS (Learning Management System):** plataforma de gestión del aprendizaje que centraliza materiales, actividades y comunicación de un curso. Moodle es el LMS de referencia en el ámbito universitario argentino.
- **Moodle:** sistema de gestión de aprendizaje de código abierto, ampliamente utilizado por instituciones educativas para administrar cursos en línea.
- **Plugin:** componente de software que extiende las funcionalidades de una plataforma existente sin modificar su núcleo. NexusAI se distribuye como un plugin de tipo `local` para Moodle.
- **Inteligencia artificial generativa:** rama de la IA capaz de producir contenido nuevo —texto, imágenes, código— a partir de patrones aprendidos de grandes volúmenes de datos.
- **Modelo de lenguaje de gran escala (LLM):** modelo de inteligencia artificial entrenado sobre grandes cantidades de texto, capaz de comprender y generar lenguaje natural.
- **RAG (Retrieval-Augmented Generation):** técnica que combina la búsqueda de información relevante en una fuente de datos propia con la generación de texto de un LLM, permitiendo respuestas fundamentadas en material específico.
- **Embedding:** representación numérica (vector) de un fragmento de texto que captura su significado semántico, permitiendo comparar la similitud entre textos.
- **Base de datos vectorial:** sistema de almacenamiento optimizado para guardar y buscar *embeddings* por similitud semántica.
- **Alucinación (de un LLM):** fenómeno por el cual un modelo de lenguaje genera información plausible pero falsa o no fundamentada en una fuente real.
- **Chunk (fragmento):** porción de texto en la que se divide un documento para su indexación y recuperación.
- **Streaming:** entrega progresiva de la respuesta del modelo, token por token, para reducir la latencia percibida por el usuario.

4. Diagnóstico (problemática)

La problemática que da origen al proyecto no constituye únicamente un problema en sentido estricto, sino también una oportunidad de mejora dentro del proceso educativo universitario mediado por plataformas digitales.

4.1. Estado actual (contexto)

Las plataformas LMS como Moodle son fundamentales en la educación universitaria, pero en la práctica se utilizan como repositorios estáticos: los estudiantes descargan archivos y entregan trabajos, sin un acompañamiento real al proceso de aprendizaje. A partir de la experiencia directa del equipo del proyecto como estudiantes de la Universidad Católica de Córdoba (UCC), se identificaron de manera preliminar tres problemáticas recurrentes en el uso del campus virtual, que luego se validaron mediante un relevamiento formal a 166 estudiantes y 17 docentes de la institución:

- **Dispersión de la información** entre el campus virtual, aplicaciones de mensajería y servicios de almacenamiento personales, que dificulta encontrar el material correcto en el momento de estudiar. El 80,7 % de los estudiantes encuestados percibe esta dispersión al menos "a veces", y un 43,4 % la califica como alta o frecuente.
- **Dificultad para organizar el estudio** y planificar repasos antes de las evaluaciones, en un contexto donde solo el 34 % de los estudiantes describe la mayoría de sus materias como bien organizadas dentro del campus.
- **Uso pasivo del campus virtual** frente al material académico: aunque el 72,3 % de los estudiantes ingresa al campus a diario o varias veces por semana, el 100 % de quienes fueron consultados al respecto ya recurre a herramientas de IA generalistas —ajenas al material de la materia— para estudiar o resolver trabajos, lo que evidencia una necesidad no cubierta por la plataforma institucional.

4.2. Impacto sobre los interesados

La situación afecta a dos grupos principales. Por un lado, los estudiantes reciben respuestas genéricas de modelos entrenados sobre internet abierto —no sobre el material específico de su curso—, con riesgo de respuestas plausibles pero incorrectas en el contexto de esa materia particular. Por otro lado, los docentes pierden visibilidad sobre qué consultan los estudiantes acerca de su material, porque dichas consultas suceden fuera del LMS.

4.3. Oportunidades

A partir de este diagnóstico se identifican tres oportunidades de mejora que el proyecto busca aprovechar:

- Mantener a los estudiantes dentro del campus virtual, donde reside el material validado por el docente.
- Ofrecer respuestas fundamentadas en el material específico del curso, y no en fuentes genéricas de internet.

- Generar datos accionables para el docente sobre las consultas y los vacíos de contenido detectados.

  Los datos citados en esta sección provienen del relevamiento propio del equipo: encuesta a 166 estudiantes y encuesta a 17 docentes de la UCC, realizadas entre marzo y junio de 2026. El detalle de preguntas, metodología y resultados completos se desarrolla en la sección *Relevamiento y metodología de investigación*, a continuación.

5. Relevamiento y metodología de investigación

Esta sección documenta en detalle el relevamiento mencionado en el Diagnóstico: diseño, proceso de recolección, preguntas completas y resultados de las dos encuestas propias del equipo, junto con el contexto institucional relevado en paralelo.

5.1. Metodología

Ambas encuestas se diseñaron como formularios de Google, difundidas entre marzo y junio de 2026, y comparten una particularidad metodológica que se documenta explícitamente para no inflar artificialmente la muestra: el formulario se amplió mientras ya se estaban recolectando respuestas, de modo que las primeras respuestas solo vieron el bloque inicial de preguntas y las posteriores vieron el formulario completo. Por esta razón, cada resultado reportado a continuación indica el **N real** de quienes vieron esa pregunta en particular, en lugar de asumir el total de respondentes para toda pregunta — algunos resultados tienen como denominador el total de la encuesta y otros un subconjunto, según corresponda.

5.2. Encuesta a estudiantes (N = 166)

Relevamiento cerrado entre el 31 de marzo y junio de 2026, con 166 respuestas mayoritariamente de la Facultad de Ingeniería, con representación también de Ciencias Económicas y de Administración, Ciencias de la Salud, Derecho y Ciencias Sociales, Ciencias Políticas y RRII, y Ciencias Agropecuarias. El cuestionario cubrió cinco bloques: perfil y uso del campus, experiencia y organización de materias, dispersión de información y comunicación, validación de funcionalidades de NexusAI, y una pregunta abierta de cierre.

Frecuencia de uso del campus virtual (n=166): el 72,3 % (120/166) lo usa todos los días o varias veces por semana. El campus es, en la práctica, parte de la rutina de la mayoría — la problemática que motiva el proyecto no es la falta de uso, sino qué tan bien ese uso frecuente se traduce en organización real del estudio.

Dispersión de la información (n=166): para poder combinar las dos versiones del formulario (que ofrecían escalas de respuesta distintas para esta pregunta), los resultados se agruparon en tres categorías equivalentes. El 43,4 % (72/166) reporta dispersión alta o frecuente, el 37,3 % (62/166) reporta dispersión intermedia y el 19,3 % (32/166) reporta dispersión baja o nula. En conjunto, **el 80,7 % de los estudiantes percibe dispersión de información al menos "a veces"**, confirmando con datos formales la problemática que el equipo había identificado inicialmente de forma informal.

Experiencia y organización de materias (n=88): el 80,7 % califica su experiencia con el campus como buena o mejor, pero la razón dominante ("funciona bien aunque le faltan cosas") describe un uso intensivo y a la vez insatisfecho, no un rechazo a la plataforma. Sobre la organización de sus materias, solo el 34 % ve "la mayoría" o "todas" bien organizadas; el 54,5 % las describe como "mitad y mitad" — la organización depende fuertemente de cada docente, no de la plataforma en sí.

Uso de herramientas de IA para estudiar (n=88): el 100 % de quienes vieron esta pregunta ya usa alguna herramienta de IA generalista para estudiar, hacer trabajos, o ambas cosas. Es un dato a interpretar con cautela porque el formulario no ofrecía ninguna opción negativa, pero es consistente con el resto del relevamiento: la IA generalista ya es una práctica de estudio extendida, mientras el campus virtual no ofrece nada equivalente integrado.

Corrección automática de ejercicios (n=88): el 95,5 % (84/88) ve valor en que una IA corrija ejercicios con explicación — 43,2 % la usaría frecuentemente, 37,5 % como complemento a la corrección del docente. Solo el 4,5 % prefiere que la corrección quede exclusivamente en manos del docente.

Dos respuestas abiertas ilustran el patrón encontrado:

> "Mejoraría el hecho de que no esté tan dispersa la información, también que esté más organizado."

> "El valor del aula virtual depende mucho de cómo la preparen los profesores. Bien organizada, mejora mucho la experiencia."

5.3. Encuesta a docentes (N = 17)

Relevamiento cerrado entre el 1 de abril y el 19 de junio de 2026, con 17 respuestas de docentes mayoritariamente de la Facultad de Ingeniería. La encuesta se revisó previamente con Leandro Juarez, director del proyecto y docente de la cátedra de Proyecto Integrador, antes de su difusión.

Uso actual de IA en la práctica docente (n=17): el 64,7 % (11/17) ya usa alguna herramienta de IA; ningún docente la rechaza de plano.

Delegación de tareas a una IA integrada al campus (n=17): el 88,2 % (15/17) delegaría al menos parcialmente tareas a una IA integrada —el 47,1 % condicionado a poder revisar el resultado antes de publicarlo, el 23,5 % "según la tarea" y el 17,6 % sin condición. Ningún docente respondió que no delegaría nada. La condición de supervisión antes de publicar, repetida en la mayoría de las respuestas, valida directamente el patrón de diseño "asistir, no reemplazar" adoptado en NexusAI.

Estructura inicial del curso armada por IA (n=15): el 86,7 % (13/15) ve valor en que una IA arme la estructura inicial del curso, dividido entre hacerlo con revisión posterior (40 %) o en paralelo decidiendo cada paso junto a la IA (40 %). Solo el 13,3 % prefiere armarlo íntegramente solo.

Herramientas de evaluación actuales (n=15): un tercio no las usa y no puede opinar; del resto, las opiniones se dividen entre "básicas pero sirven", "me faltan funcionalidades" y "cubren lo que necesito" en proporciones similares. Las sugerencias abiertas más repetidas piden corrección automática de trabajos y rúbricas inteligentes.

Dos respuestas abiertas:

> "Transformarlo en una herramienta de gestión real y no un reservorio de materiales."

"Alertas tempranas sobre temas docentes a resolver (contenido, clases, asistencias, notas, condiciones)."

La tabla siguiente resume cómo los resultados confirmaron o descartaron decisiones de alcance tomadas antes de tener los datos:

Condición evaluada	Resultado real
>50 % de interés en generador de evaluaciones / delegar tareas a una IA → adelantar esa épica al Sprint 3	**Confirmado (88,2 %)** — consistente con incluir Herramientas para Docentes en el alcance del MVP.
Bajo interés en analytics → bajar prioridad post-MVP	**Descartado** — alto interés: la mayoría de las respuestas abiertas pide ver temas con más dudas y alumnos en riesgo, lo que mantuvo Analytics dentro del alcance.
>70 % prioriza citar fuentes / objeciones fuertes a que los datos salgan a un proveedor externo de IA	No se preguntó explícitamente en la versión final del formulario — el requisito de citación ya estaba definido desde el diseño técnico, y no hay evidencia de objeción en las respuestas abiertas relevadas.

5.4. Contexto institucional relevado

En paralelo a las encuestas, el equipo relevó los requisitos técnicos y políticos que impone la UCC para instalar un plugin de terceros en su instancia institucional de Moodle (versión y SO del servidor, proceso formal de aprobación, restricciones de red, marco de privacidad aplicable). La mayoría de esas preguntas —dirigidas al área técnica de Moodle de la universidad— quedó sin respuesta confirmada dentro del plazo del proyecto. Por eso, desde una etapa temprana, el equipo priorizó una estrategia de despliegue que no dependiera de esa aprobación institucional: una demo autohospedada, independiente de la infraestructura de la UCC, que es efectivamente la que se usa durante el desarrollo y la que se describe en el Anexo D de este informe (backend permanente en Oracle Cloud; cada integrante corre Moodle localmente apuntando a ese backend). La sumisión del plugin al Moodle Plugins Directory, descripta en la sección *Publicación en Moodle Marketplace*, es en los hechos la vía que terminó reemplazando a la aprobación institucional directa: un plugin publicado y revisado por Moodle HQ es más fácil de autorizar para un área de IT que uno sin ningún tipo de validación externa.

5.5. Síntesis

Problemática del Diagnóstico	Evidencia de la encuesta a estudiantes	Evidencia de la encuesta a docentes
Dispersión de la información	80,7 % percibe dispersión al menos "a veces"; 43,4 % la percibe alta o frecuente.	—

Problemática del Diagnóstico	Evidencia de la encuesta a estudiantes	Evidencia de la encuesta a docentes
Uso pasivo / desorganizado del campus virtual	Solo 34 % ve sus materias bien organizadas; depende del docente más que de la plataforma.	33 % no usa las herramientas de evaluación del campus.
Recurso a IA generalista ajena al material del curso	100 % de quienes vieron la pregunta ya usa IA para estudiar y/o trabajos; 95,5 % quiere corrección automática con explicación.	64,7 % ya usa IA en su práctica docente; 88,2 % delegaría tareas a una IA integrada al campus.

6. Objetivos

6.1. Objetivo general

Desarrollar un plugin para Moodle que incorpore un asistente académico basado en inteligencia artificial, capaz de responder consultas en lenguaje natural sobre el contenido real de cada materia, generar ejercicios de práctica personalizados y proveer herramientas de *analytics* al docente, mejorando la experiencia educativa dentro del aula virtual de la UCC.

6.2. Objetivos específicos

- Identificar y documentar las problemáticas del uso actual del campus virtual a partir de la experiencia directa del equipo como estudiantes de la UCC, validada mediante un relevamiento formal a 166 estudiantes y 17 docentes de la institución.
- Diseñar e implementar un plugin de tipo `local` para Moodle que se integre al entorno existente sin modificar su núcleo.
- Desarrollar un prototipo funcional (MVP) con un asistente conversacional basado en técnicas de RAG e integración con modelos de lenguaje de gran escala, validado con usuarios reales.
- Implementar un sistema de generación de cuestionarios de práctica con corrección automática asistida por IA.
- Proveer al docente un panel de *analytics* sobre las consultas de sus estudiantes y herramientas de detección de vacíos de contenido en el material.
- Evaluar el impacto de la solución mediante pruebas con usuarios reales y métricas de calidad de respuesta.

6.3. Tabla de trazabilidad

La siguiente tabla evidencia el cumplimiento de cada objetivo específico vinculándolo con los requerimientos implementados y la prueba que lo valida.

Objetivo específico	Requerimiento(s)	Evidencia de cumplimiento
Relevamiento de problemáticas	—	Encuesta a 166 estudiantes y 17 docentes UCC (`investigacion/09-relevamiento/`): 80,7 % de estudiantes percibe dispersión de información; 100 % de quienes respondieron ya usa IA generalista para estudiar; 88,2 % de docentes delegaría tareas a una IA integrada al campus.

Objetivo específico	Requerimiento(s)	Evidencia de cumplimiento
Plugin `local` integrado a Moodle	RF-15 a RF-18	Plugin instalable en Moodle 4.1–4.5; pruebas de instalación
Asistente conversacional RAG	RF-01 a RF-07	Chat en producción; `test_retriever`, `test_pipeline`
Generación de cuestionarios	RF-10 a RF-14	Funcionalidad de *quiz* en producción; validación de tema
Analytics y detección de vacíos	RF-20 a RF-22	Reporte de *gaps* por curso; `test` de *gaps recorder*; validado además por el 88,2 % de docentes dispuestos a delegar tareas de analytics/evaluación relevado en la encuesta a docentes
Evaluación con usuarios reales	RNF-06 a RNF-09	Métricas de latencia; *golden set* de calidad de respuesta

PENDIENTE — ajustar la columna de "Evaluación con usuarios reales" con los resultados de las pruebas de usabilidad cuando estén consolidados (TEST-01/TEST-02, fuera del alcance de este relevamiento).

7. Marco teórico

El presente marco teórico proporciona el fundamento conceptual necesario para comprender la problemática, sin plantear todavía una solución específica. El análisis abarca el contexto del problema, las técnicas disponibles y las alternativas existentes en el mercado.

7.1. Contexto general del problema

La incorporación de inteligencia artificial generativa a los entornos educativos ha sido señalada como una de las tendencias tecnológicas más relevantes para la educación superior. Los modelos de lenguaje de gran escala (LLM) son capaces de sostener conversaciones en lenguaje natural, pero su conocimiento proviene de los datos con los que fueron entrenados, por lo que desconocen el material particular de una materia universitaria. Al consultarlos sobre dicho material, tienden a producir respuestas genéricas o, en el peor caso, **alucinaciones**: información plausible pero incorrecta o no fundamentada (Ji et al., 2023).

7.2. Técnicas investigadas

Para que un asistente responda sobre contenido específico de una materia existen tres estrategias principales:

Estrategia	Costo	Flexibilidad	Limitación principal
Prompting puro	Bajo	Baja	El modelo no conoce el material; inventa o se rehúsa
Fine-tuning	Muy alto	Alta	Requiere reentrenar el modelo por cada curso
RAG	Medio	Media-alta	Requiere infraestructura de indexación y recuperación

La técnica de **Retrieval-Augmented Generation** (RAG) combina la búsqueda semántica sobre documentos propios con la generación de texto de un LLM (Lewis et al., 2020). Permite incorporar material nuevo sin reentrenar el modelo, recuperando los fragmentos más relevantes y proveyéndolos como contexto. Diversos trabajos posteriores han sistematizado sus variantes y su aplicación a tareas intensivas en conocimiento (Gao et al., 2023). La calidad del sistema depende de decisiones de diseño como la estrategia de fragmentación (*chunking*), el modelo de *embeddings* y la métrica de similitud empleada.

7.3. Tecnologías investigadas

Además de la técnica general (RAG), se investigó y comparó la pila tecnológica concreta necesaria para implementarla, evaluando alternativas reales antes de decidir cada componente.

7.3.1. Base de datos vectorial

Alternativa	Características	Encaje con la escala del proyecto
pgvector (extensión de PostgreSQL)	Un solo sistema para datos relacionales y vectoriales; permite combinar filtros SQL y búsqueda vectorial en una sola consulta.	Pensado para integrarse a un backend que de todas formas necesita una base relacional, sin sumar una pieza de infraestructura más.
ChromaDB (ChromaDB, s.f.)	Sistema separado de PostgreSQL: las consultas relacionales y vectoriales requieren dos llamadas y lógica de coordinación adicional.	Agrega un segundo sistema a operar y mantener disponible.
Pinecone / Weaviate / Qdrant	Se justifican a partir de decenas de millones de vectores con alta concurrencia.	La escala proyectada de NexusAI (~240.000 vectores para toda la UCC, hasta ~4,8 millones en una expansión multi-institución) queda muy por debajo de ese umbral.

7.3.2. Modelos de lenguaje y *embeddings*

Se comparó el costo y las prestaciones de los modelos de lenguaje candidatos: Gemini 2.5 Flash ofrece una capa gratuita suficiente para un MVP sin costo operativo, pero sin garantías de nivel de servicio para producción (Google, s.f.-a); GPT-4o-mini resulta significativamente más económico que GPT-4o y es la referencia de facto del mercado para este tipo de tareas, reservando GPT-4o para casos de razonamiento más complejo (OpenAI, s.f.-b). Un punto a favor de cualquiera de las dos opciones es que prácticamente todos los proveedores relevantes exponen una interfaz compatible con el SDK de OpenAI —incluido Gemini (Google, s.f.-a)—, lo que habilita una abstracción común sobre ambos sin atarse a un proveedor específico, en lugar de adoptar un *framework* de orquestación como LangChain, cuya API ha mostrado inestabilidad entre versiones.

7.3.3. Arquitectura de plugin Moodle

Moodle admite varios tipos de plugin (`local`, `block`, `mod`, `filter`, `auth`, entre otros), cada uno con su propio ciclo de vida y nivel de integración con el núcleo. Un `block` queda descartado para este caso de uso porque, con el tema Boost de Moodle 4.x, los bloques quedan ocultos en un panel lateral y cada docente debería agregarlo curso por curso manualmente. El **subsistema de IA nativo de Moodle 4.5+** tampoco cubre el caso de uso: carece de un estado de memoria conversacional persistente a lo largo del cuatrimestre, limitación funcional del núcleo que condiciona cualquier asistente que necesite recordar el contexto de una conversación entre

sesiones. Un plugin de tipo `local`, en cambio, permite definir *web services*, tareas programadas y *hooks* propios sin depender de que el docente lo agregue manualmente a cada curso.

7.3.4. Extracción y fragmentación de documentos

Para la extracción de texto de los materiales subidos por el docente se compararon PyPDF2/pypdf (extracción deficiente en PDFs con diseño complejo), pdfminer.six (interfaz más compleja de integrar), PyMuPDF (licencia AGPL, incompatible con la distribución de un plugin que se publica en un directorio de terceros) y pdfplumber (pdfplumber, s.f.), con mejor manejo nativo de tablas y diseño de página que las anteriores. Para la fragmentación (*chunking*), el tamaño del fragmento es en sí mismo un *trade-off*: los fragmentos pequeños mejoran la precisión de la recuperación semántica, mientras que cierto grado de superposición entre fragmentos consecutivos mitiga la pérdida de contexto cuando uno de ellos corta una oración o una idea a la mitad.

7.3.5. Estilos de arquitectura del backend

Para un backend que debe ejecutar varias responsabilidades (conversación, indexación de material, *analytics*) existen, en términos generales, dos estilos: un **monolito** organizado internamente por dominios, o una **arquitectura de microservicios** con un proceso independiente por responsabilidad. Microservicios ofrecen escalado y despliegue independiente por componente, a costa de una complejidad operativa considerable: cada servicio necesita su propio *pipeline* de CI/CD, descubrimiento de servicios y manejo de fallas de red entre procesos que antes eran simples llamadas de función. Para un equipo reducido —en este caso, de tres personas— y una infraestructura con recursos acotados, esa complejidad adicional compite directamente con el tiempo disponible para desarrollar funcionalidad; un monolito organizado por dominios internos ofrece gran parte del orden que los microservicios buscan imponer, sin la sobrecarga operativa de coordinar múltiples procesos desplegados por separado.

7.3.6. Autenticación servicio-a-servicio

Cuando dos servicios propios —no un usuario y un servicio— necesitan autenticarse entre sí sin mantener estado, las alternativas más comunes son HMAC con *timestamp* y *nonce*, JWT, y mTLS. JWT está pensado sobre todo para delegar la identidad de un usuario entre sistemas (por ejemplo, para que un *frontend* pruebe ante un backend quién es el usuario logueado), un problema distinto al de dos servicios propios que ya confían en el canal que los conecta; HMAC resuelve integridad y autenticidad del mensaje con un secreto compartido, sin necesidad de un token con información de identidad. mTLS ofrece una garantía más fuerte a nivel de transporte, pero implica distribuir y rotar certificados en ambos extremos, una carga operativa comparable a la de los microservicios discutida arriba para un equipo y una infraestructura de este tamaño.

Más allá de qué esquema de autenticación usar entre dos servicios propios, hay una pregunta previa: si el navegador del usuario final debe hablar directamente con el backend que orquesta el modelo de lenguaje, o si un intermediario ya autenticado por la plataforma —que actúa como *proxy*— es quien reenvía esa comunicación. Exponer el backend directo al navegador requiere

resolver CORS y, sobre todo, decidir dónde vive la clave del proveedor de IA: si viaja al cliente, cualquier vulnerabilidad de *scripting* del lado del navegador puede filtrarla; un *proxy* autenticado evita ese riesgo porque la clave nunca sale del lado servidor, a costa de un salto de red adicional y de que el intermediario quede en el camino crítico de cada solicitud.

7.3.7. Transporte de respuestas en tiempo real

Para entregar la respuesta de un modelo de lenguaje token por token, en lugar de esperar a que esté completa, las opciones principales son *Server-Sent Events* (SSE) y WebSockets (el *long-polling* queda descartado de entrada por la latencia que agrega). WebSockets ofrece un canal bidireccional persistente, pero requiere un *upgrade* de protocolo HTTP que varios *proxies* y *firewalls* corporativos o universitarios bloquean o manejan de forma inconsistente. SSE, en cambio, es unidireccional (servidor → cliente) y corre sobre HTTP puro, sin *upgrade* de protocolo — suficiente para un caso de uso donde el cliente solo necesita recibir texto a medida que se genera, sin enviar datos por el mismo canal mientras la respuesta está en curso.

7.3.8. Infraestructura de despliegue

Para alojar el backend se compararon tres categorías de infraestructura: un PaaS gestionado (por ejemplo Railway o Fly.io), que simplifica el despliegue a cambio de un costo recurrente y menos control sobre el entorno; una IaaS con nivel gratuito permanente (por ejemplo Oracle Cloud *Always Free*), que exige administrar el sistema operativo y el *stack* de contenedores a mano, pero sin costo mientras el proyecto se mantenga dentro de los límites del nivel gratuito; e infraestructura propia de la institución, que eliminaría el costo de hosting pero depende de un proceso de aprobación administrado por un tercero, con plazos fuera del control del equipo. Esta última opción es justamente la que el relevamiento institucional de la UCC dejó sin resolver dentro del plazo del proyecto (ver *Relevamiento y metodología de investigación → Contexto institucional relevado*), lo que convirtió a una infraestructura autogestionada, independiente de esa aprobación, en la alternativa con menor riesgo de bloqueo para sostener una demo funcionando durante todo el desarrollo.

7.3.9. Validación de datos en los límites del sistema

Para los datos que llegan a una API desde un cliente externo existen, en términos generales, dos posturas. Una validación permisiva acepta y procesa la solicitud aunque lleguen campos no declarados en el contrato —el comportamiento por defecto de buena parte de las herramientas de validación—, lo que la hace más tolerante a cambios del lado del cliente, pero deja pasar en silencio parámetros inesperados, sea por un error de integración o por un intento deliberado de colar un campo no previsto. Una validación estricta, en cambio, rechaza con un error cualquier campo fuera del esquema declarado: sacrifica algo de flexibilidad a cambio de que cualquier desvío del contrato se note de inmediato, en el momento en que ocurre, en lugar de ejecutarse sin aviso.

7.4. Opciones similares en el mercado

Se relevaron asistentes académicos basados en IA existentes, con el fin de comprender el panorama actual y las carencias que el proyecto podría atender, distinguiendo dos grupos: asistentes académicos generales, ajenos al ecosistema Moodle, y plugins de Moodle que ya incorporan IA.

7.4.1. Asistentes académicos generales

- **Khanmigo (Khan Academy):** tutor de IA pedagógicamente pulido, con modo socrático y cuidado explícito de la privacidad de menores, pero responde sobre el contenido de Khan Academy —no sobre el material de cada materia— y no se integra con Moodle (Khan Academy, s.f.).
- **Coursera Coach:** asistente ya conectado a los videos y transcripciones del curso, pero cerrado al ecosistema Coursera, sin apertura a contenido externo (Coursera, 2023).
- **NotebookLM (Google):** ofrece buen RAG con citas precisas, pero requiere que el usuario suba los documentos manualmente, uno por uno, y almacena los datos en servidores de un tercero (Google, s.f.-b).
- **Microsoft Copilot for Education:** fuerte integración con Teams, Word y OneNote, pero centrado en su propio ecosistema, sin integración nativa con Moodle (Microsoft, s.f.).
- **ChatGPT Edu:** máxima potencia del modelo base, pero sin integración con el LMS —el alumno tiene que pegar el contexto manualmente— y sin *analytics* para el docente (OpenAI, s.f.-a).

Producto	Integra con Moodle	RAG sobre material del docente	Self-hosted	Open source	Analytics docente
Khanmigo					parcial
Coursera Coach		sí, en Coursera			parcial
NotebookLM		sí, manual			
MS Copilot Edu		con plugins			parcial
ChatGPT Edu					
NexusAI		sí, automático			

Ningún competidor de este grupo combina integración nativa con Moodle, RAG automático sobre el material del docente y despliegue autohospedado. Con la misma honestidad con la que se reconocen las fortalezas propias, corresponde señalar dónde NexusAI no gana frente a este grupo: Khanmigo acumula años de investigación pedagógica que NexusAI recién empieza a construir, y el modelo de lenguaje de producción (GPT-4o-mini) rinde por debajo de un GPT-4 completo en razonamiento puro —aunque para preguntas y respuestas sobre un contexto ya recuperado

por RAG esa diferencia pesa menos—; Khan Academy y Coursera además ya cuentan con un ecosistema de cursos armado, mientras que NexusAI depende del material que cada docente suba, lo cual es a la vez su limitación y su fortaleza central: contexto real de la materia, no contenido enlatado.

7.4.2. Plugins de Moodle con inteligencia artificial

El panorama relevante para este proyecto no son solo los asistentes académicos generales, sino el ecosistema de plugins de Moodle que ya incorporan IA, por ser la comparación directa con lo que NexusAI propone:

- **`block_openai_chat`** (Bryce Yoder): el plugin de IA más descargado del directorio de Moodle. Ofrece un chat con OpenAI en la barra lateral y un campo "Source of Truth" donde el docente pega texto manualmente como contexto —sin RAG real: si el docente quiere que el bot conozca 200 páginas de apuntes, tiene que pegarlas a mano.
- **`block_ai_chat`** + **`local_ai_manager`** (BYCS): arquitectura modular con subplugins para distintos proveedores (OpenAI, Azure, Anthropic) y soporte multi-tenant, pero sin RAG sobre el material del curso: es un chatbot genérico conectado a un LLM, no distinto en esencia de `block_openai_chat`.
- **`block_terusrag`:** uno de los pocos plugins de Moodle que implementa RAG real sobre el material del curso, pero con *issues* abiertos reportados sobre la calidad de las respuestas, por deficiencias en su *chunking* y recuperación.
- **`local_ai_course_assistant`** (Saylor): el más completo de los cuatro y la referencia arquitectónica más cercana a NexusAI —widget flotante con *streaming* SSE, soporte multi-proveedor, modo socrático y cumplimiento GDPR/SOC2—, pero pensado para instituciones globales, sin Study Planner, *analytics* docente ni generación de evaluaciones.

Característica	`block_openai_chat`	`block_ai_chat`	`block_terusrag`	`local_ai_course_assistant`	NexusAI
RAG auténtico sobre PDFs del curso			con bugs	parcial	
RAG self-hosted (datos en la institución)				parcial	
Chat con historial					
Streaming SSE	parcial	parcial			
Widget flotante en todas las páginas					

Característica	block_openai_chat	block_ai_chat	block_terusrag	local_ai_courseassistant	NexusAI
Indexación automática de material				manual	
Study Planner / cuestionarios con IA					
Analytics docente					
Fallback honesto ante falta de información				parcial	
Agnóstico de proveedor de LLM					

Ninguno de los cuatro combina indexación automática del material del curso, RAG self-hosted de calidad y herramientas de analítica para el docente en una misma solución — ese es, en el ecosistema Moodle específicamente, el vacío que NexusAI ocupa.

Por qué no se adoptó el subsistema de IA nativo de Moodle 4.5+. Moodle 4.5 introdujo un subsistema de IA con arquitectura *Placement* → *Manager* → *Provider*: los *Placements* definen dónde aparece la IA en la interfaz, los *Providers* conectan con APIs externas y el *Manager* media entre ambos, gestionando límites de uso, registro y aceptación de políticas. Su limitación central para este proyecto es que solo expone tres acciones —`generate_text`, `generate_image` y `summarise_text`— sin ninguna acción nativa de conversación con historial persistente, el tipo de interacción que motiva este proyecto. A eso se suma que el subsistema no existe antes de Moodle 4.5, mientras que el proyecto necesitaba compatibilidad desde 4.1 al momento de diseñarse. Ambas limitaciones apuntan en la misma dirección que la comparación de tipos de plugin de la sección anterior: un plugin autocontenido, que no dependa de la maduración de un subsistema todavía incompleto, resulta más adecuado para este caso de uso.

El principal riesgo competitivo identificado es que Moodle HQ madure este subsistema nativo y agregue una acción de chat con historial en una versión futura; la mitigación considerada es que el diferencial de NexusAI no se limita al chat, sino que incluye Study Planner, *analytics* docente y foros con IA —funcionalidades que exceden el alcance de lo que el subsistema nativo expone incluso en un escenario de maduración.

8. Propuesta de solución

La propuesta de solución describe cómo se aborda el problema planteado, a partir de lo analizado en el marco teórico. Esta es la sección más técnica del trabajo.

NexusAI es un plugin de Moodle con asistente de IA que combina tres capas: un plugin de tipo `local` (Moodle HQ, 2024) dentro de Moodle, una interfaz de chat embebida y un backend que orquesta el pipeline RAG. La pieza diferencial es el **RAG auténtico**: el material que el docente sube a Moodle se indexa automáticamente y el asistente responde citando la fuente; si la pregunta no puede responderse con el material disponible, el sistema lo admite explícitamente en lugar de inventar.

8.1. Alcance funcional

El sistema delimita claramente lo que entra y lo que queda fuera de su alcance actual. El MVP (junio de 2026) fue el primer hito funcional; el desarrollo continuó después de esa entrega, ampliando el alcance original.

Funcionalidades del MVP (junio 2026):

- Asistente conversacional RAG con respuesta en *streaming* y citas trazables al fragmento de origen.
- Buscador semántico (recuperación pura, sin LLM) sobre el material del curso.
- Chat multi-curso opcional, con citas que indican la materia de cada fragmento.
- Gestión de material por parte del docente: carga de PDF, indexación automática asíncrona, visualización de estado y borrado en cascada.
- Generador de cuestionarios de opción múltiple a partir del material, con feedback inmediato.
- Panel de detección de vacíos de contenido (*gaps*) para el docente.

Funcionalidades incorporadas después del MVP:

- Foros con detección automática de posts similares o duplicados mientras el alumno escribe, resumen de hilos largos y sugerencia de respuesta con RAG para el docente.
- Panel de analítica docente con preguntas frecuentes agrupadas por tema, a partir de un registro anonimizado de las interacciones del chat.
- Generador de exámenes a partir del material del curso, exportable al formato GIFT nativo de Moodle.
- Modo Estudio ampliado: más tipos de pregunta (verdadero/falso, abiertas, flashcards), historial de errores persistido en el backend, y un plan de estudio personalizado que combina errores de práctica, vacíos de contenido detectados en el chat y el próximo examen del calendario del curso.
- Filtros de búsqueda por tipo de material y por unidad/sección del curso.
- Vista de calendario con próximos exámenes y entregas.
- Soporte de material en PPTX, XLSX, CSV, Markdown y HTML además de PDF, con reconocimiento óptico de caracteres (OCR) de respaldo para documentos escaneados.

- Rediseño de la interfaz (agosto de 2026): el chat pasó de un *dropdown* flotante a un panel lateral acoplado, y el panel del docente se unificó en un lenguaje visual consistente de tipo *dashboard*, con paneles de material, vacíos de contenido, preguntas frecuentes, generación de exámenes y búsqueda integrados bajo la misma navegación.

Fuera de alcance (excluido conscientemente): soporte multi-institución nativo, integración con mensajería externa, y contenido multimedia, entre otros (ver detalle en *Anexos*).

Los requerimientos funcionales (RF-01 a RF-22) y no funcionales (RNF-01 a RNF-21) que detallan el alcance del MVP se encuentran documentados en los Anexos.

8.2. Diseño

8.2.1. Arquitectura del software

La arquitectura adoptada es **cliente-servidor en tres capas** con un backend organizado como **monolito modular**. El navegador del estudiante nunca se comunica directamente con el backend: toda llamada pasa por el plugin de Moodle, que actúa como proxy autenticado (patrón *Hybrid PHP Proxy*). Este diseño resuelve tres cuestiones de manera simultánea: la clave de la API del LLM nunca llega al navegador, la protección ante CSRF queda cubierta por el mecanismo nativo de Moodle, y se evitan los problemas de CORS al existir una única comunicación servidor-a-servidor. Como se observa en la Figura 1, el navegador solo habla con el plugin PHP, que es quien reenvía cada solicitud al backend y a los proveedores de LLM y *embeddings*.

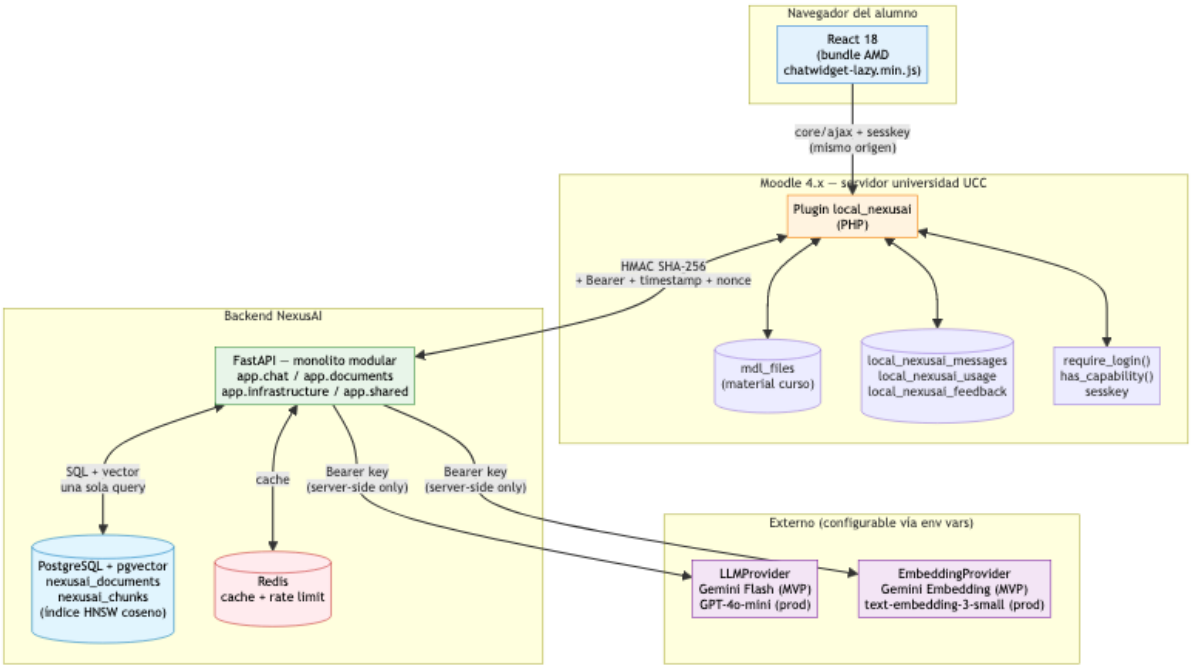


Figura 1. Diagrama de componentes de NexusAI (navegador, plugin Moodle, backend y servicios externos). *Fuente:* elaboración propia (`docs/diagrams/architecture.md`). *Texto alternativo:* esquema de tres capas que conecta el navegador con el plugin PHP, este con el backend FastAPI, y el backend con la base de datos vectorial y los proveedores de LLM y *embeddings*.

8.2.2. Patrones de diseño

El sistema aplica el patrón *Hybrid PHP Proxy* para el aislamiento de credenciales y la abstracción **multi-proveedor** de LLM y *embeddings*, que permite cambiar de proveedor mediante variables de entorno, sin modificar el código de aplicación.

8.2.3. Interfaz de usuario

La interfaz de chat se dispara desde un ícono en la barra de navegación de Moodle y se despliega como un panel lateral acoplado al borde derecho de la pantalla, de ancho fijo y alto completo, en lugar del *dropdown* flotante de las primeras versiones. Presenta la respuesta en *streaming*, citas clickeables que expanden el fragmento utilizado con su porcentaje de similitud, e historial de conversaciones por sesión, todo dentro del mismo panel. En dispositivos móviles el panel se comporta como una hoja a pantalla completa (*bottom-sheet*). Como se observa en la Figura 2a, el panel responde con el texto en *streaming* y la cita a la fuente debajo de la respuesta.

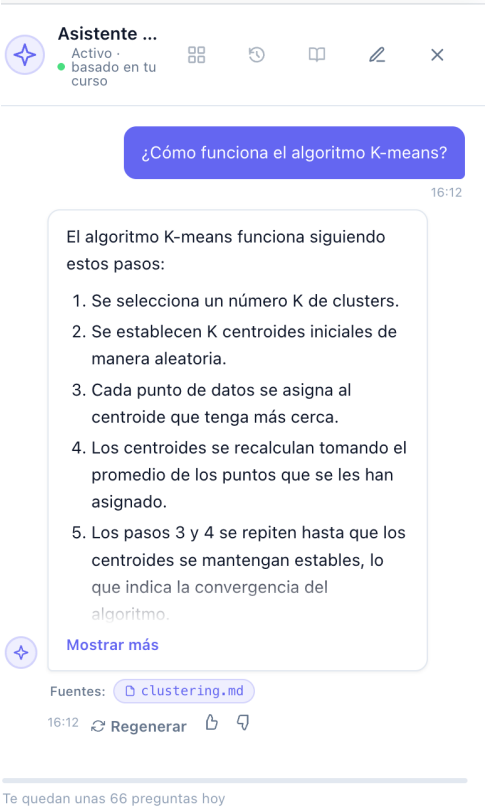


Figura 1: Figura 2a

Figura 2a. Widget de chat respondiendo a una pregunta sobre K-means con cita a la fuente. *Fuente:* elaboración propia, captura de la versión actual desplegada localmente (panel lateral post-rediseño de agosto). *Texto alternativo:* una conversación donde el asistente explica el algoritmo K-means en pasos numerados, con un chip "Fuentes: clustering.md" debajo de la respuesta.

El panel docente ofrece, además, un buscador semántico sobre el mismo material indexado, como se observa en la Figura 2b.



Figura 2: Figura 2b

Figura 2b. Buscador semántico del panel docente, con el término "K-means" resaltado dentro del resultado. *Fuente:* elaboración propia, captura de la versión actual desplegada localmente. *Texto alternativo:* un campo de búsqueda con filtros por tipo de archivo y unidad, devolviendo un fragmento de texto con dos coincidencias del término buscado resaltadas.

Desde el mismo panel, el docente gestiona el material indexado y su estado, según se muestra en la Figura 2c.

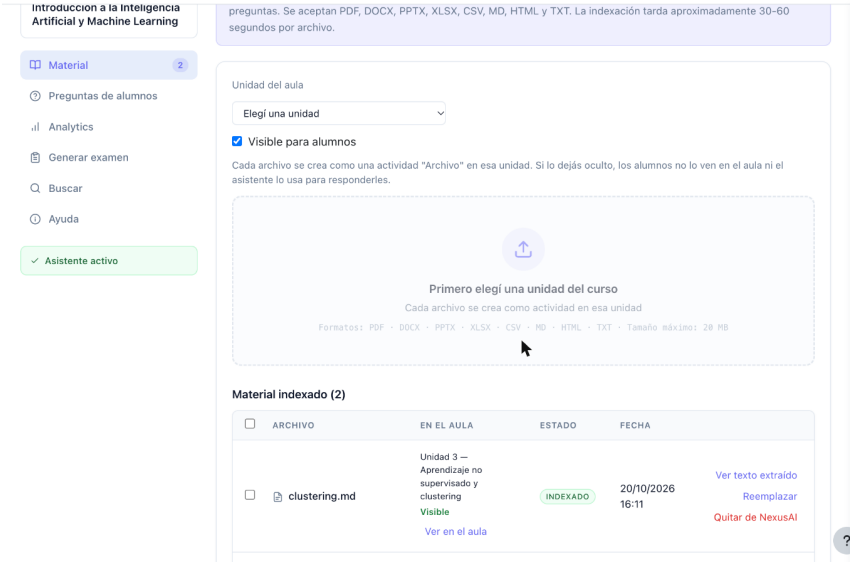


Figura 3: Figura 2c

Figura 2c. Panel del docente: gestión de material indexado. *Fuente:* elaboración propia, captura de la versión actual desplegada localmente. *Texto alternativo:* la tabla de materiales subidos, con la unidad del curso asignada, el estado de indexación y si el material está visible para los alumnos.

El panel también expone las preguntas de alumnos sin responder, es decir los vacíos de contenido detectados, como se observa en la Figura 2d.



Figura 4: Figura 2d

Figura 2d. Panel del docente: preguntas de alumnos sin responder (vacíos de contenido). *Fuente:* elaboración propia, captura de la versión actual desplegada localmente. *Texto alternativo:* una pregunta real de alumno ("¿Qué es el clustering?") marcada como "sin match", es decir, sin una respuesta bien respaldada por el material indexado en ese momento.

8.2.4. Proceso de diseño de la interfaz

El panel lateral descrito arriba es el resultado de dos iteraciones previas, documentadas en `docs/diseno/`.

El primer concepto (`wireframes-mvp.html`, issue FRONT-01/#158, 05/05/2026) era un *dropdown* flotante disparado por un ícono, no un modal de pantalla completa — decisión justificada explícitamente para que el alumno pueda leer el material del curso y conversar con el asistente al mismo tiempo, con Intercom, Crisp y el *widget* de ChatGPT nombrados como referencia. El *wireframe* define cinco estados de la vista de alumno (cerrado, bienvenida, conversando, cargando, y error —este último mostrando el texto real del error del backend, por ejemplo un HTTP 503, con opción de reintentar—) y cuatro de la vista docente (vacío con zona de arrastrar y soltar, indexando con una barra de progreso marcada explícitamente como estimada, ya que el backend solo reporta `pending`/`indexing`/`indexed`/`error` y no un porcentaje real, lista de materiales ya indexados, y configuración del *plugin*). De las seis decisiones de diseño documentadas con su *trade-off*, dos son especialmente relevantes para el resto del informe: mostrar las fuentes citadas junto a cada respuesta en vez de solo el texto generado, atado al principio de "no inventar" que gobierna el diseño del asistente; y la indexación asíncrona del material, para no bloquear la interfaz del docente durante los 30 a 60 segundos que puede tardar procesar un PDF.

El panel lateral que describe esta sección es, en cambio, el resultado de un rediseño posterior (`rds-01` a `rds-07`, 10 al 12/08/2026, issue #400): el *dropdown* original, con *resize* libre en sus cuatro bordes, se reemplaza por un panel acoplado al borde derecho de alto completo, que angosta de verdad el contenido de la página de Moodle (con un *fallback* silencioso si el tema activo no expone el selector esperado o el *viewport* es angosto), agrega un riel colapsado como

nueva forma de reabrirlo, y elimina el cierre al hacer clic afuera —un panel acoplado ya no tiene sentido que se cierre solo por tocar el contenido del curso, ahora angostado y literalmente al lado—. La misma semana se rediseñaron, con el mismo criterio, el historial de conversaciones (de superponerse en una capa a convertirse en una vista más del propio panel) y la navegación del panel docente (de pestañas horizontales a un menú lateral).

En paralelo, `docs/diseno/v0-prompts.md` (28 al 30/07/2026) documenta una capa de pulido visual sobre componentes de React que ya funcionaban, no un rediseño de lógica: *prompts* listos para pegar en v0.dev, la herramienta de Vercel para generar interfaces a partir de una descripción (v0, s.f.) —no debe confundirse con un *prompt* del asistente de IA del proyecto—. Los cinco *prompts* trabajados (*widget* de chat, plan de estudio personalizado, *quiz* del modo estudio, buscador semántico, panel docente) comparten un mismo bloque de sistema de diseño tomado de `react/src/styles.css` sin inventar uno nuevo: color primario `#6366f1`, radios de 4 a 16 píxeles, iconografía de trazo simple sin emojis, y referencias estéticas a Linear, Vercel y v0.dev mismo. El tamaño fijo del panel que fijan estos *prompts* —400×600 píxeles en escritorio, *bottom-sheet* a pantalla completa en *mobile*— coincide con el que ya describe esta misma subsección. Otras seis pantallas quedaron en una lista de pendientes, todavía sin *prompt* escrito.

Las Figuras 2a a 2d de esta sección son capturas de la versión actual del *widget*, posterior al rediseño de agosto recién descrito.

8.3. Implementación

La solución se construyó de manera incremental, dividida en módulos lógicos:

- **Módulo de asistente conversacional (chat):** orquesta el pipeline RAG y el *streaming* de respuestas.
- **Módulo de gestión de documentos:** extracción de texto, fragmentación, generación de *embeddings* e indexación asíncrona.
- **Módulo de búsqueda semántica:** recuperación de fragmentos por similitud.
- **Módulo de cuestionarios (*quiz*):** generación de preguntas de opción múltiple.
- **Módulo de detección de vacíos (*gaps*):** registro de consultas no resueltas y reporte agregado para el docente.
- **Módulo de seguridad:** autenticación HMAC SHA-256 en tres capas (clave de API, firma y *nonce* anti-replay).

El pipeline de indexación procesa los documentos de forma asíncrona: extrae el texto, lo divide en fragmentos de aproximadamente 512 tokens con solapamiento, genera los *embeddings* y los almacena en una base de datos PostgreSQL con la extensión **pgvector** (pgvector, s.f.), actualizando el estado del documento (`pending → indexing → indexed | error`).

Como se observa en la Figura 3, la secuencia completa de una consulta del estudiante atraviesa autenticación, limitación de tasa, búsqueda vectorial y generación de la respuesta en *streaming*:

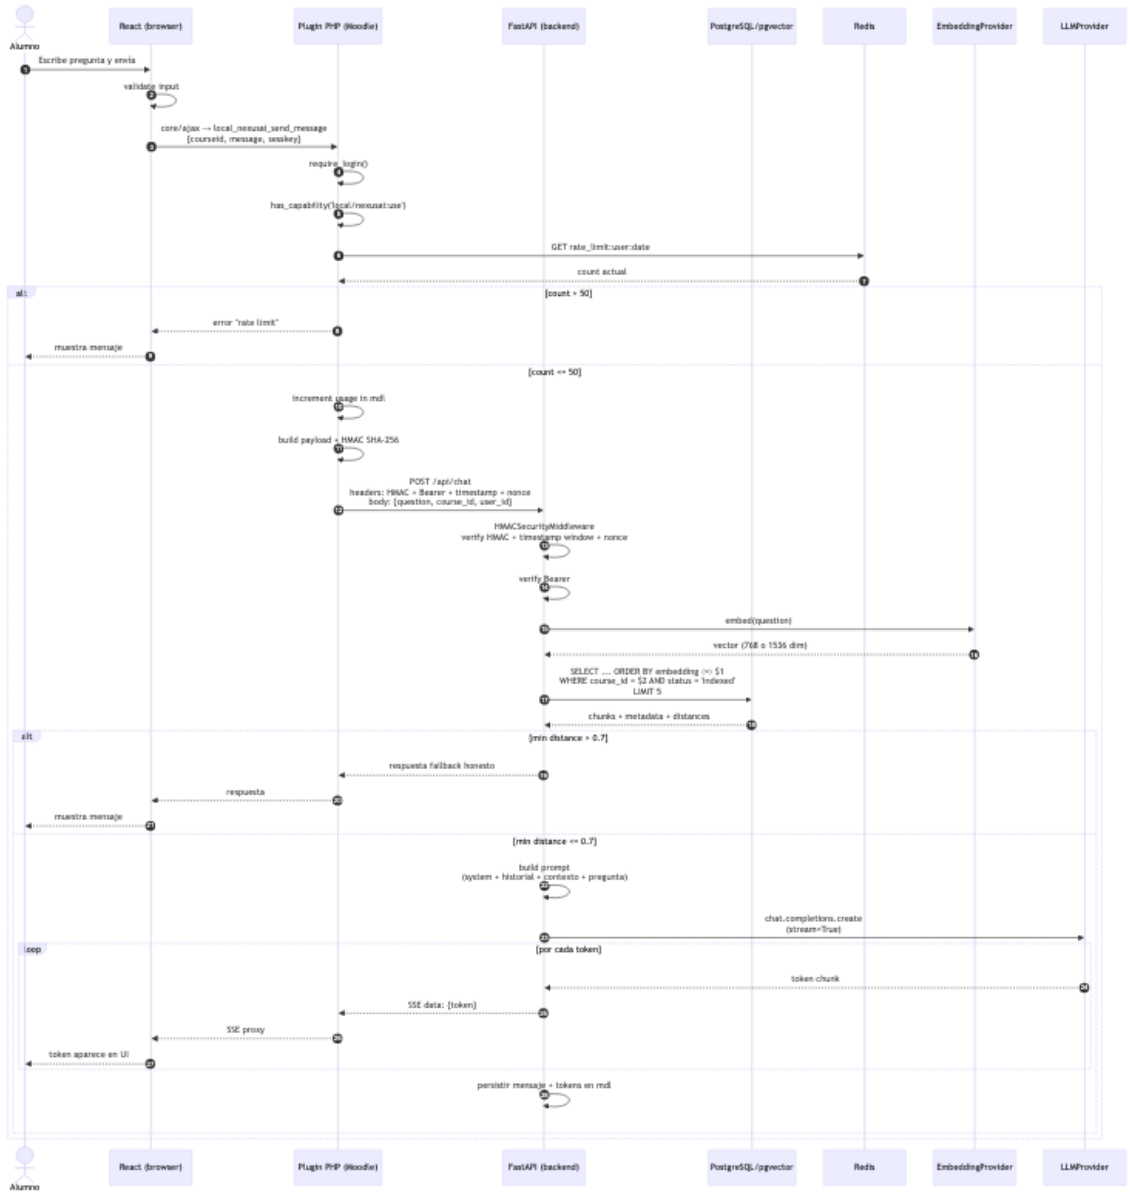


Figura 3. Diagrama de secuencia de una consulta del estudiante. *Fuente:* elaboración propia (`docs/diagrams/sequence-chat.md`). *Texto alternativo:* secuencia desde que el alumno escribe una pregunta hasta que recibe la respuesta en streaming, pasando por autenticación, rate limiting, embedding de la pregunta, búsqueda vectorial y generación con el LLM.

El pipeline de indexación corre en paralelo, de forma asíncrona y previa a cualquier consulta: la Figura 4 muestra el flujo completo, desde que el docente sube un documento hasta que queda disponible para la búsqueda vectorial.

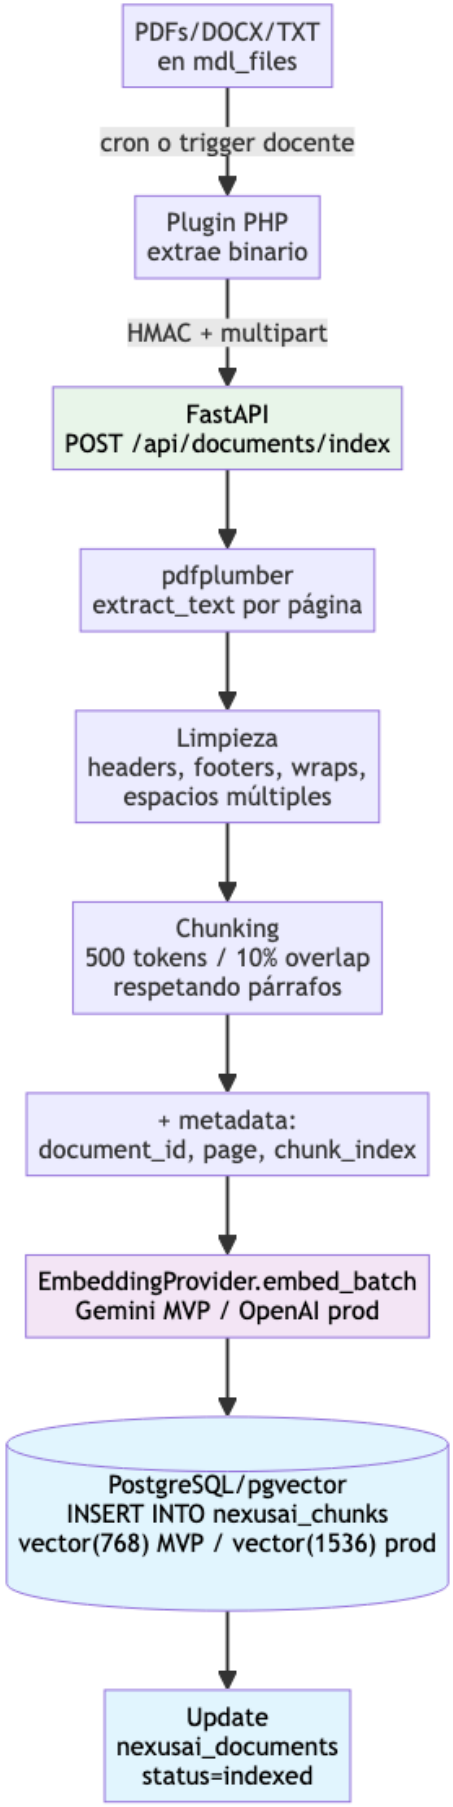

PDFs/DOCX/TXT
en mdl_files
cron o trigger docente
Plugin PHP
extrae binario
HMAC + multipart
FastAPI
POST /api/documents/index
pdfplumber
extract_text por página
Limpieza
headers, footers, wraps,
espacios múltiples
Chunking
500 tokens / 10% overlap
respetando párrafos
+ metadata:
document_id, page, chunk_index
EmbeddingProvider.embed_batch
Gemini MVP / OpenAI prod
PostgreSQL/pgvector
INSERT INTO nexusai_chunks
vector(768) MVP / vector(1536) prod
Update
nexusai_documents
status=indexed

Figura 4. Pipeline de indexación de material (offline). *Fuente:* elaboración propia (`docs/diagrams/rag-flow.md`). *Texto alternativo:* flujo desde que el docente sube un documento hasta que queda indexado como chunks vectoriales, pasando por extracción de texto, limpieza, fragmentación y generación de *embeddings*.

8.3.1. Funcionalidades post-MVP

Los seis módulos descritos arriba son los que entregó el MVP de junio de 2026. El desarrollo siguió después, organizado en epopeyas (`docs/presentaciones/NexusAI_Avances_2026-08-06.md`) que ya se nombran como alcance en "Alcance funcional", pero sin mostrar nunca cómo se ven realmente en uso. Esta sección cierra ese vacío con capturas del entorno desplegado localmente, como se observa en las Figuras 5a y 5b.

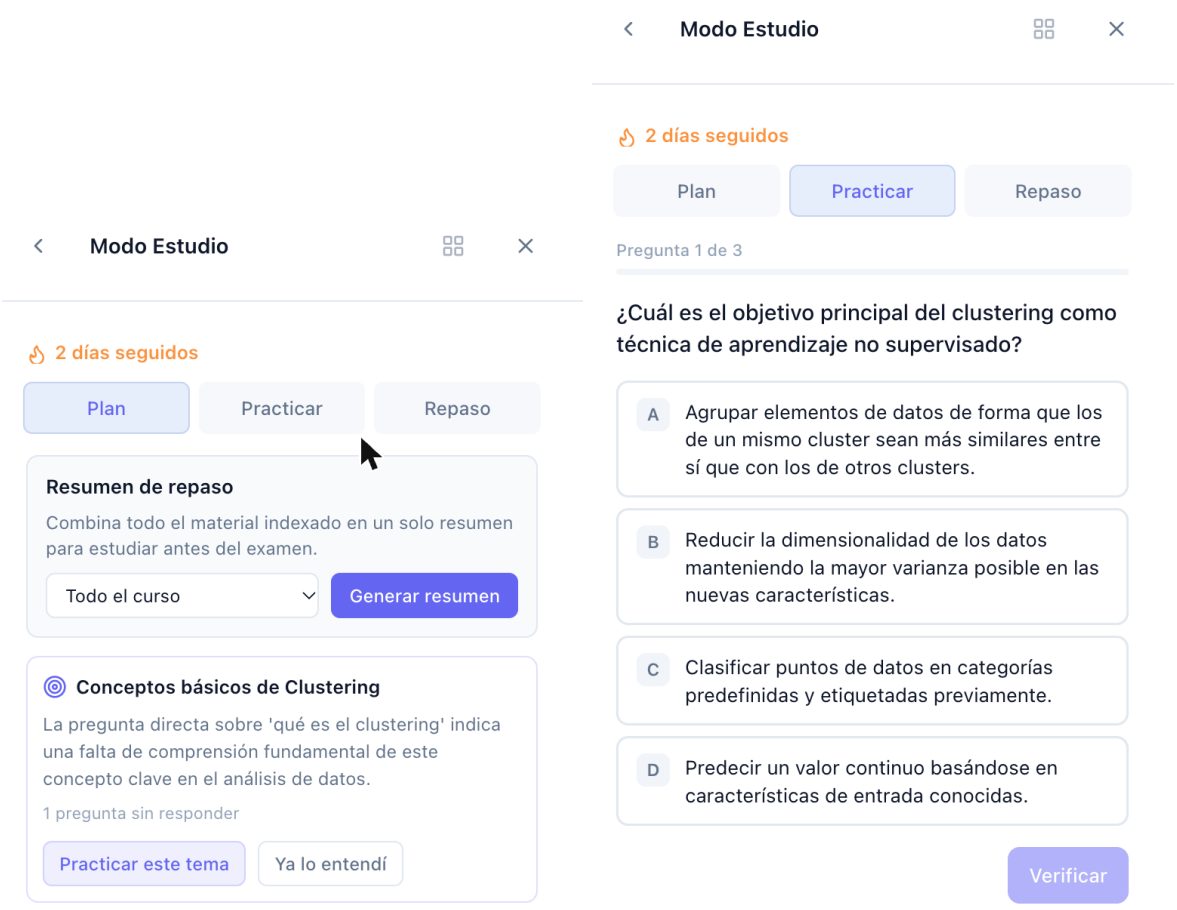


Figura 5a/5b. Modo Estudio: plan de repaso (izquierda) y *quiz* de práctica (derecha). *Fuente:* elaboración propia, capturas de la versión actual desplegada localmente. *Texto alternativo:* a la izquierda, una recomendación de repaso generada a partir de un vacío de contenido detectado, con botones "Practicar este tema" y "Ya lo entendí"; a la derecha, una pregunta de opción múltiple de un *quiz* de práctica, con cuatro alternativas y un botón "Verificar".

El plan de repaso cruza dos fuentes que ya existen en el backend: los vacíos de contenido del módulo de *gaps* ya descrito, y los errores cometidos en *quizzes* anteriores. Sobre ese mismo

quiz de práctica se agregaron después *flashcards* con repetición espaciada (algoritmo SM-2, SP-11/#315, 07/09/2026), que no se capturan acá por no tener una pantalla propia distinta del *quiz*. El calendario y el resumen semanal del foro, en cambio, sí tienen pantalla propia, como se observa en las Figuras 6a y 6b.

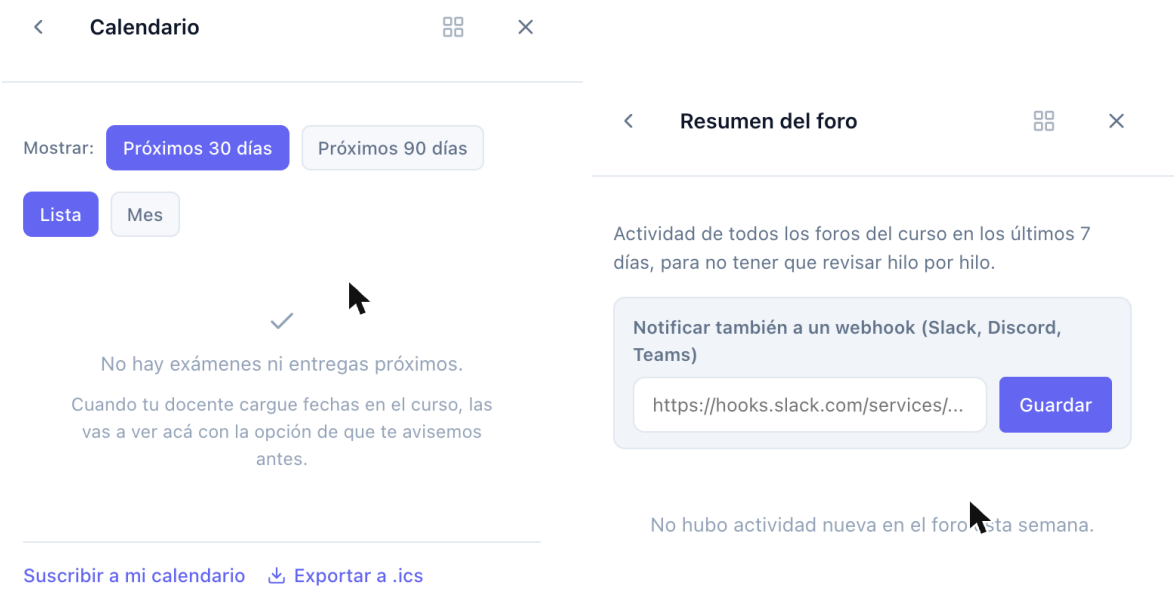


Figura 6a/6b. Calendario de próximas entregas (izquierda) y resumen semanal del foro (derecha). *Fuente:* elaboración propia, capturas de la versión actual desplegada localmente. *Texto alternativo:* a la izquierda, un estado sin exámenes ni entregas próximas, con opciones de suscribirse al calendario o exportarlo como `.ics`; a la derecha, un resumen sin actividad nueva en el foro esa semana, con un campo para notificar también a un *webhook* externo.

El calendario (CAL-02) expone las fechas del curso como *feed* `.ics` suscribible; un *bug* posterior de ese mismo *feed* —incluía usuarios suspendidos o eliminados— ya está contado en "Correcciones de la primera ronda" de la publicación en el Moodle Marketplace, sin repetirlo acá. El resumen del foro nació junto con los foros con asistencia de IA del MVP extendido, y sumó después la opción de reenviar el mismo resumen semanal a un *webhook* de Slack, Discord o Teams (FOR-07/#378, 08/09/2026), para que el docente no tenga que entrar a Moodle a leerlo.

El mismo panel docente agrupa automáticamente las preguntas de los alumnos por tema, como se observa en la Figura 7.

Figura 7. Panel docente: preguntas de alumnos agrupadas por tema. *Fuente:* elaboración propia, captura de la versión actual desplegada localmente. *Texto alternativo:* dos temas detectados a partir de preguntas reales de alumnos, cada uno con la cantidad de veces consultado y un ejemplo de la pregunta original.

El panel de *Analytics* reúne estas y otras métricas de uso del curso en una sola vista, como se observa en la Figura 8.

Figura 8. Panel docente: *Analytics*. *Fuente:* elaboración propia, captura de la versión



Figura 5: Figura 7

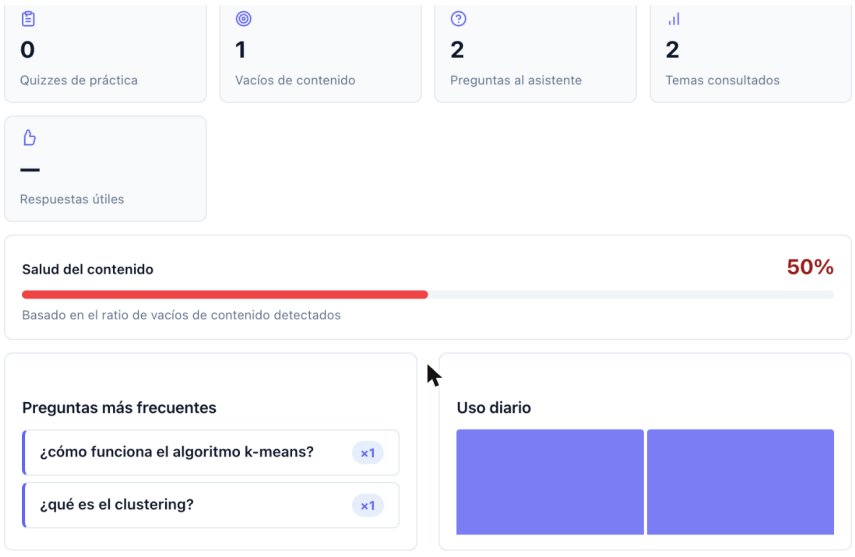


Figura 6: Figura 8

actual desplegada localmente. *Texto alternativo:* métricas de uso del curso —*quizzes* de práctica, vacíos de contenido, preguntas al asistente, temas consultados—, un indicador de "salud del contenido" y la lista de preguntas más frecuentes.

El generador de exámenes completa el panel docente, como se observa en la Figura 9.

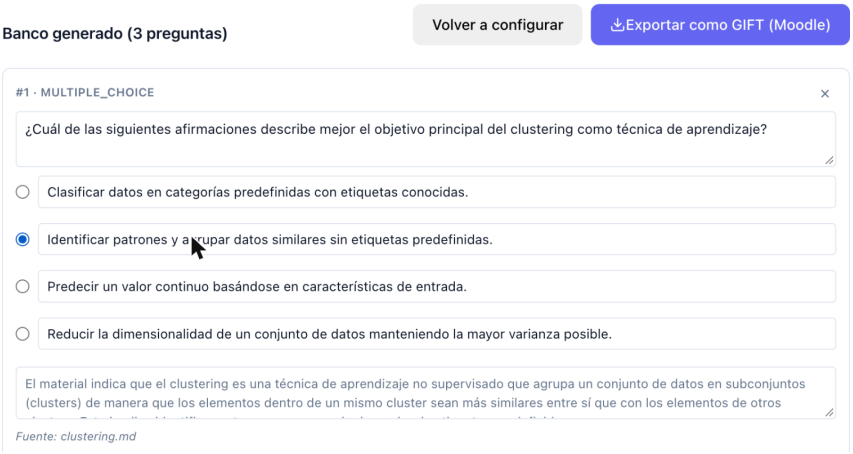


Figura 7: Figura 9

Figura 9. Panel docente: generador de exámenes. *Fuente:* elaboración propia, captura de la versión actual desplegada localmente. *Texto alternativo:* una pregunta de opción múltiple generada a partir del material del curso, con la fuente citada debajo y un botón para exportar el banco completo en formato GIFT de Moodle.

Las preguntas frecuentes de la Figura 7 comparten el mismo backend de analítica que la Figura 8 (DOC-D01): el texto de cada pregunta se normaliza y se agrupa primero, y recién después un LLM le pone nombre al tema resultante — pero el conteo de cuántas veces se preguntó cada tema siempre se recalcula en Python, nunca se le confía al LLM, el mismo criterio de no inventar que ya gobierna el resto del asistente. El generador de exámenes (EVAL-01/#235) pide que el docente elija a mano los archivos de origen en vez de usar todo el material del curso automáticamente, y resuelve la exportación al formato GIFT del lado del *frontend*, no del backend.

8.4. Arquitectura técnica del backend

Las Figuras 1 y 3 muestran la arquitectura y el flujo de una consulta a nivel de componentes y secuencia; esta sección describe el mecanismo real detrás de cada pieza marcada en esos diagramas (`investigacion/05-backend-fastapi/`).

8.4.1. Autenticación HMAC en tres capas

El plugin y el backend son dos servicios independientes, y la clave del proveedor de IA vive solo en el backend. Por eso el navegador nunca habla directamente con FastAPI: todas las solicitudes pasan por un *proxy* PHP dentro de Moodle (`investigacion/05-backend-fastapi/autenticacion-hmac.md`), lo que evita exponer la clave en el cliente, elimina la necesidad de CORS entre dominios y reutiliza la sesión ya autenticada de Moodle. El lado PHP usa la clase `curl` propia de

Moodle en lugar de `file_get_contents`, porque muchas instalaciones universitarias deshabilitan `allow_url_fopen`; esa clase respeta además `$CFG->proxyhost/proxyport` y las listas `curlsecurityblockedhosts/curlsecurityallowedport` que fija cada institución, habitualmente limitadas a los puertos 80 y 443 — razón por la que el backend solo necesita responder en 443, dado que conseguir que el equipo de TI de una universidad habilite un puerto no estándar puede tardar entre dos y ocho semanas.

Del lado del servidor, un `HMACSecurityMiddleware` se aplica a toda solicitud salvo `/docs`, `/openapi.json` y `/health` (`investigacion/05-backend-fastapi/lifespan-y-estado.md`). Verifica, en orden: (1) que el *timestamp* esté dentro de la ventana de tolerancia de 5 minutos ya fijada en ADR-005; (2) que el *nonce* no se haya visto antes, contra un almacén de nonces (hoy un conjunto en memoria, con la migración a Redis con `SET NX EX 300` prevista en el propio ADR-005 como paso a producción); y (3) que la firma HMAC-SHA256 coincida, comparada con `hmac.compare_digest` para evitar *timing attacks* (Krawczyk et al., 1997). La implementación amplía la cadena canónica que firma ADR-005 (`timestamp + nonce + body`) agregando también el método HTTP y el *path* (`MÉTODO\nPATH\ntimestamp\nnonce\nbody`), de modo que una firma válida para un endpoint no pueda reutilizarse contra otro. El cuerpo de la solicitud se lee una vez para validarlo y se reinyecta en el *stream* de la petición para que el router de destino pueda volver a leerlo. Además de JWT y mTLS —descartados en ADR-005—, se descartó exponer el backend directamente al navegador vía CORS, por el riesgo de que la clave del proveedor de IA terminara visible en el cliente; el esquema de tres capas mitiga específicamente el ataque de *replay* que un esquema de solo `Bearer` no cubre (OWASP, s.f.-a).

8.4.2. Esquema de base de datos: alcance vigente y migración de dimensión

El Anexo B documenta el modelo de datos vigente y los parámetros del índice HNSW (`m=16`, `ef_construction=200`); por ADR-002 y ADR-014, hoy PostgreSQL/pgvector indexa únicamente los *chunks* del material de curso, ya que los datos del alumno se movieron a tablas nativas de Moodle. Un detalle operativo que no está en ningún otro capítulo (`investigacion/05-backend-fastapi/database-schema.md`) es la migración de dimensión de los *embeddings* al pasar de Gemini (MVP, 768 dimensiones) a OpenAI (producción, 1536 dimensiones) bajo ADR-004: los vectores de un modelo no son comparables con los de otro, así que no alcanza con cambiar el tipo de columna. El procedimiento elimina el índice HNSW existente, modifica la columna `embedding` a la nueva dimensión, recrea el índice y marca todos los *chunks* con `status = 'pending'` para que el pipeline de indexación (Figura 4) los vuelva a procesar y reemplace sus vectores con el nuevo modelo.

8.4.3. Streaming de respuestas: *Server-Sent Events*

La Figura 3 ya muestra el flujo de una consulta en tiempo real; el presupuesto de latencia detrás de esa figura (`investigacion/05-backend-fastapi/sse-streaming.md`) es de aproximadamente 130 ms para la búsqueda vectorial y cercano a 200 ms hasta el primer token visible para el alumno. Se eligió *Server-Sent Events* sobre *WebSockets* porque el canal es unidireccional (servidor → cliente, suficiente para un chat), corre sobre HTTP/443 puro sin *upgrade* de protocolo,

y varios *proxies* y *firewalls* universitarios bloquean o manejan mal el *handshake* de WebSocket, mientras que una respuesta SSE se ve, a efectos de la red, como una respuesta HTTP larga común. El formato en el cable es simple (`data: {"token": "..."}\n\n`, con un evento final `completion`); el endpoint FastAPI envuelve un generador asíncrono con `EventSourceResponse` (sse-starlette, s.f.) que consulta la API de OpenAI en modo *streaming* y revisa en cada iteración si el cliente se desconectó, para dejar de generar —y de pagar— tokens en cuanto el alumno abandona la conversación. El patrón *Hybrid PHP Proxy* de la sección anterior se mantiene también para el *streaming*: el `EventSource` del navegador habla con el *endpoint* AJAX de Moodle, que reenvía el flujo del backend sin romperlo.

8.4.4. Contratos de datos: *schemas* Pydantic

Las solicitudes y respuestas del backend se validan con Pydantic V2 (`investigacion/05-backend-fastapi/pyd`
Pydantic, s.f.). El *schema* de entrada declara `model_config = ConfigDict(extra='forbid')` como decisión explícita de seguridad: a diferencia del comportamiento por defecto de Pydantic V1, que ignora en silencio cualquier campo no declarado, esta configuración rechaza con un error 422 cualquier campo extra en el cuerpo de la solicitud —por ejemplo, un campo `admin_token` agregado por error o con intención maliciosa— en lugar de aceptarlo sin aviso. El *schema* de salida incluye un `confidence_score` entre 0 y 1; cuando cae por debajo de un umbral, la interfaz debe advertir al alumno que la respuesta se basa en información parcial, en vez de presentarla con la misma certeza que una respuesta bien respaldada por el material del curso. Para las respuestas que necesitan esa estructura garantizada, el backend usa *Structured Outputs* de OpenAI (`client.beta.chat.completions.parse`), que fuerza al modelo a decodificar dentro del *schema* declarado; esto es una garantía más fuerte que pedir `response_format={"type": "json_object"}`, que solo asegura JSON sintácticamente válido, sin garantizar que las claves y tipos coincidan con el *schema* esperado.

8.4.5. Ciclo de vida y estado de la aplicación

FastAPI dejó obsoletos los *hooks* `@app.on_event("startup"/"shutdown")` desde la versión 0.95, en favor de un *context manager* asíncrono `lifespan` (`investigacion/05-backend-fastapi/lifespan-y-estad`
FastAPI, s.f.). En el arranque, ese bloque inicializa una única vez el cliente de la base vectorial y lo expone en `app.state`, compartido entre todas las solicitudes sin reabrir la conexión en cada una; en el mismo punto de armado de la aplicación se registra el `HMACSecurityMiddleware` descrito más arriba, de modo que la seguridad y el estado compartido de la app se configuran juntos, antes de que el servidor empiece a aceptar tráfico.

8.5. Arquitectura técnica del plugin Moodle

Esta sección completa, del lado del plugin, el mecanismo que la sección anterior describió del lado del backend (`investigacion/01-moodle/`, `investigacion/06-frontend-react/`): cómo se inyecta el widget en la página, cómo se controla quién puede usarlo, cómo se expone (y se consume) la capa de integración con Moodle, y cómo convive React —pensado para *bundlers* modernos— dentro del sistema de módulos AMD de Moodle.

8.5.1. Inyección del widget: Hook API y *callback* legado

Moodle 4.4 introdujo una API de *hooks* tipada (PSR-14) que reemplaza a los *callbacks* por convención de nombre. El equipo verificó durante el Sprint 1, sobre un build real de Moodle 4.5 (`2024042200`), que el *callback* legado `before_footer()` sigue ejecutándose en 4.4 en adelante, pero **su valor de retorno ya no se imprime** — Moodle solo emite una advertencia de deprecación (`investigacion/01-moodle/hooks-y-apis.md`). Para no romper el widget en ninguna versión soportada, NexusAI implementa los dos mecanismos a la vez: el *callback* legado `local_nexusai_before_footer()` en `lib.php` sigue activo para Moodle 4.1–4.3, y un *listener* tipado (`classes/hook/output/before_footer_listener.php`, registrado en `db/hooks.php` contra `\core\hook\output\before_footer_html_generation::class`) atiende 4.4 en adelante usando `$hook->add_html(...)` en lugar de un `return`. El *callback* legado se protege con un *guard* de versión (`if ((int)$CFG->version >= 2024041600) return '';`) para no inyectar el widget dos veces cuando ambos caminos están activos. Antes de inyectar nada, ambos caminos validan `isloggedin()`, `!isguestuser()`, `$COURSE->id > 1` y `has_capability('local/nexusai:use', $context)`, y llaman a `$PAGE->requires->js_call_amd('local_nexusai/chatwidget-lazy', 'init', [[...]])` con `courseid`, `userid`, `sesskey`, `wwwroot` y `lang` (Moodle HQ, s.f.-b).

8.5.2. Capabilities y control de acceso

El acceso al plugin se controla con tres *capabilities* declaradas en `db/access.php` (`investigacion/01-moodle/seguridad-capabilities.md`; Moodle HQ, s.f.-a): `local/nexusai:use` (lectura, contexto de curso, permitida a estudiante, docente, docente editor y administrador), `local/nexusai:manage` (escritura, riesgo `RISK_CONFIG`, solo docente editor/administrador) y `local/nexusai:reindex` (escritura, riesgo `RISK_DATALOSS`, mismo alcance que `:manage`). El patrón de verificación es siempre `require_login($course)` → `context_course::instance()` → `require_capability(...)`. El secreto compartido con el backend se almacena vía `admin_setting_configpasswordunmask` (nunca en texto plano visible en el formulario) y se recupera con `get_config('local_nexusai', 'shared_secret')`. La Privacy API (`classes/privacy/provider.php`) no es opcional: un plugin sin ella no pasa la revisión de Moodle.org, y debe declarar al proveedor de IA como una *external location* (`add_external_location_link('llm_provider', ...)`) con un nombre deliberadamente genérico, no atado a un proveedor puntual — consistente con la abstracción `LLMProvider` ya vista en ADR-003 y con el hecho de que, por ADR-006 y ADR-014, los datos personales del alumno terminaron viviendo en tablas nativas de Moodle y no en el backend. (Una fuente del proyecto, `arquitectura-plugin-detallada.md`, registra una iteración anterior de estos mismos nombres —`local/nexusai:usechat` y `local/nexusai:manageconfig`, esta última a nivel de sistema—; el resto del informe y las Figuras 1 y 3 ya usan `:use`/`:manage`/`:reindex`, por lo que esta sección se ancla a esos tres nombres.)

8.5.3. *Web services*: el patrón de tres métodos

Moodle expone sus funciones externas en tres capas: una interfaz de servidor externo (REST/SOAP/XML-RPC), una API pública en PHP que extiende `external_api`, y una API interna de bajo nivel que no valida nada por sí misma y confía en que la capa pública ya lo hizo (`investigacion/01-moodle/webservices-teoria.md`; Moodle HQ, s.f.-e). Toda función externa sigue el mismo patrón obligatorio de tres métodos: `execute_parameters()` define un contrato tipado que bloquea inyección de parámetros no esperados, `execute()` debe empezar siempre con `validate_parameters()` y seguir con `validate_context()` y `require_capability()` antes de tocar cualquier dato, y `execute_returns()` sanea la salida con `external_api::clean_return_value()`. NexusAI decidió **no** habilitar Web Services REST para la comunicación Moodle→FastAPI —esa llamada la resuelve el *proxy* PHP interno con autenticación HMAC ya descrito en "Autenticación HMAC en tres capas"—, pero sí los **consume** en sentido inverso: para extraer el material de un curso, el backend llama a `core_course_get_contents` con un token de servicio, recorre secciones y módulos, filtra los archivos PDF y los descarga adjuntando el mismo token a la URL del archivo. El Subsistema de IA nativo de Moodle 4.5+ —que resolvería parte de este problema sin plugin propio— se descartó explícitamente por su limitación de diseño: solo soporta solicitudes atómicas de pedido/respuesta, sin memoria conversacional persistente a lo largo de un cuatrimestre, que es exactamente el caso de uso de NexusAI.

8.5.4. React como módulo AMD

Moodle organiza su JavaScript en módulos AMD/RequireJS compilados con Grunt, mientras que React se piensa para *bundlers* modernos con módulos ES/CommonJS y encapsulación propia — dos mundos que no se integran directamente (`investigacion/06-frontend-react/integracion-moodle-amd.`
Moodle HQ, s.f.-c). La solución adoptada compila todo el frontend de React en un único *bundle* AMD autocontenido (`amd/build/chatwidget-lazy.min.js`) que exporta una función `init()`, montada con `createRoot` (React, s.f.) y cargada por Moodle con `js_call_amd()`. Un detalle fácil de pasar por alto: los parámetros de `js_call_amd()` deben pasarse como un arreglo anidado dentro de otro arreglo (`[[...]]`) — el arreglo externo se expande como argumentos posicionales de `init()`, así que el arreglo interno llega como un único objeto; un arreglo plano entregaría los parámetros como argumentos sueltos en lugar de un objeto. El sufijo `-lazy` en el nombre del archivo es obligatorio: sin él, el sistema de agrupamiento de módulos AMD de Moodle fusionaría el *bundle* de React (grande, con su propio runtime) con otros módulos AMD, generando errores de módulo duplicado. React se comunica con Moodle únicamente a través de `core/ajax`, que agrega automáticamente el `sesskey` (protección CSRF), reutiliza la sesión ya autenticada y mantiene el mismo origen —sin necesidad de CORS. Durante el Sprint 1 el equipo encontró y documentó un *bug* real de producción: los `import()` dinámicos de Webpack (Webpack, s.f.) (`import('react')`, `import('./ChatApp')`) generan *chunks* que, sin `output.publicPath` configurado, se resuelven en relación con la URL del último script que el navegador ejecutó —en este caso, el CDN de MathJax—, lo que producía un `ChunkLoadError` real intentando cargar el *chunk* desde `cdn.jsdelivr.net`. La corrección tuvo dos partes obligatorias: fijar `publicPath` a la ruta real del *bundle* en el plugin y desactivar la división

de código (`splitChunks: false`, `runtimeChunk: false`), y reemplazar todos los `import()` dinámicos por *imports* estáticos en el punto de entrada.

8.5.5. Empaquetado con Webpack

La configuración de Webpack 5 (`investigacion/06-frontend-react/webpack-config.md`) declara como *externals* a `core/ajax`, `core/str`, `core/notification`, `core/templates` y `jquery`: no se empaquetan dentro del *bundle* de React porque Moodle ya los expone en tiempo de ejecución, lo que permite reutilizar el *sesskey*/CSRF de `core/ajax`, las cadenas de idioma de Moodle en `core/str`, su sistema de notificaciones, y evitar una segunda copia de `jquery` corriendo junto a la que varios módulos núcleo de Moodle ya esperan como variable global. El CSS del widget usa *CSS Modules* con el prefijo `nexusai-` en cada clase, para no colisionar con las clases del tema Boost/Bootstrap que Moodle ya carga en toda la página. El tamaño final del *bundle* —React 18 más la interfaz de chat propia— ronda los 200-220KB comprimidos, dentro del umbral de 512KB que Webpack usa para advertir sobre *bundles* demasiado grandes. Por convención para plugins distribuibles de Moodle, el archivo compilado `amd/build/chatwidget-lazy.min.js` se commitea al repositorio junto con el código fuente de React, en lugar de generarse solo en una *pipeline* de build separada.

8.6. Pruebas

La estrategia de pruebas se organizó en nueve ciclos documentados como issues `TEST-01` a `TEST-09`, todas cerradas durante el Sprint 4 (MVP), cada una con un responsable y un alcance específico.

8.6.1. Pruebas unitarias y de integración (backend)

`TEST-02` cubrió la *suite* unitaria del backend en Python con **pytest** (pytest, s.f.), sobre RAG, *embeddings*, *chunking* y los *endpoints* de FastAPI. A la fecha de redacción de este capítulo, esa *suite* (`services/api/tests/`) tiene 530 funciones de test en 41 archivos —más que el *snapshot* de 37 tests que registra el Anexo C, porque la *suite* siguió creciendo después del MVP; ambos números son correctos, cada uno en su momento. Usa `@pytest.mark.asyncio` para los *endpoints* asíncronos, `@pytest.mark.parametrize` para cubrir variantes de un mismo caso, y *fixtures* de `conftest.py` (`fake_redis`, `fake_openai_chat_response`, `fake_chat_stream`) con `AsyncMock`/`MagicMock` y *dependency overrides* de FastAPI para simular Redis y al proveedor de LLM sin llamadas de red reales. Un archivo aparte, `tests/integration/test_llm_real.py`, se mantiene deliberadamente fuera de ese *mocking*: corre contra el proveedor de LLM real, para no depender únicamente de respuestas simuladas.

Las pruebas de integración restantes fueron manuales: `TEST-03` verificó el flujo completo React → *plugin* PHP → backend Python → proveedor de LLM con datos reales; `TEST-04` probó el *plugin* en un *sandbox* real de Moodle con usuarios de prueba; `TEST-05` encadenó ambas en una sesión *end-to-end* completa, desde que un alumno abre el chat hasta que recibe una respuesta sobre material real de curso.

8.6.2. Pruebas automatizadas del frontend (Vitest)

Antes de la issue `#311` (*QA-01*), el *widget* de React no tenía ningún test automatizado — ni Vitest (Vitest, s.f.) ni Jest estaban siquiera declarados en su `package.json`. La issue proponía priorizar los componentes con más estado (`StudyPlanPanel`, `AnalyticsDashboardPanel`, `ExamGeneratorPanel`); lo que efectivamente se implementó, en cambio, priorizó la lógica pura y la capa de API: `gift.js` (la conversión al formato GIFT de Moodle) llegó al 100 % de cobertura como pedía la issue, y se suman pruebas de los módulos `api/*.js` y de un componente de manejo de errores — ocho archivos, 65 casos en total. Los paneles con estado que la issue señalaba como prioridad quedaron sin cubrir; se cuenta esta desviación tal cual, no como si el plan original se hubiera cumplido punto por punto. La *suite* corre en `frontend-ci.yml`, que sube el reporte de cobertura como artefacto de *build*; todavía no exige un umbral mínimo para pasar el CI, algo que una épica posterior de calidad de software agrega por fuera de esta issue.

8.6.3. Evaluación de calidad del asistente: dos campañas

`TEST-08` produjo `golden_set.md`: una rúbrica manual de doce preguntas sobre contenido de base de datos, evaluadas en tres criterios de 1 a 5 (Relevancia, Completitud, Honestidad). Esa corrida, ejecutada en el MVP, es la que ya resume el Anexo C (8 de 10 preguntas respondidas correctamente con citación adecuada, 2 de 2 casos donde el asistente admitió correctamente no poder responder, cero falsos positivos o negativos) — no se repite esa tabla acá.

Existe una segunda campaña, automatizada y mucho más reciente (`investigacion/02-rag/eval-dataset.jso`
y `eval-report.json`, 11/09/2026), que **no es la misma corrida con otro formato**: reusa las doce preguntas de `golden_set.md`, agregándoles palabras clave de referencia para automatizar el *scoring*, pero las corre contra un *fixture* sintético bajo un `course_id` dedicado (`990001`) en lugar del plan original de 30-50 preguntas anotadas por un docente real sobre material de curso genuino — ese plan más ambicioso nunca se ejecutó, y se documenta como limitación en lugar de ocultarlo. Mide en tres niveles: *retrieval* (ocho preguntas con respuesta esperada en el material) con **Recall@5 = 1,00** (objetivo >= 0,85, cumplido), **Precision@5 = 0,275** (objetivo >= 0,50, no cumplido, explicado por un corpus de prueba muy chico —unos nueve *chunks* en total— donde casi todo el top-5 son vecinos legítimos por superposición de *chunking*, no ruido) y **MRR = 0,9375** (objetivo >= 0,70, cumplido); *faithfulness* de la respuesta generada, evaluada por un segundo LLM como juez (de un proveedor distinto al que genera la respuesta en producción, para que el modelo no se autoevalúe); y honestidad del *fallback* ante las cuatro preguntas deliberadamente fuera de material. En esta corrida en particular, la cuota gratuita de Gemini se agotó a mitad de la ejecución y el modelo de *fallback* configurado resultó estar descontinuado, devolviendo error en vez de una respuesta — de las ocho preguntas de *faithfulness* solo dos llegaron a evaluarse (una fiel, una parcial por corte de respuesta) y ninguna de las cuatro de *fallback* se pudo medir. El propio reporte distingue explícitamente "no medible" de "0 % de honestidad", y el hallazgo en sí —un modelo de respaldo roto que convierte una degradación esperable en un error duro— es, más allá del número, el resultado más valioso de haber corrido esta evaluación.

8.6.4. Pruebas de aceptación, usuarios reales y rendimiento

`TEST-06` sumó *feedback* real de usabilidad y precisión de tres a cinco compañeros de la UCC usando el asistente con contenido real de curso. `TEST-09` midió tiempos de respuesta con el objetivo de mantener un promedio menor a 10 segundos. `TEST-07` cerró el ciclo con la corrección de los *bugs* encontrados en los pasos anteriores y una verificación de regresión. (Las pruebas automatizadas del *plugin* en sí —PHPUnit y Behat— se describen en "Prácticas de seguridad del plugin", no acá, por tratarse de una *suite* distinta a la del backend.)

> **PENDIENTE** — arreglar el modelo de *fallback* descontinuado y re-correr completos los niveles de *faithfulness* y honestidad de la evaluación automatizada; ampliar el *dataset* a 30-50 preguntas con un docente real sobre material de curso genuino; integrar `ragas` y pytest al CI para que esta evaluación corra en cada *pull request*, no solo manualmente.

9. Seguridad y cumplimiento

Las secciones anteriores describieron la arquitectura de seguridad desde el diseño (autenticación HMAC, *capabilities*, Privacy API). Este capítulo da respaldo concreto a esas decisiones: una auditoría de seguridad real ejecutada sobre el proyecto, la estrategia de privacidad bajo la que opera, y las prácticas del plugin que todavía no se explicaron en profundidad.

9.1. Auditoría de seguridad: OWASP Top 10 y análisis de dependencias

En agosto de 2026 el equipo ejecutó una auditoría de seguridad formal sobre el proyecto (`docs/security/owasp-audit-2026-08.md`), combinando análisis automatizado de dependencias (`pip-audit` en el backend, `npm audit` en el *widget* de React) con un *checklist* manual del OWASP Top 10 (OWASP, s.f.-b) aplicado específicamente a NexusAI. El escaneo de dependencias del backend pasó de 43 CVEs en 11 paquetes a 12 CVEs en 3: dos paquetes sin uso real en el código (`python-jose[cryptography]`, `python-multipart`) se eliminaron por completo —verificado por `grep` en todo `app/`, ya que la autenticación usa el módulo `hmac` de la librería estándar, no JWT, y las subidas de archivo son JSON+base64, no *multipart*—, `Pillow` se actualizó de 10.4.0 a 12.3.0, y las 12 CVEs restantes quedan **aceptadas y documentadas por CI, no ignoradas en bloque**: `starlette` está fijado por la versión de FastAPI en uso (una corrección completa implicaría migrar cada *router*), `pdfminer-six` está fijado transitivamente por `pdfplumber`, el núcleo del *pipeline* de extracción de PDF del sistema RAG (actualizarlo sin pruebas dedicadas arriesga romper la función central del producto), y `pytest` es una dependencia de desarrollo que nunca llega a producción. El frontend pasó de 6 vulnerabilidades (1 baja, 1 moderada, 4 altas) a 0, resueltas con `npm audit fix` sin forzar actualizaciones mayores; la auditoría destaca en particular `dompurify`, que sanitiza las respuestas del asistente antes de insertarlas en el DOM (`MessageBubble.jsx`) — la única superficie real de XSS del *widget*. Como hallazgo colateral, la auditoría encontró que el *workflow* de CI del frontend apuntaba a un `package.json` que no existe (la ruta real está un nivel más abajo, en `react/`), por lo que ese *job* nunca había corrido realmente en ningún PR anterior; se corrigió como parte de esta misma issue.

El *checklist* OWASP Top 10 aplicado al proyecto confirma, entre otros puntos: **A01 (control de acceso roto)** mitigado — todo *endpoint* exige `verify_hmac` y toda función externa de Moodle valida contexto y *capability* antes de delegar, con el `user_id` siempre tomado de `$USER->id`, nunca controlable por el alumno; **A02 (fallas criptográficas)** mitigado por el esquema HMAC de tres capas ya descrito; **A03 (inyección/XSS)** mitigado por *queries* parametrizadas y el saneo de respuestas con `DOMPurify` mencionado arriba; **A07 (fallas de autenticación)** mitigado por el *nonce* anti-*replay* en Redis y el uso de `compare_digest` para comparar secretos; y **A09 (fallas de *logging* y monitoreo)**, marcado como parcialmente cubierto: existe *logging* estructurado de acceso, pero la auditoría confirma explícitamente, tras revisar el código de chat, cuestionarios y foros, que **en ningún lugar se registra el contenido en texto plano de los mensajes**. La auditoría también documenta, con honestidad, los *gaps* que quedan abiertos: el límite de 50 consultas diarias por alumno está documentado como decisión de diseño pero **no implementado en código** (solo el límite por minuto sí corre en producción), y no existe moderación de contenido

sobre las respuestas del asistente. Esta auditoría es la evidencia directa que respalda **RNF-01** (la clave del proveedor de IA nunca llega al navegador), **RNF-02** y **RNF-03** (HMAC en tres capas, rechazo de firmas/timestamps/*nonces* inválidos) y **RNF-05** (un alumno no puede leer sesiones de chat ajenas); **RNF-04** (validación de la *capability* `local/nexusai:use`) queda respaldado por el punto A01 del *checklist* y por el capítulo de Capabilities ya descrito en la arquitectura del plugin.

9.2. Estrategia de privacidad y cumplimiento normativo

El Anexo E ya resume las decisiones de ADR-006 y ADR-014 —los disparadores que llevaron de `null_provider` a mover los datos del alumno a tablas nativas de Moodle, y los tres números de latencia que motivaron el cambio—; esta sección desarrolla el marco de cumplimiento detrás de esas decisiones, que el Anexo E no profundiza. El propio ADR-006 encuadra la estrategia de privacidad bajo dos marcos normativos explícitos: la Ley de Protección de Datos Personales argentina (Ley 25.326) y el RGPD europeo, y enumera las categorías concretas de datos personales en juego: los mensajes que el alumno envía al chat, el historial de conversación, el vínculo entre el `user_id` de Moodle y las sesiones/*embeddings*, y las métricas de uso. Una limitación real que el ADR documenta sin suavizar: la Privacy API de Moodle permite a un administrador exportar o borrar los datos personales que viven en tablas de Moodle, pero **no alcanza al backend externo en Python** — mientras los datos del alumno vivieron ahí (antes de ADR-014), un pedido de derecho al olvido requería coordinación manual con quien administra el backend, no un botón en la interfaz estándar de Moodle. Por eso, antes de desplegar el proyecto con alumnos reales fuera del entorno de prueba, el ADR deja pendiente la firma de un **Acuerdo de Tratamiento de Datos (DPA)** con la UCC, con responsabilidad asignada a Belén Zarazaga (Admin de Proyectos) para coordinarlo con el área legal de la universidad.

Un hallazgo concreto de la migración de ADR-014, más valioso que cualquier afirmación general de cumplimiento: al revisar las métricas de uso para decidir qué datos mover, el equipo encontró que el identificador de usuario usado en esas métricas era un hash **SHA-256 sin sal** de un número entero (el `user_id` de Moodle) — un esquema de pseudonimización roto en la práctica, porque el espacio de IDs de usuario es lo suficientemente chico como para recalcular el hash de cada ID posible y revertirlo por fuerza bruta. El propio proyecto identificó y documentó esta falla como parte de endurecer su postura de privacidad, no como un hallazgo externo. La migración en sí incorporó mecánica de retención explícita: *backups* previos, un ensayo completo sobre una copia de producción en *staging*, verificación de conteos y consumo por curso/mes antes de dar la migración por buena, y las tablas viejas del backend se archivaron durante 60 días antes de borrarlas definitivamente, en lugar de eliminarlas de inmediato. **RNF-14** del Anexo A quedó desactualizado por este mismo cambio de arquitectura — ya no describía la estrategia vigente, sino `null_provider`, la del MVP previo a ADR-014; esa fila ya se corrigió en el Anexo A como parte del ensamblado final del informe.

9.3. Prácticas de seguridad del plugin

Más allá de las *capabilities* y el patrón de autorización ya descritos, `seguridad-capabilities.md` documenta un conjunto de prácticas de seguridad a nivel de código que todavía no aparecían en el informe. El plugin nunca lee `$_GET`/`$_POST` directamente: todo parámetro de entrada pasa por `required_param()` u `optional_param()` con una constante `PARAM_*` (`PARAM_INT`, `PARAM_TEXT`, `PARAM_ALPHANUMEXT`, etc.), que valida y sanea el tipo antes de que el valor llegue a cualquier lógica de negocio. El código se valida además contra el estilo de codificación de Moodle con `local_codechecker`. Los errores del backend o del proveedor de IA se manejan con `moodle_exception` y un mensaje amigable para el usuario — nunca con `die()` o `exit()`, que cortarían la ejecución de Moodle de forma abrupta — y cada interacción relevante con el asistente se registra a través de la Events API de Moodle para fines de auditoría. Las pruebas del plugin se automatizan con PHPUnit para la lógica de negocio y Behat para los flujos de usuario, mockeando el proveedor de LLM para que los resultados sean deterministas — un nivel de prueba que `## Pruebas` no menciona, porque esa sección describe la cobertura del backend, no la del plugin. Por último, `thirdpartylibs.xml` declara cada librería de terceros empaquetada en el plugin —React, Webpack y sus dependencias— con su nombre, versión y licencia, un requisito de la revisión de Moodle.org.

La misma fuente incluye una tabla de riesgos y mitigaciones pensada explícitamente para la defensa ante el jurado: la exposición de la clave del proveedor de IA se mitiga con el patrón *Hybrid PHP Proxy* ya descrito; el acceso entre cursos se mitiga filtrando por `course_id` en la búsqueda vectorial y validando la *capability* en el contexto del curso; que un alumno vea respuestas de otro se mitiga con el campo `userid` en cada mensaje y el filtrado correspondiente; que un alumno evite `require_login` se mitiga porque esa validación es la primera línea de toda función externa; y un cambio de proveedor de LLM se resuelve solo con configuración, gracias a la abstracción `LLMProvider`. El riesgo más específico de la lista —y el que ningún *checklist* genérico como el OWASP Top 10 de la sección anterior cubre— es la **inyección de *prompt*** a través del material de curso: un documento subido por un docente podría contener texto diseñado para manipular al modelo de lenguaje. La mitigación documentada es estructurar el *prompt* con delimitadores explícitos y una instrucción de sistema firme que el contenido del curso no puede sobreescribir.

10. Despliegue e infraestructura

10.1. Topología: del plan original a las dos VMs reales

El ADR-011 (Anexo E) ya cuenta por qué el backend pasó por tres destinos de despliegue distintos a lo largo del proyecto hasta quedar en Oracle Cloud. Esta sección documenta cómo es ese despliegue en la práctica, no por qué cambió. Como se observa en la Figura 10, el plan original ubicaba el backend sobre infraestructura propia de la UCC.

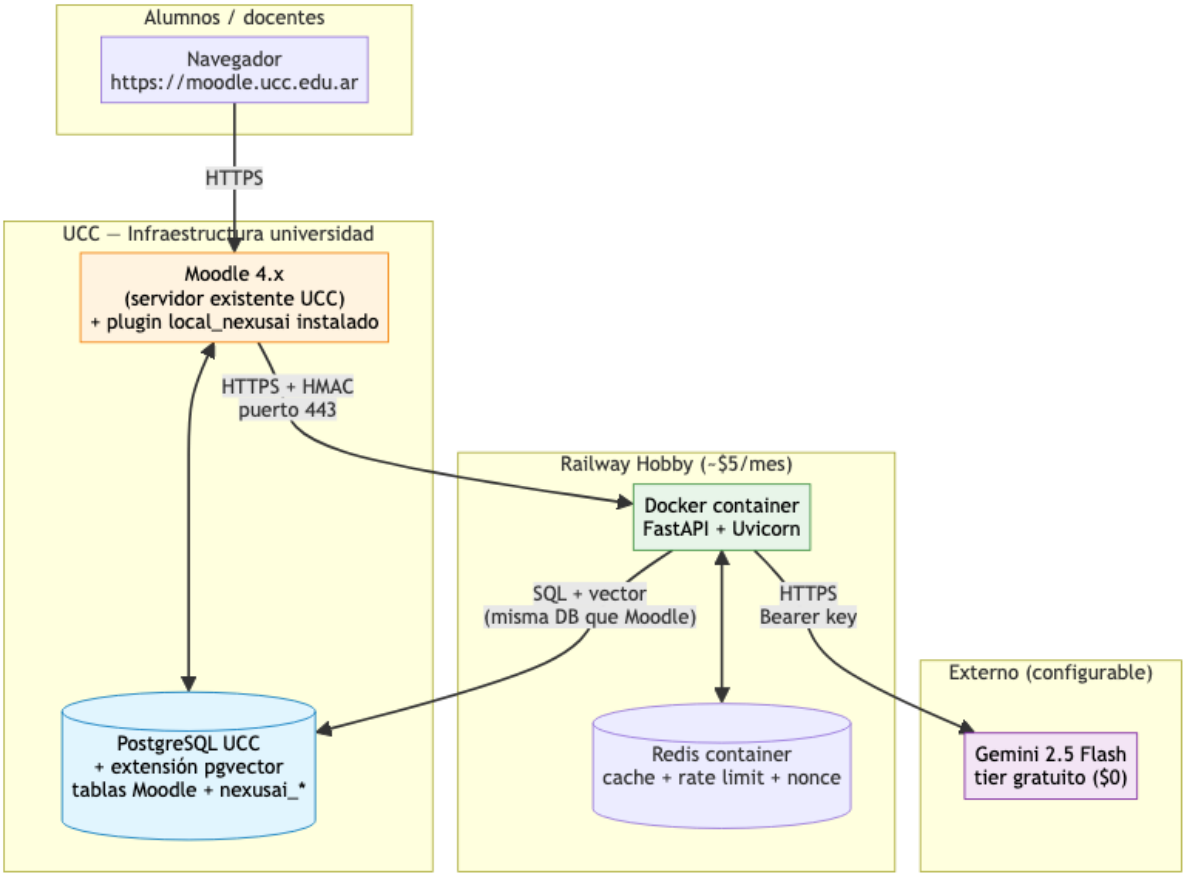


Figura 10. Arquitectura de despliegue originalmente planificada en mayo de 2026, sobre infraestructura propia de la UCC (Railway/Hetzner, PostgreSQL de la universidad). *Fuente:* elaboración propia (`docs/diagrams/deployment.md`). **No vigente**: se conserva tal cual, sin reescribirla, por el mismo criterio que ya aplica ADR-011 a la documentación histórica del proyecto. El despliegue real reemplazó Railway/Hetzner y el PostgreSQL de la UCC por infraestructura autogestionada en Oracle Cloud, y nunca llegó a correr Moodle junto al resto del *stack*.

La Figura 11, en cambio, muestra la topología real, vigente desde agosto de 2026:

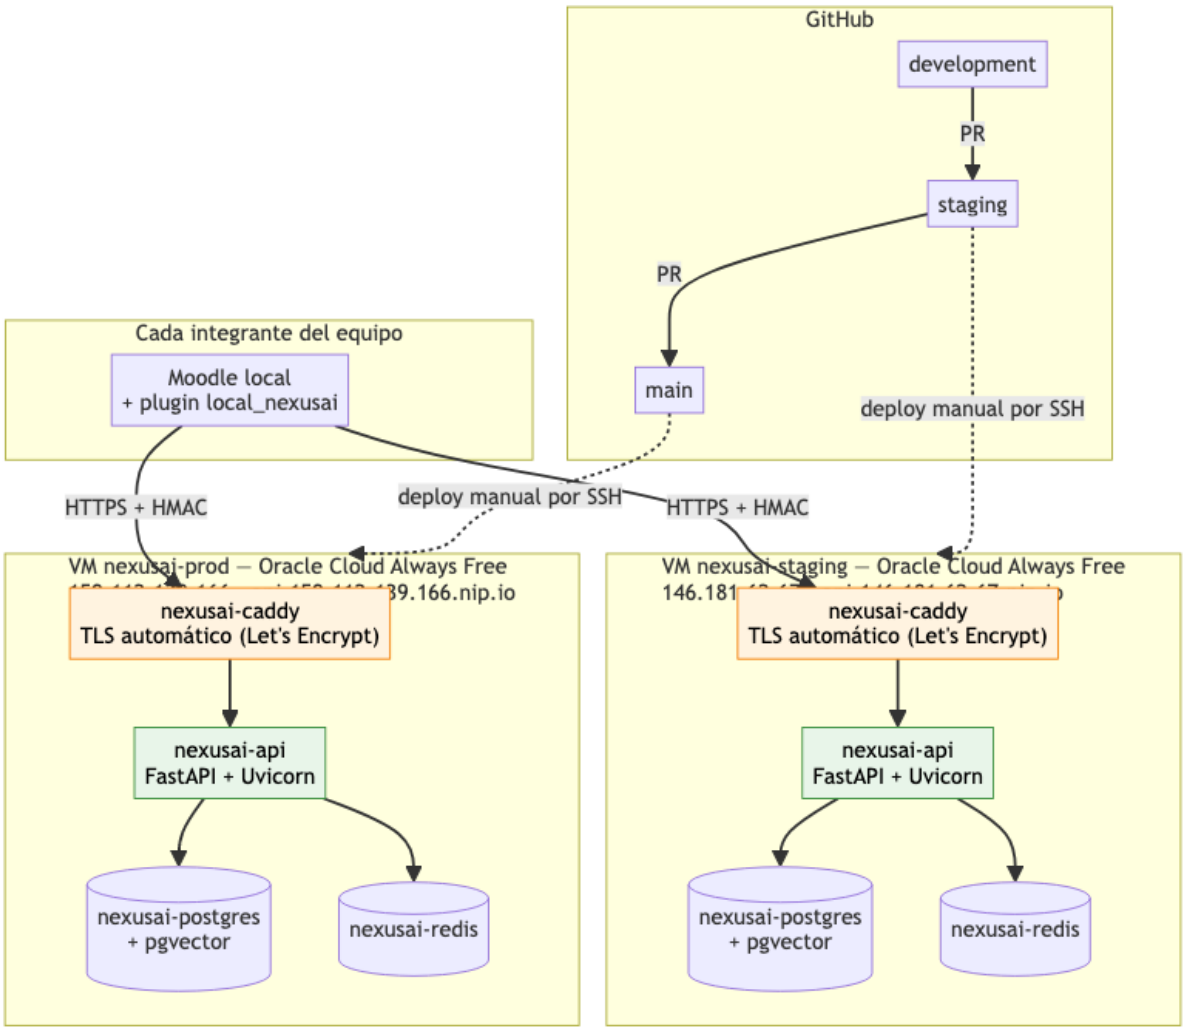


Figura 11. Topología real del despliegue, vigente desde agosto de 2026. *Fuente:* elaboración propia (`docs/DEPLOY_ORACLE.md`). *Texto alternativo:* dos VMs *Always Free* de Oracle Cloud (Oracle, s.f.), una por ambiente, cada una siguiendo su propia rama de Git y corriendo los mismos cuatro contenedores Docker; Moodle no corre en ninguna VM — cada integrante del equipo lo sigue corriendo localmente, apuntando el *plugin* al ambiente que necesite probar.

Cada VM es una instancia `VM.Standard.E2.1.Micro` (1 OCPU / 1 GB RAM, más 4 GB de *swap*) en la región Chile Central, con el proyecto clonado en `~/nexusAI/NexusAI`. La de *staging* (`nexusai-staging`, creada el 2026-08-08) sigue la rama `staging`; la de producción (`nexusai-prod`, creada el 2026-08-05) sigue `main`. La regla de oro del equipo es que cada VM sigue exclusivamente la rama de su ambiente — nunca se hace `git pull origin development` directamente sobre una VM "para probar algo rápido", porque deja ese ambiente en un estado que no corresponde a ninguna rama y el siguiente *deploy* normal lo pisa sin aviso.

10.2. El proceso de despliegue manual

No hay integración continua hacia las VMs — un `git push` no cambia nada por sí solo, hay que entrar por SSH y traer el código a mano (`docs/DEPLOY_ORACLE.md`). El procedimiento es

idéntico en los dos ambientes: mergear la *pull request* a la rama correspondiente, conectarse por SSH y confirmar con `git branch --show-current` que la VM está parada en la rama esperada, `git pull` y levantar de nuevo el *stack* con `sudo docker compose -f docker-compose.yml -f docker-compose.prod.yml up -d --build` (Docker, s.f.) — el `--build` solo es necesario cuando cambió código del backend; un cambio solo en el *plugin* de Moodle no toca la VM en absoluto. Después de levantar, se confirma que los cuatro contenedores estén `Up`/*healthy* con `docker ps`, que el *health check* responda con el `env` correcto, y ante cualquier falla se revisan los logs de `nexusai-api` o `nexusai-caddy`. Las migraciones de Alembic corren solas en este flujo: `entrypoint.sh` ejecuta `alembic upgrade head` antes de levantar Uvicorn, y si una migración falla el contenedor de la API directamente no llega a levantar — a diferencia del entorno de desarrollo local, donde esa migración se corre a mano.

Un único archivo `Caddyfile` (Caddy, s.f.) sirve a ambos ambientes porque el dominio no está *hardcodeado* en el repositorio: sale de la variable de entorno `NEXUSAI_DOMAIN`, distinta en el `.env` de cada VM, que Caddy usa para pedir automáticamente el certificado TLS a Let's Encrypt (Let's Encrypt, s.f.). Cuando ese valor no coincide con el dominio real por el que se accede, Caddy levanta igual pero no consigue el certificado: el sitio responde por HTTP con una redirección 308 mientras el HTTPS falla con un error de TLS — el *fix* es corregir `NEXUSAI_DOMAIN` y volver a levantar el *stack*. Los dominios usados (`api.146.181.62.67.nip.io`, `api.159.112.139.166.nip.io`) son de `nip.io`, un servicio gratuito que resuelve ese formato de dominio a la IP que contiene sin necesidad de registrarlo; la contrapartida es que, si la IP pública de una VM cambia, el dominio cambia con ella y hay que actualizar el `.env` de esa VM, la documentación y la configuración del *plugin* en cada Moodle local.

Las credenciales se dividen en dos grupos con necesidades distintas: el `.env` completo de cada VM y la clave SSH privada, que hoy solo necesita Santiago —único integrante con cuenta propia de Oracle Cloud y, por lo tanto, único administrador de *deploy*—; y los tres valores de configuración del *plugin* (URL del backend, *API key*, secreto compartido), que sí necesita cualquier compañero que quiera probar el flujo completo contra un backend público, ingresados directamente en la pantalla de configuración del *plugin* en Moodle y compartidos por un canal directo, nunca por *git*/*issue*/PR. La *API key* y el secreto compartido son distintos entre *staging* y producción: cambiar la URL del backend del *plugin* sin cambiar también esos dos valores rompe la validación HMAC.

10.3. Operación, mantenimiento y brechas pendientes

La limitación de 1 GB de RAM por VM —ya mencionada en ADR-012 como motivo para no sumar un *stack* de observabilidad— también se monitorea de forma manual con `free -h` y `docker stats --no-stream` cuando hace falta. Dos tareas recurrentes mantienen el consumo de IA auditable: un *cron* diario (`30 3 * * *`) corre `scripts/rollup_llm_usage.py` dentro del contenedor de la API para consolidar por día el detalle de más de 13 meses de uso de LLM, y un *script* de *backfill* (`scripts/backfill_llm_usage.py`) se corrió una vez, de forma idempotente, para cargar hacia atrás los tokens históricos del chat después de que la migración 023 creara las tablas `llm_usage`, `model_prices` y `llm_usage_daily`.

El propio equipo documenta, sin disfrazarlas, las brechas que quedan abiertas en este despliegue interino. La más crítica: **no hay *backups* automáticos de PostgreSQL en ningún ambiente** — si se pierde una VM, se pierde su base de datos entera, y hoy no existe ningún `pg_dump` programado que lo evite. Le siguen, en orden de importancia menor: la dependencia de dominios `nip.io` en lugar de un dominio propio o DuckDNS; la ausencia de integración continua hacia las VMs, que implicaría cargar la clave SSH como *secret* de GitHub —alternativa ya evaluada y descartada en ADR-011—; y la falta de un Moodle de *staging* con el *plugin* conectado para probar el flujo completo antes de cada promoción a producción, hoy reemplazada por pruebas manuales desde el Moodle local de cada integrante.

11. Publicación en Moodle Marketplace

Más allá de las pruebas internas descritas en la sección anterior, el proyecto fue sometido a una validación externa concreta: la revisión de código y funcionalidad que exige el Moodle Plugins Directory (*Moodle Marketplace*) para publicar un plugin de terceros. Esta sección documenta ese proceso, los hallazgos de la revisión y cómo se resolvieron, por tratarse de la evaluación independiente más rigurosa que atravesó el plugin hasta el momento de este informe.

11.1. Por qué separar el repositorio

El formulario de registro de un plugin en moodle.org no admite indicar una subcarpeta: recibe una URL de repositorio y asume que su raíz es la raíz del plugin (Moodle HQ, s.f.-d). El código de NexusAI, sin embargo, vive dentro de un monorepo (`nexusAI`) junto al backend, la documentación y el material de investigación del proyecto, cuatro niveles por debajo de la raíz real del repositorio git. Un validador automático que clona el repo y busca `version.php` en el nivel superior no lo encuentra, y el envío se rechaza antes de llegar a un revisor humano.

De las alternativas evaluadas para resolverlo —pasar la URL del monorepo tal cual, usar un *submodule* de git o copiar la carpeta a mano a un repositorio nuevo— ninguna resultó viable sin perder el historial de commits del plugin o sin dejar de resolver el problema de fondo. La solución adoptada fue `git subtree split`: extrae únicamente los commits que modificaron la carpeta del plugin, con su historial intacto, hacia un repositorio nuevo y vacío (`nexusai-ucc/moodle-local_nexusai`), cuyo nombre sigue además la convención `moodle-{tipo}_{nombre}` que exige Moodle. Desde entonces, el monorepo sigue siendo el lugar donde se desarrolla, y un workflow de GitHub Actions (`sync-derived-repos.yml`) repite el *subtree split* de forma automática en cada *push* a `development`, manteniendo al repositorio público sincronizado sin intervención manual.

11.2. Proceso de envío y primera revisión

El plugin se envió al Moodle Plugins Directory el 20 de septiembre de 2026 en su versión `0.18.1` (*beta*), tras validar un checklist de requisitos de envío: metadatos completos en `version.php`, cabecera de licencia GPL v3+, cadenas de idioma en inglés y español, instalación desde ZIP sin pasos de compilación adicionales, CI real corriendo sobre Moodle 4.5 a 5.2 con PostgreSQL y MySQL, `LICENSE` dual (MIT en el repositorio raíz, GPL v3 en el plugin), ícono de 256×256 px y capturas de pantalla en inglés.

El flujo de revisión de Moodle es público (`moodle.org/plugins/queue.php`) y sigue un circuito estándar: *Upload initial version* → *Waiting for approval* → *Needs more work* → *Upload fixed version* → … hasta la aprobación. Recibir *"Needs more work"* en la primera ronda es la norma, no una señal de rechazo. NexusAI no fue la excepción: el ticket de revisión (identificado internamente como **MMR-301**, a cargo del revisor Volodymyr Dovhan, de Moodle HQ) devolvió el plugin con **"Changes needed"**, señalando 16 puntos a corregir sobre el código de la versión enviada.

11.3. Correcciones de la primera ronda

El equipo corrigió los 16 puntos del ticket en dos rondas de *pull requests*, agrupables en estas categorías:

- **Privacidad en foros con IA:** las funciones de resumen de hilo, sugerencia de respuesta y detección de posts similares verificaban el acceso a la discusión pero no a cada post individual, por lo que una respuesta privada podía llegar a un modelo de lenguaje o a estudiantes a los que no estaba dirigida, y una respuesta de un foro de preguntas y respuestas podía verse antes de que el estudiante publicara la propia. Se corrigió reutilizando la verificación de visibilidad nativa de `mod_forum` en cada post.
- **Endurecimiento de la conexión con el backend:** el *stream* del chat llamaba a `curl_init()` directamente; se reemplazó por la clase `\curl` de Moodle, que valida el certificado TLS del backend y no sigue redirecciones.
- **Falsos positivos de seguridad:** la página de estado de administración marcaba como "bloqueada" cualquier URL en `localhost`, en una red privada o en el puerto 8000, aun cuando el plugin funcionaba correctamente contra un backend de desarrollo legítimo; se ajustó para que solo valide que el endpoint responda `http(s)` y muestre los campos de salud del backend.
- **Calendario:** el feed `.ics` no excluía a usuarios suspendidos o eliminados ni verificaba que el usuario conservara el permiso `local/nexusai:use` en el curso.
- **Internacionalización y cabeceras de licencia:** textos fijos del widget de chat y de los paneles de foro que no pasaban por el paquete de idioma, y archivos PHP sin la cabecera estándar GPL que exige Moodle en todo el código fuente, incluidos los módulos AMD y las fuentes React que viajan en el ZIP.
- **Matriz de integración continua:** la versión enviada corría CI solo sobre un subconjunto de versiones soportadas; se amplió para cubrir Moodle 4.5 a 5.3 contra PostgreSQL y MySQL.

Estas correcciones, junto con la purga de posts de foro indexados en el backend tras borrar los datos de un usuario —otro de los 16 puntos—, se integraron en la versión `0.19.0`.

11.4. Auditoría propia y cierre de los últimos gaps

Antes de responder al ticket, el equipo hizo una auditoría interna cruzando cada punto marcado como resuelto contra el código real de `development`, y encontró una discrepancia: borrar un **curso completo** seguía sin purgar los posts de foro que el backend tenía indexados de ese curso. `data_cleanup::delete_course()` —la función que corre cuando Moodle borra un curso de verdad— solo encolaba la purga de documentos; la purga de posts de foro solo era alcanzable desde los tres métodos de la API de Privacidad de Moodle, que **no se ejecuta** en un borrado de curso real (a diferencia de un pedido de eliminación de datos de un usuario). El método que faltaba conectar (`provider::delete_backend_forum_posts()`) ya existía y ya soportaba el caso de "todos los usuarios del curso"; solo hacía falta exponerlo como público y llamarlo desde el lugar correcto.

Una revisión posterior, más allá de los 16 puntos originales, encontró un segundo caso del mismo tipo de bug: borrar un **foro puntual**, dejando el resto del curso intacto, tampoco purgaba nada —siempre, no solo en el caso excepcional que el equipo tenía anotado. La causa resultó ser distinta a la del curso: el observador del evento `course_module_deleted` de Moodle filtra a propósito cualquier actividad que no sea de tipo "Archivo", y aunque se hubiera manejado ahí, no habría funcionado: `forum_delete_instance()` —la función que borra las discusiones y los posts de un foro— se ejecuta **antes** de que Moodle dispare ese evento. Para cuando un observador llega a correr, los posts ya no existen en las tablas del foro y no hay nada que consultar. La solución usa en cambio `pre_course_module_delete($cm)`, un *callback* que Moodle descubre por convención de nombre de archivo y ejecuta **antes** de borrar el módulo, pensado exactamente para este tipo de caso —el mismo patrón que usan `tool_recyclebin` y otros complementos del núcleo de Moodle.

Ambos hallazgos se corrigieron, con pruebas automatizadas nuevas que reproducen cada caso, y la corrección quedó incluida en la versión `0.19.0` enviada de vuelta al revisor.

11.5. Sincronización automática y una lección operativa

Como el repositorio que revisa Moodle es un derivado del monorepo, cada corrección depende de que el workflow de sincronización (`sync-derived-repos.yml`) efectivamente la traslade. Al mergear las correcciones del último hallazgo, el workflow falló silenciosamente en las dos corridas siguientes: el token de GitHub (`SYNC_REPOS_TOKEN`) con el que el workflow empuja los cambios al repositorio público había vencido, así que el repositorio que vería el revisor seguía mostrando una versión vieja del plugin a pesar de que el monorepo ya tenía el fix. El incidente se detectó revisando el estado real de las corridas de CI —no asumiéndolo por el estado de los *pull requests* en el monorepo—, se resolvió generando un nuevo token de acceso de alcance limitado (permisos de escritura únicamente sobre los dos repositorios derivados) y quedó documentado como recordatorio de verificar la fecha de vencimiento del token la próxima vez que se renueve.

11.6. Estado actual

El plugin fue **aprobado y publicado** en el Moodle Plugins Directory, en la misma versión `0.19.0` (`MATURITY_BETA`) que incorporó las correcciones de los 16 puntos de MMR-301 y de los dos hallazgos adicionales descritos arriba. El *listing* público confirma un último *release* del 15 de octubre de 2026 — un día después de la fecha de esa misma versión en el `CHANGELOG` del repositorio, consistente con el tiempo que toma la publicación una vez aprobada la revisión. Como se observa en la Figura 12, la ficha pública ya refleja esa versión.

Figura 12. Ficha pública de NexusAI en el Moodle Plugins Directory. *Fuente:* `https://marketplace.moodle.com/plugins/4243`, capturado el 21/10/2026. *Texto alternativo:* la ficha del plugin "NexusAI" en el Moodle Marketplace, con etiqueta "Free", botón de descarga, soporte para Moodle 4.1 a 5.3, fecha del último *release* y tres capturas de la interfaz real (calendario, chat en un curso, panel docente).

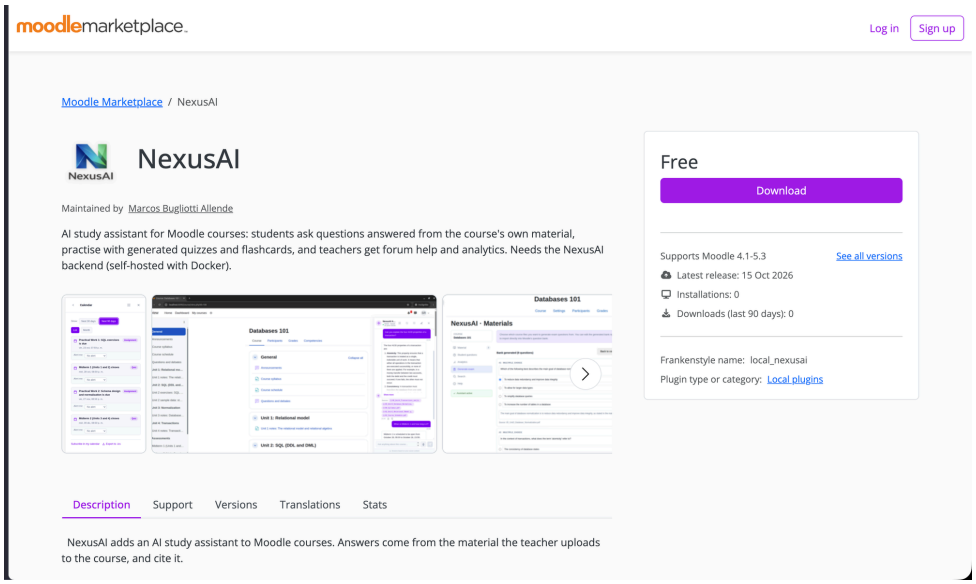


Figura 8: Figura 12

12. Gestión del proyecto y metodología ágil

Esta sección documenta cómo se gestionó el proyecto puertas adentro: la metodología adoptada, el cierre formal de dos de sus instancias —Fase 1 y Sprint 2— con sus métricas de valor ganado, y un ejemplo concreto de cómo la planificación se ajustó frente a la evidencia durante el desarrollo.

12.1. Metodología adoptada

El equipo trabajó con **Scrum**, en sprints de aproximadamente dos semanas, con roles diferenciados: Santiago Tricherri como *Project Manager* y responsable del backend de IA, Delfina Salinas como *Scrum Master* y responsable del frontend, y Marcos Bugliotti a cargo de la base de datos y la integración con Moodle. Cada fase y cada sprint cierran con un **acta formal**, firmada por los tres integrantes, que documenta entregables planificados contra entregados, desviaciones justificadas, métricas y una retrospectiva — el mismo formato que exige la cátedra de Administración de Proyectos de Software, de la que estas actas son entregable directo.

El seguimiento de avance usa **EVM** (*Earned Value Management*): valor planificado (PV), valor ganado (EV) y costo real (AC) por fase, de los que se derivan las variaciones de cronograma y costo (SV, CV) y los índices de desempeño SPI (`EV/PV`) y CPI (`EV/AC`) — una práctica de gestión de proyectos formal, no solo una tabla de velocity informal.

12.2. Cierre de Fase 1 — Setup e Investigación

La Fase 1 (9 al 22 de abril de 2026) cerró con sus entregables técnicos 100 % completados y en plazo, con un **sobre-cumplimiento deliberado** en investigación y formalización: 47 documentos en `investigacion/` contra los ~20 esperados originalmente, y 6 ADRs aceptados contra los 4 planificados (se sumaron HMAC PHP-Python y la estrategia de Privacidad, ambos necesarios antes de lo previsto por decisiones técnicas tempranas).

Las métricas de valor ganado al cierre de la fase fueron **SPI = 1,00** (en línea con el cronograma) y **CPI = 0,77** (23 % de sobrecosto en esfuerzo). El equipo interpretó ese sobrecosto como una decisión consciente, no como un desvío no controlado: invertir más horas en documentación y ADRs amortizó tiempo de desarrollo en los sprints siguientes, hipótesis que las mediciones acumuladas del proyecto al 4 de mayo (SPI = 1,10, CPI = 0,85) respaldaron.

De las lecciones aprendidas documentadas en el acta de cierre, dos resultan especialmente relevantes para entender decisiones posteriores: el equipo subestimó el tiempo de coordinación con actores externos a la universidad (la reunión con el técnico de Moodle de la UCC quedó pendiente al cierre de la fase y nunca se concretó, lo que terminó reforzando la estrategia de demo autohospedada descrita en *Relevamiento y metodología de investigación*), y reconoció que hubiera convenido empezar la primera prueba funcional antes de cerrar toda la documentación, ya que varios problemas de integración (migración del Hook API de Moodle, *chunks* de Webpack rotos, *symlinks* no funcionando en Docker) solo aparecieron al implementar.

El registro de riesgos abierto al cierre de la fase incluía, entre otros: el riesgo de que la aprobación institucional de la UCC demorara más de 4-6 semanas (mitigación: Plan B de demo local, que terminó siendo la estrategia efectiva), el riesgo de que la calidad del RAG con material real quedara por debajo de lo esperado (mitigación: dataset de evaluación propio con preguntas reales del Proyecto Integrador) y el riesgo de restricciones de privacidad del proveedor de embeddings sobre datos de alumnos (mitigación: términos a confirmar antes del piloto, con un proveedor local como plan de contingencia).

12.3. Cierre de Sprint 2 — RAG completo

El Sprint 2 (7 al 20 de mayo de 2026) cerró en plazo con el núcleo funcional del MVP: el sistema ya respondía preguntas usando el material real del curso, citando la fuente, con una vista docente para gestionar ese material. Tres desviaciones de alcance quedaron documentadas con su justificación técnica: el modelo de *embeddings* planificado (`text-embedding-004`) dejó de responder por la vía compatible con OpenAI que expone Google y se reemplazó por `gemini-embedding-001`; el formato de subida de archivos pasó de *multipart* con HMAC (frágil de firmar correctamente en PHP) a JSON con el archivo en base64; y el *streaming* de respuestas, considerado para este sprint, se postergó al Sprint 3 al estimarse en 3 días adicionales de trabajo frente a una latencia sin *streaming* ya aceptable (3 a 6 segundos) para el MVP.

Las métricas de cierre: 25 *issues* completados, una velocidad acumulada de ~12,5 *issues* por sprint, SPI = 1,10 (10 % adelantado), CPI = 0,85 (15 % de sobrecosto, ya esperado al tratarse de los primeros sprints), cerca de 5.860 líneas de código entre backend, plugin y frontend, y una suite de tests que creció de 18 a aproximadamente 35 casos. La retrospectiva registró como punto fuerte que el *polling* de estado de indexación en la vista docente resultó una solución de UX simple y efectiva, y como punto débil la documentación opaca de la API de *embeddings* de Google, cuyo modelo aceptado cambió sin aviso previo.

12.4. Un pivote real de infraestructura

La planificación original del Sprint 3 contemplaba desplegar el backend en Fly.io, con un procedimiento documentado paso a paso. Ese despliegue se ejecutó, pero fue reemplazado más adelante por el esquema actual: backend autohospedado en Oracle Cloud (decisión formalizada en el ADR-011). El documento de planificación original de Fly.io se conserva en el repositorio sin modificar, marcado explícitamente como histórico — un registro honesto de que la infraestructura efectivamente usada no fue la primera que se planificó, y de por qué cambió.

12.5. Cierre

El Anexo C de este informe conserva la tabla de *velocity* consolidada del proyecto completo (SP comprometidos y completados por sprint) como referencia numérica rápida; este capítulo documenta, en cambio, el relato de gestión detrás de dos de esas instancias de cierre formal —con sus métricas de valor ganado, sus desviaciones justificadas y sus lecciones aprendidas— tal como quedaron asentadas en las actas firmadas por el equipo.

13. Beneficios post-implementación

Tras la implementación del proyecto se esperan los siguientes beneficios, tanto tangibles como intangibles:

- **Acceso a asistencia académica disponible de forma permanente (24/7)** sobre el material real del curso, sin necesidad de incorporar personal de tutoría adicional — con siete funcionalidades ya en producción y una cobertura de pruebas automatizadas cercana al 80 % en el backend (ver Diagnóstico y Propuesta de Solución).
- **Reducción de la dispersión de la información**, al concentrar las consultas dentro del campus virtual donde reside el material validado: el relevamiento propio mostró que el 80,7 % de los estudiantes percibía esa dispersión antes de la implementación.
- **Mejora en la toma de decisiones del docente**, mediante el reporte de vacíos de contenido que evidencia qué temas no quedan cubiertos por el material.
- **Mitigación del riesgo de respuestas incorrectas**, gracias a la trazabilidad de cada respuesta hacia su fragmento de origen.
- **Preservación de la soberanía de los datos académicos**, al mantenerlos en la infraestructura controlada por la institución.
- **Costo operativo bajo**: ~$5,81 por estudiante al año en el escenario de producción estimado (ver Impacto Económico), un orden de magnitud por debajo de soluciones comerciales comparables.

14. Impacto económico (estudio de costos)

El análisis de costos contempla cuatro categorías: infraestructura, servicios de IA, personal y costos académicos. Se distingue el escenario actual del MVP del escenario de una eventual producción.

14.1. Costos de infraestructura y servicios de IA

En el escenario actual del MVP, el uso de niveles gratuitos de hosting y del modelo de IA permite un costo operativo prácticamente nulo. En un escenario de producción estimado para 500 estudiantes activos, el costo se mantiene reducido.

Concepto	Escenario MVP (actual)	Escenario producción (anual, 500 alumnos)
Infraestructura (hosting, base de datos, *cache*, dominio)	~$36 / año	~$170
Servicios de IA (LLM + *embeddings*)	$0 (nivel gratuito)	~$1.296
Mantenimiento (10 h/mes)	—	~$1.440
Total	**~$36 / año**	**~$2.906**

El costo de producción equivale a aproximadamente **$5,81 por estudiante por año**, un orden de magnitud por debajo de soluciones comerciales comparables.

14.2. Costos de personal (valoración teórica)

El equipo está compuesto por tres estudiantes de Ingeniería en Sistemas. Valorado a tarifa de mercado junior (~$12 por hora), el desarrollo del MVP representó aproximadamente **840 horas-persona**, equivalentes a una valoración teórica de ~**$10.080**. Este monto **no constituye un costo real** para la institución —el trabajo es académico— pero permite dimensionar el valor del proyecto.

14.3. Análisis costo-beneficio

El beneficio principal es la disponibilidad de asistencia académica permanente sin contratar personal de tutoría adicional. Si la institución ahorrara una hora de tutoría por estudiante por año, el retorno superaría ampliamente el costo del sistema. A ello se suma la condición autohospedada de la solución, que evita riesgos regulatorios de privacidad asociados a los servicios de IA de terceros.

15. Impacto social

El impacto social del proyecto se relaciona con la mejora del acceso al conocimiento y la equidad educativa, más allá de los aspectos técnicos o económicos.

- **Beneficio general:** el sistema democratiza el acceso a un acompañamiento académico permanente, históricamente limitado a quienes disponen de tiempo, recursos o redes de apoyo para resolver dudas fuera del aula.
- **Segmentos beneficiados:** estudiantes que cursan a distancia, que trabajan, o que por distintos motivos no pueden asistir a consultas presenciales, encuentran un canal de apoyo disponible en todo momento.
- **Inclusión y reducción de brechas:** al responder sobre el material validado por el docente y citar la fuente, el sistema ofrece una alternativa más confiable y equitativa que el uso desigual de herramientas de IA generales.
- **Apoyo al rol docente:** la solución amplifica la tarea del docente en lugar de reemplazarla, y le brinda información para mejorar su material en beneficio del conjunto del estudiantado.

El relevamiento propio del equipo (166 estudiantes, 17 docentes UCC; ver `investigacion/09-relevamiento/`) refuerza estos puntos con datos concretos: el 100 % de los estudiantes que respondieron ya recurre a herramientas de IA generalistas para estudiar, evidenciando una necesidad de acompañamiento académico ya instalada que hoy queda fuera del ámbito institucional y sin trazabilidad hacia el material real de la materia. Del lado docente, el 88,2 % delegaría tareas a una IA integrada al campus —la mayoría con la condición de revisar el resultado antes de publicarlo—, lo que indica una disposición amplia a que la tecnología amplifique su rol sin reemplazarlo, consistente con el diseño “asistir, no sustituir” adoptado por NexusAI.

16. Impacto medioambiental (opcional)

Si bien se trata de una solución de software, se consideran sus efectos sobre el consumo de recursos de cómputo:

- **Uso eficiente de la energía:** la arquitectura de un único servicio (monolito modular) y el uso de una sola base de datos reducen la huella de cómputo frente a arquitecturas distribuidas más complejas.
- **Aprovechamiento de niveles gratuitos y recursos compartidos:** el despliegue real corre sobre dos VMs `VM.Standard.E2.1.Micro` (1 OCPU / 1 GB RAM cada una) del nivel *Always Free* de Oracle Cloud —una de *staging* y otra de producción—, sin aprovisionar hardware dedicado adicional.
- **Sostenibilidad a largo plazo:** la abstracción multi-proveedor permite migrar a modelos de IA más eficientes a medida que estén disponibles, sin rediseñar el sistema.

17. Conclusión

El proyecto cumplió con los objetivos planteados al inicio. Se desarrolló un plugin de Moodle funcional con un asistente de IA que aplica RAG auténtico sobre el material del curso, con citas trazables, despliegue autohospedado y respuesta en *streaming*. El MVP entregado en junio de 2026 alcanzó siete funcionalidades en producción con una cobertura de pruebas automatizadas en el backend cercana al 80 %, superando el objetivo planteado, y el desarrollo continuó después de esa entrega incorporando foros con asistencia de IA, analítica docente, generación de exámenes, un plan de estudio personalizado y soporte de más formatos de material.

Desde el punto de vista académico, el trabajo aporta respuestas concretas a tres cuestiones vigentes en la aplicación de IA a la educación: la mitigación de la alucinación mediante RAG con citas trazables; el cierre del circuito de retroalimentación entre estudiante y docente mediante la detección automática de vacíos de contenido; y la preservación de la privacidad y la soberanía de los datos académicos mediante una arquitectura autohospedada.

Entre las **limitaciones** actuales se reconocen la ausencia de un esquema multi-institución nativo, la dependencia de la calidad del modelo de lenguaje en el generador de cuestionarios, la cobertura manual de pruebas en el frontend y el plugin, y la evaluación con usuarios reales (RNF-06 a RNF-09), que quedó pendiente de consolidar con métricas de latencia y un *golden set* de calidad de respuesta más allá de las pruebas internas del equipo.

Como **trabajo futuro** se plantean la publicación del plugin en el directorio oficial de Moodle, la incorporación de pruebas automatizadas de frontend, y el agrupamiento semántico (por embeddings, no solo por texto normalizado) de los vacíos de contenido detectados.

En síntesis, el proyecto demuestra que es posible integrar asistencia académica contextualizada y auditable dentro del LMS institucional, amplificando el rol del docente en lugar de sustituirlo.

17.1. Reflexiones personales del equipo

> *(Borrador a validar por cada integrante antes de la entrega final — cada uno puede reescribir su propio párrafo con su propia voz.)*

Delfina Salinas. Como *Scrum Master*, el aprendizaje de gestión más concreto fue coordinar la documentación de un proyecto que seguía creciendo en paralelo, sin que eso bloqueara al resto del equipo —dividir la expansión de este mismo informe en issues pequeñas y acotadas (`PI-08` a `PI-22`), cada una con su fuente real ya identificada, resultó más sostenible que plantear una reescritura grande de una sola vez. En lo técnico, investigar la *Hook API* de Moodle me dejó un hallazgo que no esperaba: un *callback* que funcionaba sin problema en versiones viejas de la plataforma deja de funcionar en Moodle 4.4 en adelante sin ningún error visible, solo una advertencia de deprecación fácil de pasar por alto. Si lo volviera a hacer, documentaría las decisiones de diseño e infraestructura en el momento en que se toman —el rediseño de la interfaz de agosto, por ejemplo, quedó registrado solo en mensajes de *commit*— en lugar de tener que reconstruirlas meses después para este informe.

Santiago Tricherri. Ejecutar una auditoría de seguridad real sobre el propio proyecto, en vez

de aplicar una lista genérica de buenas prácticas, me obligó a mirar código que ya daba por "terminado" con otra exigencia, y encontré algo concreto que no habría aparecido de otra forma: una métrica de usuario que usaba un hash sin sal, reversible por fuerza bruta. En gestión, ser el único integrante con acceso de *deploy* a los dos ambientes de producción me mostró que esa concentración es una responsabilidad operativa real, no solo una formalidad en un documento. Si lo volviera a hacer, repartiría ese acceso antes de que se volviera un cuello de botella, en vez de esperar a que el equipo creciera para resolverlo.

Marcos Bugliotti. Integrar un *plugin* de Moodle con un backend propio —*Hook API*, *capabilities*, *web services*— resultó sustancialmente más profundo de lo que parece desde afuera del proyecto; cada capa (autenticación, autorización, empaquetado del *frontend* como módulo AMD) terminó teniendo su propia complejidad real, no solo de diseño. En gestión, mantener la consistencia entre documentos de investigación escritos en momentos distintos del proyecto es más difícil de lo esperado: la inconsistencia de nombres de *capabilities* que encontramos al redactar este mismo informe —dos convenciones distintas documentadas en dos archivos distintos— es un ejemplo real de cómo terminología técnica puede divergir en silencio si nadie la revisa de conjunto. Si lo volviera a hacer, congelaría nombres y contratos técnicos clave más temprano en el proyecto, en lugar de dejarlos evolucionar libremente entre documentos de diseño.

18. Bibliografía / Referencias

Las referencias siguen la norma APA v7. Toda fuente citada en el texto figura en esta sección, y toda referencia listada fue utilizada en el informe.

- Caddy. (s.f.). *Caddy documentation — Automatic HTTPS*. Recuperado 2026, de https://caddyserver.com/docs/automatic-https
- ChromaDB. (s.f.). *Chroma documentation*. Recuperado 2026, de https://docs.trychroma.com/
- Coursera. (2023). *Coursera launches Coach, a personalized AI-powered coaching experience, and new applications of GenAI in the enterprise*. Coursera Blog. https://blog.coursera.org/coursera-launches-coach/
- Docker. (s.f.). *Docker Compose documentation*. Recuperado 2026, de https://docs.docker.com/compose/
- FastAPI. (s.f.). *FastAPI documentation*. Recuperado 2026, de https://fastapi.tiangolo.com/
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, H., & Wang, H. (2023). *Retrieval-augmented generation for large language models: A survey*. arXiv. https://arxiv.org/abs/2312.10997
- Google. (s.f.-a). *Gemini API — OpenAI compatibility*. Recuperado 2026, de https://ai.google.dev/gemini-api/docs/openai
- Google. (s.f.-b). *NotebookLM*. Recuperado 2026, de https://notebooklm.google/
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys, 55*(12), 1–38. https://doi.org/10.1145/3571730
- Khan Academy. (s.f.). *Khan Labs — Khanmigo*. Recuperado 2026, de https://www.khanacademy.org/khan-labs
- Krawczyk, H., Bellare, M., & Canetti, R. (1997). *HMAC: Keyed-hashing for message authentication* (RFC 2104). IETF. https://doi.org/10.17487/RFC2104
- Let's Encrypt. (s.f.). *Let's Encrypt — How it works*. Recuperado 2026, de https://letsencrypt.org/how-it-works/
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474.
- Microsoft. (s.f.). *Microsoft Copilot for Education*. Recuperado 2026, de https://www.microsoft.com/en-us/education/products/copilot
- Moodle. (s.f.). *NexusAI — Moodle Plugins Directory*. Recuperado el 21 de octubre de 2026, de https://marketplace.moodle.com/plugins/4243
- Moodle HQ. (2024). *Moodle Developer Documentation — Plugin types: local*. https://moodledev.io/docs/apis/plugintypes/local
- Moodle HQ. (s.f.-a). *Moodle Developer Documentation — Access API*. Recuperado 2026, de https://moodledev.io/docs/apis/subsystems/access
- Moodle HQ. (s.f.-b). *Moodle Developer Documentation — Hooks API*. Recuperado 2026, de https://moodledev.io/docs/apis/core/hooks
- Moodle HQ. (s.f.-c). *Moodle Developer Documentation — JavaScript modules*. Recuperado

2026, de https://moodledev.io/docs/guides/javascript/modules
- Moodle HQ. (s.f.-d). *Plugin contribution checklist*. Recuperado 2026, de https://moodledev.io/general/com
- Moodle HQ. (s.f.-e). *Moodle Developer Documentation — External functions and web services*. Recuperado 2026, de https://moodledev.io/docs/apis/subsystems/external
- OpenAI. (s.f.-a). *ChatGPT Edu*. Recuperado 2026, de https://openai.com/chatgpt/education/
- OpenAI. (s.f.-b). *GPT-4o pricing*. Recuperado 2026, de https://openai.com/api/pricing/
- Oracle. (s.f.). *Oracle Cloud Infrastructure — Always Free resources*. Recuperado 2026, de https://www.oracle.com/cloud/free/
- OWASP. (s.f.-a). *Replay attack*. OWASP Foundation. Recuperado 2026, de https://owasp.org/www-community/attacks/Replay_attack
- OWASP. (s.f.-b). *OWASP Top 10*. OWASP Foundation. Recuperado 2026, de https://owasp.org/www-project-top-ten/
- pdfplumber. (s.f.). *pdfplumber* [Software]. GitHub. https://github.com/jsvine/pdfplumber
- pgvector. (s.f.). *pgvector: Open-source vector similarity search for Postgres* [Software]. GitHub. https://github.com/pgvector/pgvector
- Pydantic. (s.f.). *Pydantic documentation*. Recuperado 2026, de https://docs.pydantic.dev/
- pytest. (s.f.). *pytest documentation*. Recuperado 2026, de https://docs.pytest.org/
- React. (s.f.). *React documentation — createRoot*. Recuperado 2026, de https://react.dev/reference/react-dom/client/createRoot
- sse-starlette. (s.f.). *sse-starlette* [Software]. GitHub. https://github.com/sysid/sse-starlette
- v0. (s.f.). *v0 by Vercel — Generative UI* [Software]. Vercel. https://v0.dev/
- Vitest. (s.f.). *Vitest documentation*. Recuperado 2026, de https://vitest.dev/
- Webpack. (s.f.). *Webpack documentation — Output, externals y code splitting*. Recuperado 2026, de https://webpack.js.org/configuration/output/

19. Anexos

Los anexos reúnen material complementario que respalda el informe sin interrumpir su lectura principal.

19.1. Anexo A — Requerimientos detallados

Cada requerimiento tiene un ID único (RF-NN funcionales, RNF-NN no funcionales), una prioridad en el contexto del MVP y el sprint donde se implementó.

19.1.1. Requerimientos funcionales

Asistente conversacional RAG

ID	Requerimiento	Prioridad	Sprint
RF-01	Consulta en lenguaje natural sobre el material del curso desde un widget flotante.	Alta	1
RF-02	El asistente responde usando exclusivamente el material indexado, citando los archivos fuente.	Alta	2
RF-03	Si la pregunta no se puede responder con el material disponible, el sistema lo admite explícitamente.	Alta	2
RF-04	El alumno ve el fragmento exacto usado para responder, con su porcentaje de similitud.	Alta	4
RF-05	La respuesta aparece token por token (*streaming*) para reducir la latencia percibida.	Media	4

ID	Requerimiento	Prioridad	Sprint
RF-06	El alumno puede retomar conversaciones anteriores desde un historial.	Media	4
RF-07	Modo multi-curso opcional: el asistente consulta material de todos los cursos inscriptos.	Media	4

Buscador semántico

ID	Requerimiento	Prioridad	Sprint
RF-08	Búsqueda de fragmentos por similitud semántica, sin pasar por el LLM.	Media	4
RF-09	Cada resultado muestra archivo, fragmento y porcentaje de similitud.	Media	4

Generador de cuestionarios

ID	Requerimiento	Prioridad	Sprint
RF-10	Generación de un *quiz* de opción múltiple desde el material del curso.	Media	4
RF-11	El alumno elige un tema específico o deja el campo vacío para variedad de temas.	Media	4
RF-12	Si el tema pedido no está en el material, el sistema avisa (no genera un *quiz* engañoso).	Media	4

ID	Requerimiento	Prioridad	Sprint
RF-13	Cada pregunta tiene 4 opciones: una correcta y tres distractores plausibles.	Media	4
RF-14	Feedback inmediato tras cada respuesta, con explicación y archivo fuente.	Media	4

Gestión de material (rol docente)

ID	Requerimiento	Prioridad	Sprint
RF-15	El docente sube archivos PDF al curso para que el asistente los indexe.	Alta	2
RF-16	Extracción de texto, *chunking* y *embeddings* de cada archivo de forma asíncrona.	Alta	2
RF-17	El docente ve el estado de cada documento (`pending` / `indexing` / `indexed` / `error`).	Alta	2
RF-18	El docente puede borrar un documento; el borrado se propaga en cascada a sus *chunks*.	Alta	2
RF-19	Detección de *uploads* duplicados por hash SHA-256, evita reindexar el mismo archivo.	Media	4

Feedback al docente (detección de vacíos)

ID	Requerimiento	Prioridad	Sprint
RF-20	Registro automático de las preguntas que el material no pudo responder.	Media	4
RF-21	Reporte agregado de vacíos por curso, ordenado por frecuencia.	Media	4
RF-22	El reporte de vacíos se filtra por ventana temporal (7/30/90/365 días).	Baja	4

19.1.2. Requerimientos no funcionales

ID	Requerimiento	Categoría
RNF-01	La API key del LLM nunca llega al navegador del alumno.	Seguridad
RNF-02	Toda comunicación entre el plugin y el backend se firma con HMAC SHA-256 en 3 capas (Bearer + firma + *nonce*).	Seguridad
RNF-03	El backend rechaza firmas inválidas, timestamps vencidos (>5 min) o *nonces* reusados.	Seguridad
RNF-04	El plugin valida la *capability* `local/nexusai:use` antes de llamar al backend.	Seguridad
RNF-05	El backend valida que un usuario no pueda leer sesiones de chat ajenas.	Seguridad
RNF-06	Latencia al primer token de respuesta (streaming) < 2 s.	Performance
RNF-07	Latencia de respuesta completa del chat (sin streaming) < 8 s.	Performance

ID	Requerimiento	Categoría
RNF-08	Latencia del buscador semántico (retrieval puro) < 1 s.	Performance
RNF-09	Tiempo de indexación de un PDF de 50 páginas < 60 s.	Performance
RNF-10	Instalable en Moodle 4.1 LTS a 4.5 sin `composer install` ni dependencias externas.	Compatibilidad
RNF-11	El widget funciona en Chrome, Firefox, Safari y Edge en versiones actuales.	Compatibilidad
RNF-12	El backend corre sobre Python 3.11+, PostgreSQL 16+ y pgvector 0.3.5+.	Compatibilidad
RNF-13	Los datos académicos viven en una base de datos controlada por la institución.	Privacidad
RNF-14	El plugin declara su Privacy API según el modelo híbrido de ADR-014 (datos del alumno en tablas nativas de Moodle, con retención/eliminación acorde).	Privacidad
RNF-15	El proveedor del LLM se cambia sin modificar código (variable de entorno).	Privacidad
RNF-16	Cobertura de tests automatizados del backend de al menos 70 %.	Mantenibilidad
RNF-17	CI/CD en GitHub Actions para backend, frontend y plugin PHP.	Mantenibilidad
RNF-18	Decisiones arquitectónicas documentadas como ADRs en `docs/adr/`.	Mantenibilidad
RNF-19	Cada *feature* documentada con ADR (si aplica), comentarios en código e issue con criterios de aceptación.	Mantenibilidad

ID	Requerimiento	Categoría
RNF-20	El plugin se distribuye como ZIP instalable vía *Site administration* → *Plugins* → *Install plugins*.	Distribución
RNF-21	Cada *release* etiquetada en GitHub con *changelog* y `version.php` actualizado.	Distribución

19.2. Anexo B — Modelo de datos

NexusAI usa una sola base de datos PostgreSQL con la extensión pgvector activada; los embeddings vectoriales y los datos relacionales viven en la misma instancia. Como se observa en la Figura 13, el modelo vigente solo tiene dos tablas.

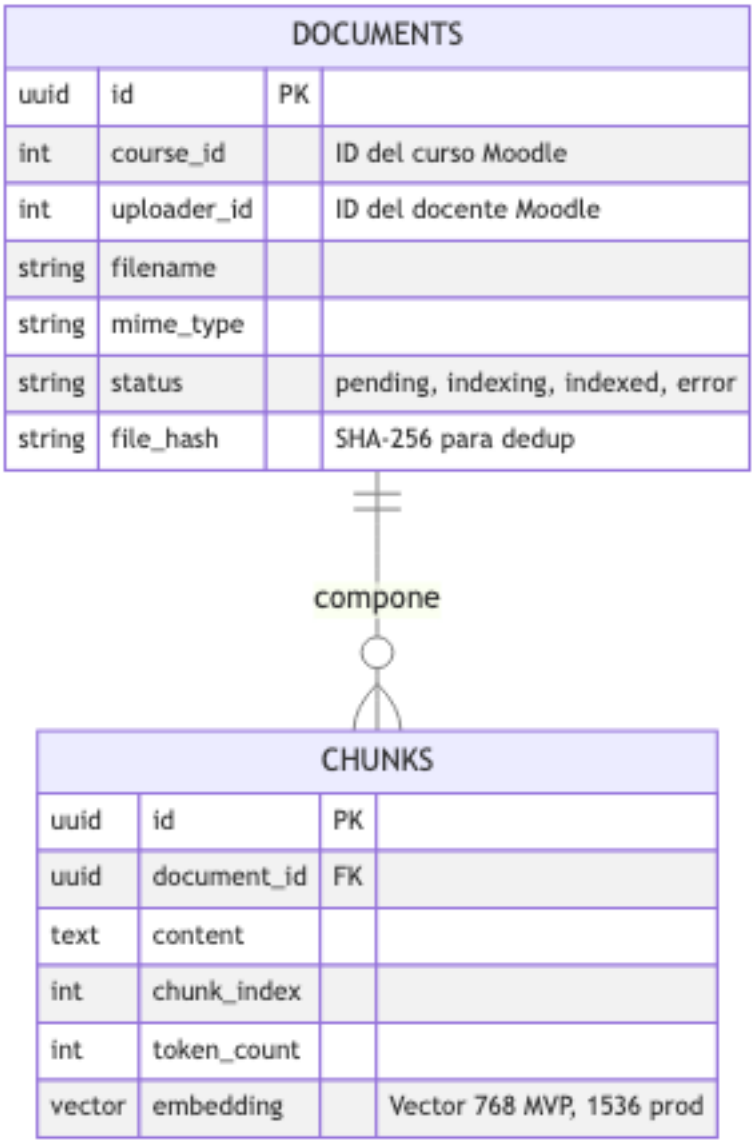


Figura 13. Diagrama entidad-relación de NexusAI. *Fuente:* elaboración propia (`entrega-final/15_modelo_datos.md`). *Texto alternativo:* dos tablas — documents y chunks — con `documents` componiendo `chunks`, único par que hoy vive en el backend. Las tablas de datos del alumno (sesiones de chat, mensajes, vacíos de contenido, entre otras) se quitaron de este diagrama porque ya no viven en PostgreSQL — ver la nota debajo.

Notas de implementación: `chunks.embedding` usa un índice **HNSW** con distancia coseno (`m=16`, `ef_construction=200`) para búsqueda aproximada en tiempo casi constante. `documents` tiene un índice único parcial sobre `(course_id, filename, file_hash)` que evita reindexar el mismo archivo dos veces. El esquema evolucionó en 5 migraciones Alembic (001 a 004, con dos migraciones `004_*` desarrolladas en paralelo por integrantes distintos y luego encadenadas). Por ADR-014 (Anexo E), las tablas `CHAT_SESSIONS`, `MESSAGES` y `UNANSWERED_QUESTIONS`

que figuraban antes en este diagrama ya no viven en PostgreSQL: los datos del alumno se movieron a dieciséis tablas nativas `local_nexusai_*` del lado del plugin de Moodle (`chat_sessions` → `local_nexusai_chat_sessions`, `messages` → `local_nexusai_messages`, `unanswered_questions` → `local_nexusai_gaps` —esta última cambió de nombre, no es la misma tabla solo renombrada—, además de intentos y errores de *quiz*, *flashcards* y alertas de calendario, entre otras). El backend conserva únicamente el índice vectorial del material de curso (`documents`/`chunks`, sin cambios) y las cachés de contenido, sin ningún dato personal del alumno.

19.3. Anexo C — Métricas del proyecto

Velocidad por sprint

Sprint	SP comprometidos	SP completados	Velocity
Sprint 0 — Setup	60	60	100 %
Sprint 1 — Core chat	50	45	90 %
Sprint 2 — RAG	60	55	92 %
Sprint 3 — Calidad	25	25	100 %
Sprint 4 — MVP	70	70	100 %
Promedio			**96 %**

Métricas de desarrollo

Métrica	Valor
Commits al repositorio	~290
Issues cerradas	160+
Pull requests mergeados	85+
Líneas de código backend Python	~3.500
Líneas de código plugin PHP	~2.500
Líneas de código React	~3.200
Migraciones de base de datos	5
ADRs documentadas	6
Tests automatizados del backend	37
Cobertura de tests del backend	~80 %

Calidad del LLM (*golden set*)

Métrica	Resultado en el MVP
Preguntas con respuesta correcta y citación adecuada	8/10
Preguntas donde el LLM admitió no poder responder (correcto)	2/2
Falsos positivos (respuesta segura pero incorrecta)	0
Falsos negativos (no responde teniendo material disponible)	0

Métrica	Resultado en el MVP

19.4. Anexo D — Repositorio y evidencias

- **Repositorio:** github.com/nexusai-ucc/nexusAI
- **Issues:** github.com/nexusai-ucc/nexusAI/issues
- **Integración continua (GitHub Actions):** github.com/nexusai-ucc/nexusAI/actions
- **Release del MVP:** `v0.8.0-mvp` (github.com/nexusai-ucc/nexusAI/releases/tag/v0.8.0-mvp). El plugin siguió evolucionando después del MVP (versión actual `0.19.0`, `MATURITY_BETA`, según `plugin/local/nexusai/version.php`) sin un *tag* formal más reciente en el repositorio — pendiente etiquetar el próximo *release* (RNF-21). Esa versión es la que está en curso de revisión en el Moodle Plugins Directory (ver "Publicación en Moodle Marketplace" → "Estado actual").

  Nota: el backend está desplegado de forma permanente en dos ambientes sobre Oracle Cloud (*Always Free*): *staging*, para pruebas del día a día (`https://api.146.181.62.67.nip.io`), y producción, solo para funcionalidad ya validada (`https://api.159.112.139.166.nip.io`). Moodle no se despliega junto al backend — cada integrante lo sigue corriendo localmente, apuntando el plugin al ambiente correspondiente. El deploy a ambas VMs es manual; para reducir el riesgo de acumular cambios sin probar, el equipo concentra los merges a `main` al cierre de cada sprint, trabajando el resto del tiempo contra `development` y *staging*.

19.5. Anexo E — Registro de decisiones de arquitectura (ADRs)

El proyecto documenta sus decisiones de arquitectura significativas como *Architecture Decision Records* (ADR) en `docs/adr/`: diez decisiones aceptadas o propuestas, cada una con su contexto, las alternativas evaluadas y sus consecuencias. Las cuatro primeras ya se desarrollaron en Marco Teórico; se listan acá solo como registro formal. Las seis restantes no están desarrolladas en ningún otro capítulo del informe.

ADR-001 — Backend Python como monolito modular (Aceptada, 02/05/2026). Un único proceso FastAPI organizado por dominios (`chat/`, `documents/`, `analytics/`) en lugar de microservicios, decisión desarrollada en Marco Teórico. Revisar si la indexación bloquea el chat por minutos, o si el equipo crece a más de 6 desarrolladores.

ADR-002 — pgvector sobre PostgreSQL como única base de datos (Aceptada, 02/05/2026; acotada por ADR-014 a partir de septiembre: pgvector queda solo para el índice del material del curso). Revisar si una institución supera los 10 millones de vectores.

ADR-003 — Arquitectura agnóstica de proveedor LLM (Aceptada, 02/05/2026). Abstracción propia (`LLMProvider`/`EmbeddingProvider`) sobre el SDK de OpenAI, compatible con la mayoría de los proveedores relevantes cambiando solo la URL base. Revisar si aparece un proveedor incompatible con ese SDK.

ADR-004 — Gemini en MVP, OpenAI en producción (Aceptada, 02/05/2026). Costo de producción proyectado de ~$108/mes para 500 alumnos ($0,22/alumno/mes). Revisar si el piloto supera el límite gratuito de Gemini (1.500 solicitudes/día) antes de pasar a producción.

ADR-005 — Autenticación PHP/Python con HMAC SHA-256 en 3 capas (Aceptada, 04/05/2026). El plugin y el backend son dos servicios independientes, y la clave del proveedor de IA vive solo en el backend — nunca puede llegar al navegador. La autenticación se resuelve en tres capas: una clave `Bearer` identifica al cliente, una firma HMAC SHA-256 sobre `timestamp + nonce + body` garantiza integridad con una ventana de 5 minutos de tolerancia, y un *nonce* de un solo uso guardado en Redis (`SET NX EX 300`) impide repetir una solicitud capturada. Se descartó JWT por no aportar nada sobre HMAC+timestamp para autenticación servicio-a-servicio sin estado, y mTLS por la complejidad de distribuir y rotar certificados para dos servicios bajo el mismo control de despliegue. Revisar si el proyecto pasa a ser multi-institucional (cada universidad como cliente distinto).

ADR-006 — Estrategia de Privacy API: `null_provider` primero (Fecha 04/05/2026; **reemplazada por ADR-014**). Mientras los datos del alumno vivieran solo en el backend externo y no en tablas de Moodle, el plugin declaraba formalmente `null_provider` en lugar de implementar el `metadata\provider` completo sin datos reales que exportar o borrar — una decisión deliberada (YAGNI), no una omisión, con triggers explícitos para disparar la migración (agregar cualquier tabla `local_nexusai_*` con `userid`, o decidir publicar el plugin en moodle.org). Esos triggers se cumplieron en septiembre y la decisión quedó reemplazada por ADR-014.

ADR-010 — Alcance del copiloto de onboarding al docente (**Propuesta, 30/08/2026 — pendiente de aprobación, no aceptada todavía**). Define que NexusAI **no escribe nada en Moodle**: cada paso del tutorial de "primeros pasos" de un curso es un link a la pantalla nativa de Moodle donde el propio docente hace la acción — se descartó explícitamente la alternativa de que NexusAI cree recursos (foros, grupos) en nombre del docente, por el riesgo de romper datos reales y por ampliar la superficie de la declaración de Privacidad sin necesidad.

ADR-011 — Retiro de las configuraciones de deploy de Railway y Fly.io (Aceptada, 07/09/2026). El backend pasó por tres destinos de despliegue a lo largo del proyecto: Railway durante el MVP y la defensa ante el jurado, Fly.io en el post-MVP temprano, y Oracle Cloud (*Always Free*) desde agosto de 2026, destino actual. Al llegar a septiembre, ninguno de los dos primeros seguía activo, pero el *workflow* de GitHub Actions que desplegaba a Fly.io seguía corriendo en cada *push* a `main` y fallando sistemáticamente — el repositorio mostraba una CI en rojo permanente por infraestructura que ya no existía, señal que competía con las fallas reales. El ADR formaliza eliminar esos archivos de configuración muerta (`deploy.yml`, `fly.toml`, `railway.json`, incluida una segunda copia divergente del *workflow* que nunca llegó a ejecutarse por estar en una ruta que GitHub Actions no lee) y deja explícitamente **sin modificar** la documentación histórica del proyecto (`entrega-final/`, `investigacion/`, el propio `CHANGELOG.md`) que describe Railway o Fly.io como entorno vigente, porque era cierto cuando se escribió — reescribirla sería falsificar el registro del proyecto, no limpiarlo.

ADR-012 — Alertas mínimas viables, sin infraestructura nueva de monitoreo (Acep-

tada, 11/09/2026). Las dos VMs de Oracle Cloud corren con 1 núcleo y 1 GB de RAM cada una, compartidos entre el backend, PostgreSQL y Redis — un stack de observabilidad como Prometheus + Grafana + Alertmanager consumiría una porción desproporcionada de esa RAM para el tráfico de un piloto. Se implementaron alertas por correo electrónico (SMTP, sin dependencias nuevas más allá de la librería estándar de Python) para los cuatro eventos con impacto directo en la experiencia del usuario: caída del backend, tasa elevada de errores 5xx, fallas o lentitud del proveedor de LLM, y cuota de IA agotada — cada uno con un umbral y una ventana en Redis para no inundar la casilla de correo mientras el problema persiste.

ADR-014 — Datos del alumno en tablas nativas de Moodle (opción C híbrida) (Aceptada, 26/09/2026; reemplaza a ADR-006 en dónde viven los datos personales, y acota a ADR-002). Es la decisión arquitectónica más relevante del proyecto en su última etapa. El diseño original —todo el dato del alumno en el backend externo— generaba privacidad incompleta (el borrado y la exportación no cubrían todas las tablas, y borrar un curso en Moodle dejaba datos huérfanos en el backend), quedaba fuera de las herramientas de Moodle (sin backup de curso, sin reportes nativos, sin backups del propio backend en ningún ambiente) y dependía de 48 de las 55 funciones externas del plugin llamando al backend por HTTP. Mediciones del equipo mostraron el costo real de esa dependencia: una lectura nativa en la base de Moodle toma 0,23 ms de mediana, la misma lectura vía el backend en la misma máquina toma 4,7 ms, y una llamada al backend de producción toma ~135 ms. La decisión mueve los datos del alumno (sesiones de chat, mensajes, interacciones, intentos y errores de cuestionarios, flashcards, alertas de calendario) a dieciséis tablas nativas `local_nexusai_*`, propiedad del plugin PHP; el backend conserva únicamente el índice vectorial del material del curso y las cachés de contenido, sin datos personales. El trade-off aceptado es tener la misma lógica de negocio duplicada en dos lenguajes (PHP y Python) para lo que se portó, mitigado probando la versión portada contra los mismos casos que los tests de Python ya cubrían.