Universidad Católica de Córdoba

Facultad de Ingeniería

Proyecto:

NexusAI

Asistente académico con inteligencia artificial integrado en Moodle

[insertar logo UCC]

Informe Final de Grado

Alumnos:

- Santiago Tricherri
- Marcos Bugliotti
- Delfina Salinas

Directores:

- Ignacio Luciano Carreño
- Federico Eduardo Porrini
- Leandro Juarez

[COMPLETAR: día] de [mes] de 2026

Córdoba — Argentina

Índice

1. Resumen **3**

1.1. Abstract . . . 3

2. Presentación del tema **5**

3. Glosario **6**

4. Diagnóstico (problemática) **7**

4.1. Estado actual (contexto) . . . 7

4.2. Impacto sobre los interesados . . . 7

4.3. Oportunidades . . . 7

5. Objetivos **9**

5.1. Objetivo general . . . 9

5.2. Objetivos específicos . . . 9

5.3. Tabla de trazabilidad . . . 9

6. Marco teórico **11**

6.1. Contexto general del problema . . . 11

6.2. Técnicas investigadas . . . 11

6.3. Tecnologías investigadas . . . 11

6.3.1. Base de datos vectorial . . . 12

6.3.2. Modelos de lenguaje y *embeddings* . . . 12

6.3.3. Arquitectura de plugin Moodle . . . 12

6.3.4. Extracción y fragmentación de documentos . . . 13

6.4. Opciones similares en el mercado . . . 13

7. Propuesta de solución **14**

7.1. Alcance funcional . . . 14

7.2. Diseño . . . 15

7.2.1. Arquitectura del software . . . 15

7.2.2. Patrones de diseño . . . 16

7.2.3. Interfaz de usuario . . . 16

7.3. Implementación . . . 17

7.4. Pruebas . . . 20

8. Publicación en Moodle Marketplace **21**

8.1. Por qué separar el repositorio . . . 21

8.2. Proceso de envío y primera revisión . . . 21

8.3. Correcciones de la primera ronda . . . 22

8.4. Auditoría propia y cierre de los últimos gaps . . . 22

8.5. Sincronización automática y una lección operativa . . . 23

8.6. Estado actual . . . 23

9. Beneficios post-implementación **24**

10. Impacto económico (estudio de costos) **25**
10.1. Costos de infraestructura y servicios de IA 25
10.2. Costos de personal (valoración teórica) 25
10.3. Análisis costo-beneficio 25

11. Impacto social **26**

12. Impacto medioambiental (opcional) **27**

13. Conclusión **28**

14. Bibliografía / Referencias **29**

15. Anexos **30**
15.1. Anexo A — Requerimientos detallados 30
15.1.1. Requerimientos funcionales 30
15.1.2. Requerimientos no funcionales 33
15.2. Anexo B — Modelo de datos 35
15.3. Anexo C — Métricas del proyecto 35
15.4. Anexo D — Repositorio y evidencias 36

1. Resumen

El presente informe documenta el desarrollo de **NexusAI**, un asistente académico basado en inteligencia artificial integrado como plugin en la plataforma Moodle. **(Introducción)**

Las plataformas de gestión del aprendizaje (LMS) como Moodle se utilizan mayoritariamente como repositorios documentales estáticos, mientras que los estudiantes recurren a asistentes de IA generales —ajenos al material de cada materia— para resolver sus dudas. Esto produce respuestas genéricas, dispersión de la información y pérdida de visibilidad del docente sobre las consultas del alumnado. **(Problema)**

Para abordar esta situación se diseñó e implementó un plugin de tipo `local` para Moodle, acompañado de un backend que aplica la técnica de *Retrieval-Augmented Generation* (RAG) sobre el material indexado de cada curso, almacenado en una base de datos vectorial. La solución recupera los fragmentos más relevantes del material y los provee como contexto a un modelo de lenguaje de gran escala, que responde citando explícitamente la fuente. **(Metodología)**

El producto mínimo viable (MVP), entregado en junio de 2026, alcanzó siete funcionalidades en producción —buscador semántico, chat conversacional multi-curso, respuesta en *streaming*, citas trazables, historial, generador de cuestionarios y detección de vacíos de contenido— con una cobertura de pruebas automatizadas cercana al 80 % en el backend. En los meses posteriores el desarrollo continuó de forma sostenida, incorporando foros con detección de posts similares y asistencia de IA, un panel de analítica para el docente, generación de exámenes exportables al formato nativo de Moodle, un plan de estudio personalizado que combina errores de práctica y vacíos detectados, y soporte para formatos de material adicionales al PDF. **(Resultado)**

Los resultados muestran que es posible ofrecer asistencia académica contextualizada y auditable dentro del LMS institucional, preservando la soberanía de los datos y mitigando la alucinación de los modelos de lenguaje mediante la trazabilidad de las respuestas. **(Conclusión)**

Palabras clave: Moodle, inteligencia artificial, RAG, asistente académico, educación, soberanía de datos.

1.1. Abstract

This report documents the development of **NexusAI**, an artificial-intelligence academic assistant integrated as a plugin into the Moodle platform. **(Introduction)**

Learning Management Systems (LMS) such as Moodle are mostly used as static document repositories, while students rely on general-purpose AI assistants —unaware of each subject's material— to solve their doubts. This leads to generic answers, information dispersion, and a loss of teacher visibility over student queries. **(Problem)**

To address this, a Moodle `local` plugin was designed and implemented, together with a backend that applies Retrieval-Augmented Generation (RAG) over each course's indexed material, stored in a vector database. The solution retrieves the most relevant fragments and provides them as context to a large language model, which answers by explicitly citing its source. **(Methodology)**

The minimum viable product (MVP), delivered in June 2026, reached seven production features —semantic search, multi-course conversational chat, response streaming, traceable citations, history, quiz generation, and content-gap detection— with automated test coverage close to 80 % in the backend. Development continued steadily in the following months, adding forums with similar-post detection and AI assistance, a teacher analytics panel, exam generation exportable to Moodle's native format, a personalized study plan combining practice errors and detected gaps, and support for additional material formats beyond PDF. **(Result)**

Results show that contextualized and auditable academic assistance can be delivered within the institutional LMS while preserving data sovereignty and mitigating large language model hallucination through answer traceability. **(Conclusion)**

Keywords: Moodle, artificial intelligence, RAG, academic assistant, education, data sovereignty.

2. Presentación del tema

La adopción de la inteligencia artificial generativa en la educación universitaria avanza más rápido que la integración formal de estas herramientas en las plataformas educativas. Mientras los estudiantes utilizan asistentes generales para resolver dudas académicas, las plataformas LMS institucionales como Moodle continúan funcionando como repositorios documentales, sin integración con la inteligencia artificial.

El proyecto NexusAI surge de esta brecha. Su propósito es incorporar, dentro del propio campus virtual, un asistente académico capaz de responder consultas en lenguaje natural sobre el material real de cada materia, generar ejercicios de práctica y proveer información accionable al docente. La relevancia del tema radica en que la solución no compite con el docente ni reemplaza a la plataforma existente: agrega una capa de inteligencia sobre Moodle, manteniendo a los estudiantes en el entorno donde reside el material académico validado.

El problema que motiva el proyecto se desarrolla en detalle en la sección *Diagnóstico*, y constituye el eje central sobre el cual se articula el resto del informe.

3. Glosario

Se definen a continuación los términos específicos del dominio del proyecto, necesarios para comprender el informe por parte de un lector no especializado en el área.

- **LMS (Learning Management System):** plataforma de gestión del aprendizaje que centraliza materiales, actividades y comunicación de un curso. Moodle es el LMS de referencia en el ámbito universitario argentino.
- **Moodle:** sistema de gestión de aprendizaje de código abierto, ampliamente utilizado por instituciones educativas para administrar cursos en línea.
- **Plugin:** componente de software que extiende las funcionalidades de una plataforma existente sin modificar su núcleo. NexusAI se distribuye como un plugin de tipo `local` para Moodle.
- **Inteligencia artificial generativa:** rama de la IA capaz de producir contenido nuevo —texto, imágenes, código— a partir de patrones aprendidos de grandes volúmenes de datos.
- **Modelo de lenguaje de gran escala (LLM):** modelo de inteligencia artificial entrenado sobre grandes cantidades de texto, capaz de comprender y generar lenguaje natural.
- **RAG (Retrieval-Augmented Generation):** técnica que combina la búsqueda de información relevante en una fuente de datos propia con la generación de texto de un LLM, permitiendo respuestas fundamentadas en material específico.
- **Embedding:** representación numérica (vector) de un fragmento de texto que captura su significado semántico, permitiendo comparar la similitud entre textos.
- **Base de datos vectorial:** sistema de almacenamiento optimizado para guardar y buscar *embeddings* por similitud semántica.
- **Alucinación (de un LLM):** fenómeno por el cual un modelo de lenguaje genera información plausible pero falsa o no fundamentada en una fuente real.
- **Chunk (fragmento):** porción de texto en la que se divide un documento para su indexación y recuperación.
- **Streaming:** entrega progresiva de la respuesta del modelo, token por token, para reducir la latencia percibida por el usuario.

4. Diagnóstico (problemática)

La problemática que da origen al proyecto no constituye únicamente un problema en sentido estricto, sino también una oportunidad de mejora dentro del proceso educativo universitario mediado por plataformas digitales.

4.1. Estado actual (contexto)

Las plataformas LMS como Moodle son fundamentales en la educación universitaria, pero en la práctica se utilizan como repositorios estáticos: los estudiantes descargan archivos y entregan trabajos, sin un acompañamiento real al proceso de aprendizaje. A partir de la experiencia directa del equipo del proyecto como estudiantes de la Universidad Católica de Córdoba (UCC), se identificaron de manera preliminar tres problemáticas recurrentes en el uso del campus virtual, que luego se validaron mediante un relevamiento formal a 166 estudiantes y 17 docentes de la institución:

- **Dispersión de la información** entre el campus virtual, aplicaciones de mensajería y servicios de almacenamiento personales, que dificulta encontrar el material correcto en el momento de estudiar. El 80,7 % de los estudiantes encuestados percibe esta dispersión al menos "a veces", y un 43,4 % la califica como alta o frecuente.
- **Dificultad para organizar el estudio** y planificar repasos antes de las evaluaciones, en un contexto donde solo el 34 % de los estudiantes describe la mayoría de sus materias como bien organizadas dentro del campus.
- **Uso pasivo del campus virtual** frente al material académico: aunque el 72,3 % de los estudiantes ingresa al campus a diario o varias veces por semana, el 100 % de quienes fueron consultados al respecto ya recurre a herramientas de IA generalistas —ajenas al material de la materia— para estudiar o resolver trabajos, lo que evidencia una necesidad no cubierta por la plataforma institucional.

4.2. Impacto sobre los interesados

La situación afecta a dos grupos principales. Por un lado, los estudiantes reciben respuestas genéricas de modelos entrenados sobre internet abierto —no sobre el material específico de su curso—, con riesgo de respuestas plausibles pero incorrectas en el contexto de esa materia particular. Por otro lado, los docentes pierden visibilidad sobre qué consultan los estudiantes acerca de su material, porque dichas consultas suceden fuera del LMS.

4.3. Oportunidades

A partir de este diagnóstico se identifican tres oportunidades de mejora que el proyecto busca aprovechar:

- Mantener a los estudiantes dentro del campus virtual, donde reside el material validado por el docente.
- Ofrecer respuestas fundamentadas en el material específico del curso, y no en fuentes genéricas de internet.

- Generar datos accionables para el docente sobre las consultas y los vacíos de contenido detectados.

  Los datos citados en esta sección provienen del relevamiento propio del equipo: encuesta a 166 estudiantes y encuesta a 17 docentes de la UCC, realizadas entre marzo y junio de 2026. El detalle de preguntas, metodología y resultados completos se encuentra en `investigacion/09-relevamiento/encuesta-estudiantes.md` y `investigacion/09-relevamiento/encuesta-docentes.md`.

5. Objetivos

5.1. Objetivo general

Desarrollar un plugin para Moodle que incorpore un asistente académico basado en inteligencia artificial, capaz de responder consultas en lenguaje natural sobre el contenido real de cada materia, generar ejercicios de práctica personalizados y proveer herramientas de *analytics* al docente, mejorando la experiencia educativa dentro del aula virtual de la UCC.

5.2. Objetivos específicos

- Identificar y documentar las problemáticas del uso actual del campus virtual a partir de la experiencia directa del equipo como estudiantes de la UCC, validada mediante un relevamiento formal a 166 estudiantes y 17 docentes de la institución.
- Diseñar e implementar un plugin de tipo `local` para Moodle que se integre al entorno existente sin modificar su núcleo.
- Desarrollar un prototipo funcional (MVP) con un asistente conversacional basado en técnicas de RAG e integración con modelos de lenguaje de gran escala, validado con usuarios reales.
- Implementar un sistema de generación de cuestionarios de práctica con corrección automática asistida por IA.
- Proveer al docente un panel de *analytics* sobre las consultas de sus estudiantes y herramientas de detección de vacíos de contenido en el material.
- Evaluar el impacto de la solución mediante pruebas con usuarios reales y métricas de calidad de respuesta.

5.3. Tabla de trazabilidad

La siguiente tabla evidencia el cumplimiento de cada objetivo específico vinculándolo con los requerimientos implementados y la prueba que lo valida.

Objetivo específico	Requerimiento(s)	Evidencia de cumplimiento
Relevamiento de problemáticas	—	Encuesta a 166 estudiantes y 17 docentes UCC (`investigacion/09-relevamiento/`): 80,7 % de estudiantes percibe dispersión de información; 100 % de quienes respondieron ya usa IA generalista para estudiar; 88,2 % de docentes delegaría tareas a una IA integrada al campus.

Objetivo específico	Requerimiento(s)	Evidencia de cumplimiento
Plugin `local` integrado a Moodle	RF-15 a RF-18	Plugin instalable en Moodle 4.1–4.5; pruebas de instalación
Asistente conversacional RAG	RF-01 a RF-07	Chat en producción; `test_retriever`, `test_pipeline`
Generación de cuestionarios	RF-10 a RF-14	Funcionalidad de *quiz* en producción; validación de tema
Analytics y detección de vacíos	RF-20 a RF-22	Reporte de *gaps* por curso; `test` de *gaps recorder*; validado además por el 88,2 % de docentes dispuestos a delegar tareas de analytics/evaluación relevado en la encuesta a docentes
Evaluación con usuarios reales	RNF-06 a RNF-09	Métricas de latencia; *golden set* de calidad de respuesta

PENDIENTE — ajustar la columna de "Evaluación con usuarios reales" con los resultados de las pruebas de usabilidad cuando estén consolidados (TEST-01/TEST-02, fuera del alcance de este relevamiento).

6. Marco teórico

El presente marco teórico proporciona el fundamento conceptual necesario para comprender la problemática, sin plantear todavía una solución específica. El análisis abarca el contexto del problema, las técnicas disponibles y las alternativas existentes en el mercado.

6.1. Contexto general del problema

La incorporación de inteligencia artificial generativa a los entornos educativos ha sido señalada como una de las tendencias tecnológicas más relevantes para la educación superior. Los modelos de lenguaje de gran escala (LLM) son capaces de sostener conversaciones en lenguaje natural, pero su conocimiento proviene de los datos con los que fueron entrenados, por lo que desconocen el material particular de una materia universitaria. Al consultarlos sobre dicho material, tienden a producir respuestas genéricas o, en el peor caso, **alucinaciones**: información plausible pero incorrecta o no fundamentada (Ji et al., 2023).

6.2. Técnicas investigadas

Para que un asistente responda sobre contenido específico de una materia existen tres estrategias principales:

Estrategia	Costo	Flexibilidad	Limitación principal
Prompting puro	Bajo	Baja	El modelo no conoce el material; inventa o se rehúsa
Fine-tuning	Muy alto	Alta	Requiere reentrenar el modelo por cada curso
RAG	Medio	Media-alta	Requiere infraestructura de indexación y recuperación

La técnica de **Retrieval-Augmented Generation** (RAG) combina la búsqueda semántica sobre documentos propios con la generación de texto de un LLM (Lewis et al., 2020). Permite incorporar material nuevo sin reentrenar el modelo, recuperando los fragmentos más relevantes y proveyéndolos como contexto. Diversos trabajos posteriores han sistematizado sus variantes y su aplicación a tareas intensivas en conocimiento (Gao et al., 2023). La calidad del sistema depende de decisiones de diseño como la estrategia de fragmentación (*chunking*), el modelo de *embeddings* y la métrica de similitud empleada.

6.3. Tecnologías investigadas

Además de la técnica general (RAG), se investigó y comparó la pila tecnológica concreta necesaria para implementarla, evaluando alternativas reales antes de decidir cada componente.

6.3.1. Base de datos vectorial

Alternativa	Decisión	Motivo
pgvector (extensión de PostgreSQL)	Elegida	Un solo sistema para datos relacionales y vectoriales; permite combinar filtros SQL y búsqueda vectorial en una sola consulta.
ChromaDB (ChromaDB, s.f.)	Descartada	Sistema separado de PostgreSQL: las consultas relacionales y vectoriales requieren dos llamadas y lógica de coordinación adicional.
Pinecone / Weaviate / Qdrant	Descartadas	Se justifican a partir de decenas de millones de vectores con alta concurrencia; la escala proyectada de NexusAI (~240.000 vectores para toda la UCC, hasta ~4,8 millones en una expansión multi-institución) queda muy por debajo de ese umbral.

6.3.2. Modelos de lenguaje y *embeddings*

Se comparó el costo y las prestaciones de los modelos de lenguaje candidatos: Gemini 2.5 Flash ofrece una capa gratuita suficiente para un MVP sin costo operativo, pero sin garantías de nivel de servicio para producción (Google, s.f.-a); GPT-4o-mini resulta significativamente más económico que GPT-4o y es la referencia de facto del mercado para este tipo de tareas, por lo que se lo eligió como modelo de producción, reservando GPT-4o para casos de razonamiento más complejo (OpenAI, s.f.-b). Dado que prácticamente todos los proveedores relevantes exponen una interfaz compatible con el SDK de OpenAI —incluido Gemini (Google, s.f.-a)— se diseñó una abstracción propia (`LLMProvider` / `EmbeddingProvider`) que permite cambiar de proveedor modificando únicamente una variable de entorno, en lugar de adoptar un *framework* de orquestación como LangChain, descartado por su peso y la inestabilidad de su API entre versiones.

6.3.3. Arquitectura de plugin Moodle

Moodle admite varios tipos de plugin (`local`, `block`, `mod`, `filter`, `auth`, entre otros). Se descartó `block` porque, con el tema Boost de Moodle 4.x, los bloques quedan ocultos en un panel

lateral y cada docente debería agregarlo curso por curso manualmente. Se evaluó también el **subsistema de IA nativo de Moodle 4.5+**, y se descartó por carecer de un estado de memoria conversacional persistente a lo largo del cuatrimestre —limitación funcional del núcleo que motiva, en gran medida, el desarrollo de un plugin propio en lugar de adoptar la funcionalidad ya incorporada a la plataforma. Se eligió finalmente un plugin de tipo `local`, que permite definir *web services*, tareas programadas y *hooks* propios sin depender de que el docente lo agregue manualmente a cada curso.

6.3.4. Extracción y fragmentación de documentos

Para la extracción de texto de los materiales subidos por el docente se evaluó pdfplumber frente a PyPDF2/pypdf (extracción deficiente en PDFs con diseño complejo), pdfminer.six (interfaz más compleja de integrar) y PyMuPDF (descartado por su licencia AGPL, incompatible con la distribución del plugin); pdfplumber (pdfplumber, s.f.) se eligió por su manejo nativo de tablas y diseño de página. Para la fragmentación (*chunking*) se adoptaron fragmentos de aproximadamente 500 tokens con 10 % de superposición entre fragmentos consecutivos: los fragmentos pequeños mejoran la precisión de la recuperación semántica, mientras que la superposición mitiga la pérdida de contexto cuando un fragmento corta una oración o una idea a la mitad.

6.4. Opciones similares en el mercado

Se relevaron asistentes académicos basados en IA existentes, con el fin de comprender el panorama actual y las carencias que el proyecto podría atender:

- **Khanmigo (Khan Academy):** tutor de IA pedagógicamente pulido, pero responde sobre el contenido de Khan Academy y no se integra con Moodle (Khan Academy, s.f.).
- **Coursera Coach:** asistente cerrado, limitado al ecosistema Coursera (Coursera, 2023).
- **NotebookLM (Google):** ofrece buen RAG con citas, pero requiere que el usuario suba los documentos manualmente y almacena los datos en servidores de un tercero (Google, s.f.-b).
- **Microsoft Copilot for Education y ChatGPT Edu:** potentes, pero centrados en sus propios ecosistemas, sin integración nativa con Moodle ni *analytics* para el docente (Microsoft, s.f.; OpenAI, s.f.-a).

Del análisis surge que ninguna de las soluciones relevadas combina simultáneamente: integración nativa con Moodle, RAG automático sobre el material del docente, despliegue autohospedado y panel de *analytics* docente. Esa intersección constituye el espacio de oportunidad que el proyecto aborda.

7. Propuesta de solución

La propuesta de solución describe cómo se aborda el problema planteado, a partir de lo analizado en el marco teórico. Esta es la sección más técnica del trabajo.

NexusAI es un plugin de Moodle con asistente de IA que combina tres capas: un plugin de tipo `local` (Moodle HQ, 2024) dentro de Moodle, una interfaz de chat embebida y un backend que orquesta el pipeline RAG. La pieza diferencial es el **RAG auténtico**: el material que el docente sube a Moodle se indexa automáticamente y el asistente responde citando la fuente; si la pregunta no puede responderse con el material disponible, el sistema lo admite explícitamente en lugar de inventar.

7.1. Alcance funcional

El sistema delimita claramente lo que entra y lo que queda fuera de su alcance actual. El MVP (junio de 2026) fue el primer hito funcional; el desarrollo continuó después de esa entrega, ampliando el alcance original.

Funcionalidades del MVP (junio 2026):

- Asistente conversacional RAG con respuesta en *streaming* y citas trazables al fragmento de origen.
- Buscador semántico (recuperación pura, sin LLM) sobre el material del curso.
- Chat multi-curso opcional, con citas que indican la materia de cada fragmento.
- Gestión de material por parte del docente: carga de PDF, indexación automática asíncrona, visualización de estado y borrado en cascada.
- Generador de cuestionarios de opción múltiple a partir del material, con feedback inmediato.
- Panel de detección de vacíos de contenido (*gaps*) para el docente.

Funcionalidades incorporadas después del MVP:

- Foros con detección automática de posts similares o duplicados mientras el alumno escribe, resumen de hilos largos y sugerencia de respuesta con RAG para el docente.
- Panel de analítica docente con preguntas frecuentes agrupadas por tema, a partir de un registro anonimizado de las interacciones del chat.
- Generador de exámenes a partir del material del curso, exportable al formato GIFT nativo de Moodle.
- Modo Estudio ampliado: más tipos de pregunta (verdadero/falso, abiertas, flashcards), historial de errores persistido en el backend, y un plan de estudio personalizado que combina errores de práctica, vacíos de contenido detectados en el chat y el próximo examen del calendario del curso.
- Filtros de búsqueda por tipo de material y por unidad/sección del curso.
- Vista de calendario con próximos exámenes y entregas.
- Soporte de material en PPTX, XLSX, CSV, Markdown y HTML además de PDF, con reconocimiento óptico de caracteres (OCR) de respaldo para documentos escaneados.

- Rediseño de la interfaz (agosto de 2026): el chat pasó de un *dropdown* flotante a un panel lateral acoplado, y el panel del docente se unificó en un lenguaje visual consistente de tipo *dashboard*, con paneles de material, vacíos de contenido, preguntas frecuentes, generación de exámenes y búsqueda integrados bajo la misma navegación.

Fuera de alcance (excluido conscientemente): soporte multi-institución nativo, integración con mensajería externa, y contenido multimedia, entre otros (ver detalle en *Anexos*).

Los requerimientos funcionales (RF-01 a RF-22) y no funcionales (RNF-01 a RNF-21) que detallan el alcance del MVP se encuentran documentados en los Anexos.

7.2. Diseño

7.2.1. Arquitectura del software

La arquitectura adoptada es **cliente-servidor en tres capas** con un backend organizado como **monolito modular**. El navegador del estudiante nunca se comunica directamente con el backend: toda llamada pasa por el plugin de Moodle, que actúa como proxy autenticado (patrón *Hybrid PHP Proxy*). Este diseño resuelve tres cuestiones de manera simultánea: la clave de la API del LLM nunca llega al navegador, la protección ante CSRF queda cubierta por el mecanismo nativo de Moodle, y se evitan los problemas de CORS al existir una única comunicación servidor-a-servidor.

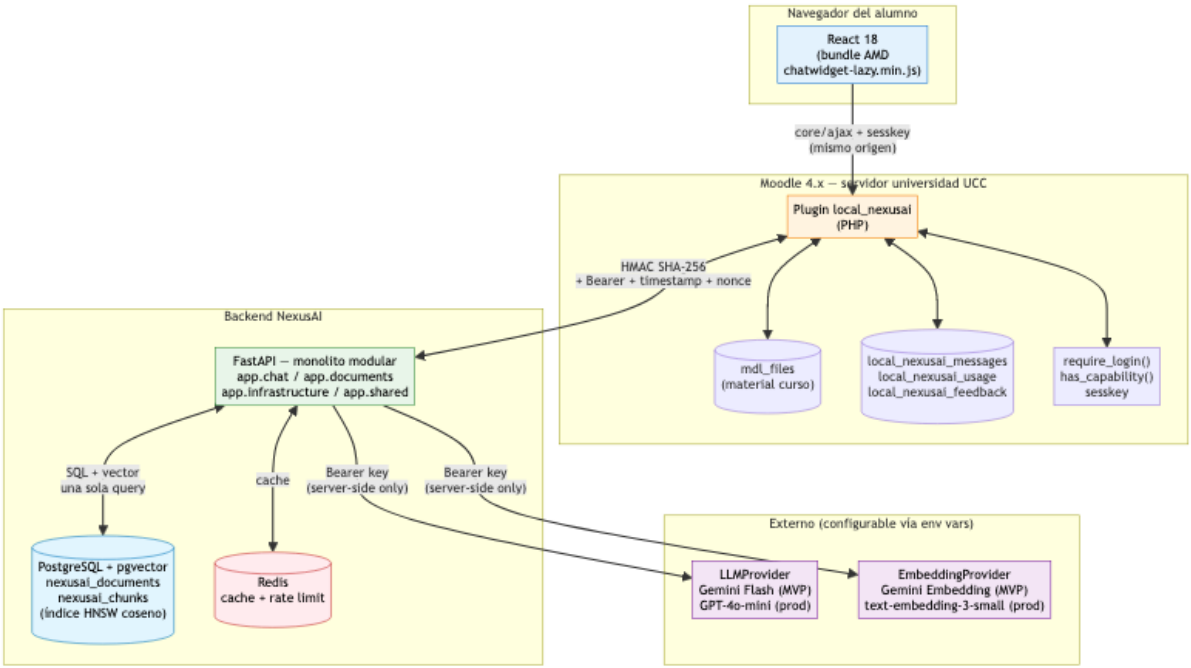


Figura 1. Diagrama de componentes de NexusAI (navegador, plugin Moodle, backend y servicios externos). *Fuente:* elaboración propia (`docs/diagrams/architecture.md`). *Texto alternativo:* esquema de tres capas que conecta el navegador con el plugin PHP, este con el backend FastAPI, y el backend con la base de datos vectorial y los proveedores de LLM y *embeddings*.

7.2.2. Patrones de diseño

El sistema aplica el patrón *Hybrid PHP Proxy* para el aislamiento de credenciales y la abstracción **multi-proveedor** de LLM y *embeddings*, que permite cambiar de proveedor mediante variables de entorno, sin modificar el código de aplicación.

7.2.3. Interfaz de usuario

La interfaz de chat se dispara desde un ícono en la barra de navegación de Moodle y se despliega como un panel lateral acoplado al borde derecho de la pantalla, de ancho fijo y alto completo, en lugar del *dropdown* flotante de las primeras versiones. Presenta la respuesta en *streaming*, citas clickeables que expanden el fragmento utilizado con su porcentaje de similitud, e historial de conversaciones por sesión, todo dentro del mismo panel. En dispositivos móviles el panel se comporta como una hoja a pantalla completa (*bottom-sheet*).

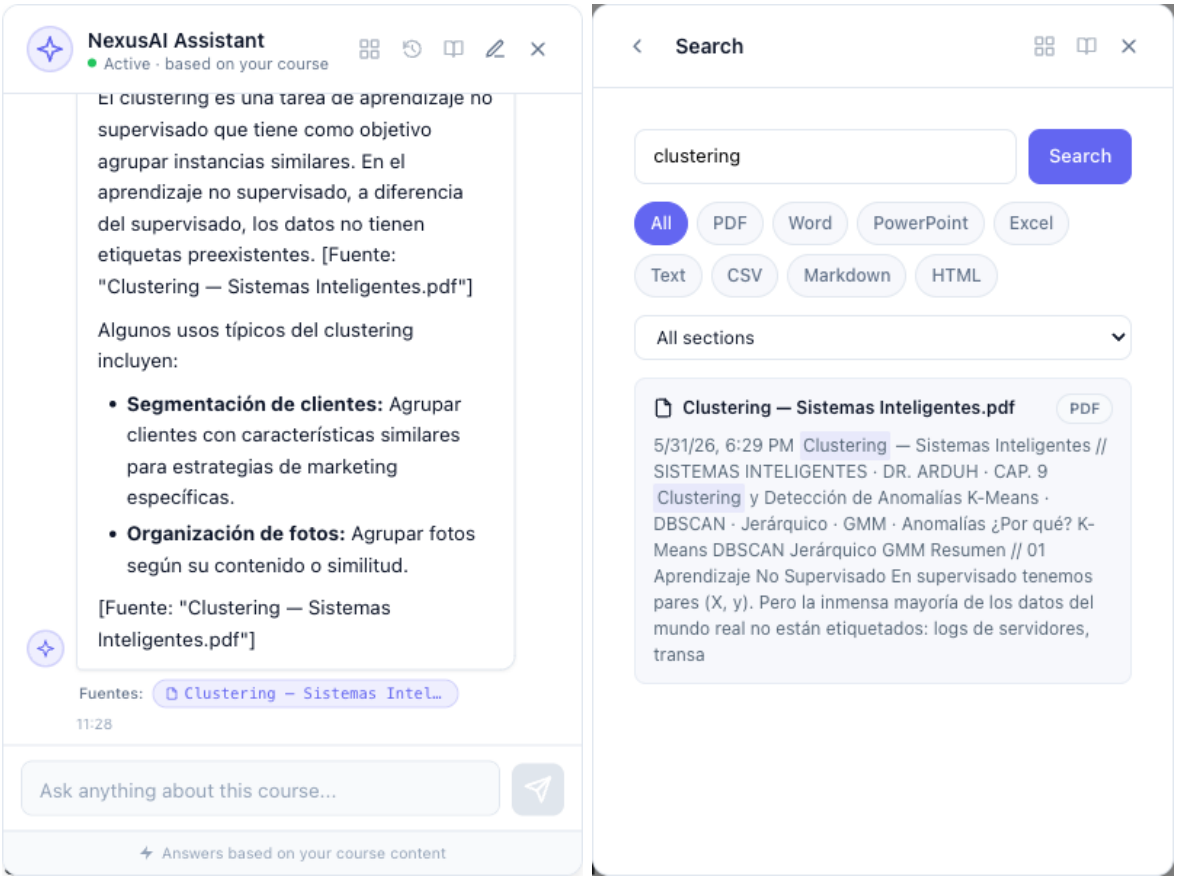


Figura 2a/2b. Widget de chat (izquierda) respondiendo con cita a la fuente, y buscador semántico (derecha) mostrando resultados resaltados. *Fuente:* elaboración propia, capturas del MVP desplegado localmente. *Texto alternativo:* a la izquierda, una conversación donde el asistente responde qué es el *clustering* citando el PDF de origen; a la derecha, el buscador semántico devolviendo un resultado con el término de búsqueda resaltado.

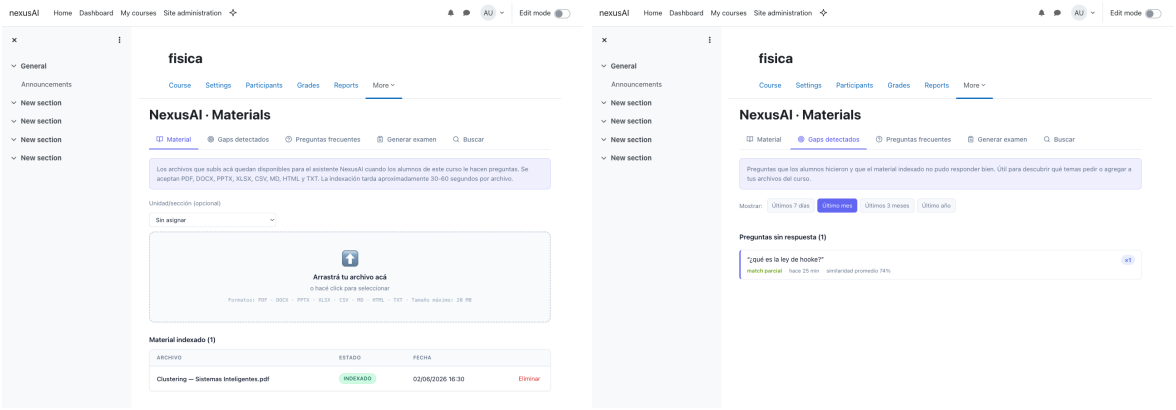


Figura 2c/2d. Panel del docente: gestión de material indexado (izquierda) y reporte de vacíos de contenido (derecha). *Fuente:* elaboración propia, capturas del MVP desplegado localmente. *Texto alternativo:* a la izquierda, la tabla de materiales subidos con su estado de indexación; a la derecha, una pregunta de un alumno que el material no pudo responder bien, con su similitud promedio.

7.3. Implementación

La solución se construyó de manera incremental, dividida en módulos lógicos:

- **Módulo de asistente conversacional (chat):** orquesta el pipeline RAG y el *streaming* de respuestas.
- **Módulo de gestión de documentos:** extracción de texto, fragmentación, generación de *embeddings* e indexación asíncrona.
- **Módulo de búsqueda semántica:** recuperación de fragmentos por similitud.
- **Módulo de cuestionarios (*quiz*):** generación de preguntas de opción múltiple.
- **Módulo de detección de vacíos (*gaps*):** registro de consultas no resueltas y reporte agregado para el docente.
- **Módulo de seguridad:** autenticación HMAC SHA-256 en tres capas (clave de API, firma y *nonce* anti-replay).

El pipeline de indexación procesa los documentos de forma asíncrona: extrae el texto, lo divide en fragmentos de aproximadamente 512 tokens con solapamiento, genera los *embeddings* y los almacena en una base de datos PostgreSQL con la extensión **pgvector** (pgvector, s.f.), actualizando el estado del documento (`pending → indexing → indexed | error`).

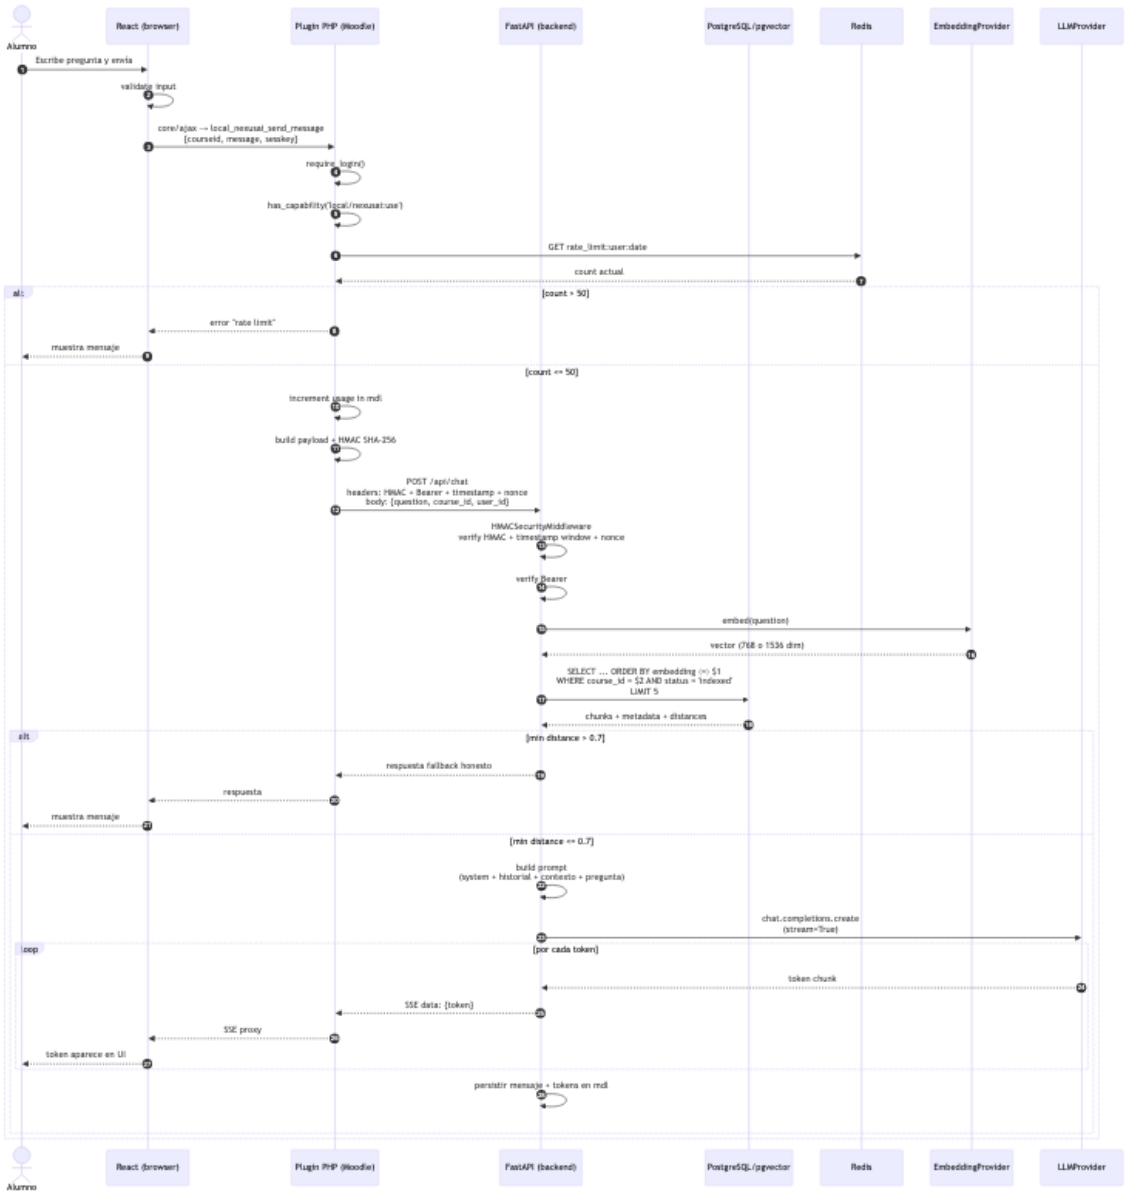


Figura 3. Diagrama de secuencia de una consulta del estudiante. *Fuente:* elaboración propia (`docs/diagrams/sequence-chat.md`). *Texto alternativo:* secuencia desde que el alumno escribe una pregunta hasta que recibe la respuesta en streaming, pasando por autenticación, rate limiting, embedding de la pregunta, búsqueda vectorial y generación con el LLM.

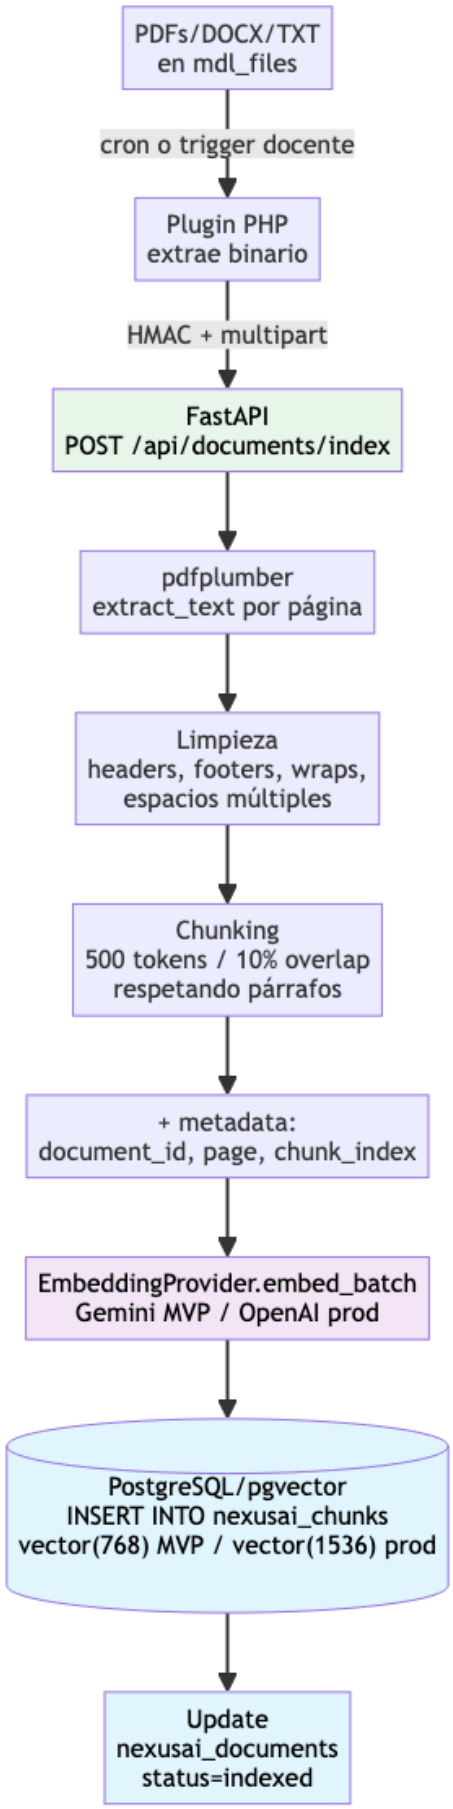

PDFs/DOCX/TXT
en mdl_files
cron o trigger docente
Plugin PHP
extrae binario
HMAC + multipart
FastAPI
POST /api/documents/index
pdfplumber
extract_text por página
Limpieza
headers, footers, wraps,
espacios múltiples
Chunking
500 tokens / 10% overlap
respetando párrafos
+ metadata:
document_id, page, chunk_index
EmbeddingProvider.embed_batch
Gemini MVP / OpenAI prod
PostgreSQL/pgvector
INSERT INTO nexusai_chunks
vector(768) MVP / vector(1536) prod
Update
nexusai_documents
status=indexed

Figura 4. Pipeline de indexación de material (offline). *Fuente:* elaboración propia (`docs/diagrams/rag-flow.md`). *Texto alternativo:* flujo desde que el docente sube un documento hasta que queda indexado como chunks vectoriales, pasando por extracción de texto, limpieza, fragmentación y generación de *embeddings*.

7.4. Pruebas

La estrategia de pruebas combina:

- **Pruebas unitarias y de integración** automatizadas en el backend (extracción, fragmentación, recuperación, autenticación HMAC), con una cobertura cercana al 80 %.
- **Pruebas funcionales** manuales sobre el plugin y la interfaz de chat.
- **Pruebas de aceptación** vinculadas a los criterios definidos en los requerimientos.
- **Evaluación de calidad de respuesta** mediante un conjunto de referencia (*golden set*) de preguntas y respuestas esperadas.

PENDIENTE — consolidar los resultados de las pruebas con usuarios reales y los valores medidos frente a los objetivos de latencia (RNF-06 a RNF-09).

8. Publicación en Moodle Marketplace

Más allá de las pruebas internas descritas en la sección anterior, el proyecto fue sometido a una validación externa concreta: la revisión de código y funcionalidad que exige el Moodle Plugins Directory (*Moodle Marketplace*) para publicar un plugin de terceros. Esta sección documenta ese proceso, los hallazgos de la revisión y cómo se resolvieron, por tratarse de la evaluación independiente más rigurosa que atravesó el plugin hasta el momento de este informe.

8.1. Por qué separar el repositorio

El formulario de registro de un plugin en moodle.org no admite indicar una subcarpeta: recibe una URL de repositorio y asume que su raíz es la raíz del plugin (Moodle HQ, s.f.). El código de NexusAI, sin embargo, vive dentro de un monorepo (`nexusAI`) junto al backend, la documentación y el material de investigación del proyecto, cuatro niveles por debajo de la raíz real del repositorio git. Un validador automático que clona el repo y busca `version.php` en el nivel superior no lo encuentra, y el envío se rechaza antes de llegar a un revisor humano.

De las alternativas evaluadas para resolverlo —pasar la URL del monorepo tal cual, usar un *submodule* de git o copiar la carpeta a mano a un repositorio nuevo— ninguna resultó viable sin perder el historial de commits del plugin o sin dejar de resolver el problema de fondo. La solución adoptada fue `git subtree split`: extrae únicamente los commits que modificaron la carpeta del plugin, con su historial intacto, hacia un repositorio nuevo y vacío (`nexusai-ucc/moodle-local_nexusai`), cuyo nombre sigue además la convención `moodle-{tipo}_{nombre}` que exige Moodle. Desde entonces, el monorepo sigue siendo el lugar donde se desarrolla, y un workflow de GitHub Actions (`sync-derived-repos.yml`) repite el *subtree split* de forma automática en cada *push* a `development`, manteniendo al repositorio público sincronizado sin intervención manual.

8.2. Proceso de envío y primera revisión

El plugin se envió al Moodle Plugins Directory el 20 de septiembre de 2026 en su versión `0.18.1` (*beta*), tras validar un checklist de requisitos de envío: metadatos completos en `version.php`, cabecera de licencia GPL v3+, cadenas de idioma en inglés y español, instalación desde ZIP sin pasos de compilación adicionales, CI real corriendo sobre Moodle 4.5 a 5.2 con PostgreSQL y MySQL, `LICENSE` dual (MIT en el repositorio raíz, GPL v3 en el plugin), ícono de 256×256 px y capturas de pantalla en inglés.

El flujo de revisión de Moodle es público (`moodle.org/plugins/queue.php`) y sigue un circuito estándar: *Upload initial version* → *Waiting for approval* → *Needs more work* → *Upload fixed version* → … hasta la aprobación. Recibir *"Needs more work"* en la primera ronda es la norma, no una señal de rechazo. NexusAI no fue la excepción: el ticket de revisión (identificado internamente como **MMR-301**, a cargo del revisor Volodymyr Dovhan, de Moodle HQ) devolvió el plugin con **"Changes needed"**, señalando 16 puntos a corregir sobre el código de la versión enviada.

8.3. Correcciones de la primera ronda

El equipo corrigió los 16 puntos del ticket en dos rondas de *pull requests*, agrupables en estas categorías:

- **Privacidad en foros con IA:** las funciones de resumen de hilo, sugerencia de respuesta y detección de posts similares verificaban el acceso a la discusión pero no a cada post individual, por lo que una respuesta privada podía llegar a un modelo de lenguaje o a estudiantes a los que no estaba dirigida, y una respuesta de un foro de preguntas y respuestas podía verse antes de que el estudiante publicara la propia. Se corrigió reutilizando la verificación de visibilidad nativa de `mod_forum` en cada post.
- **Endurecimiento de la conexión con el backend:** el *stream* del chat llamaba a `curl_init()` directamente; se reemplazó por la clase `\curl` de Moodle, que valida el certificado TLS del backend y no sigue redirecciones.
- **Falsos positivos de seguridad:** la página de estado de administración marcaba como "bloqueada" cualquier URL en `localhost`, en una red privada o en el puerto 8000, aun cuando el plugin funcionaba correctamente contra un backend de desarrollo legítimo; se ajustó para que solo valide que el endpoint responda `http(s)` y muestre los campos de salud del backend.
- **Calendario:** el feed `.ics` no excluía a usuarios suspendidos o eliminados ni verificaba que el usuario conservara el permiso `local/nexusai:use` en el curso.
- **Internacionalización y cabeceras de licencia:** textos fijos del widget de chat y de los paneles de foro que no pasaban por el paquete de idioma, y archivos PHP sin la cabecera estándar GPL que exige Moodle en todo el código fuente, incluidos los módulos AMD y las fuentes React que viajan en el ZIP.
- **Matriz de integración continua:** la versión enviada corría CI solo sobre un subconjunto de versiones soportadas; se amplió para cubrir Moodle 4.5 a 5.3 contra PostgreSQL y MySQL.

Estas correcciones, junto con la purga de posts de foro indexados en el backend tras borrar los datos de un usuario —otro de los 16 puntos—, se integraron en la versión `0.19.0`.

8.4. Auditoría propia y cierre de los últimos gaps

Antes de responder al ticket, el equipo hizo una auditoría interna cruzando cada punto marcado como resuelto contra el código real de `development`, y encontró una discrepancia: borrar un **curso completo** seguía sin purgar los posts de foro que el backend tenía indexados de ese curso. `data_cleanup::delete_course()` —la función que corre cuando Moodle borra un curso de verdad— solo encolaba la purga de documentos; la purga de posts de foro solo era alcanzable desde los tres métodos de la API de Privacidad de Moodle, que **no se ejecuta** en un borrado de curso real (a diferencia de un pedido de eliminación de datos de un usuario). El método que faltaba conectar (`provider::delete_backend_forum_posts()`) ya existía y ya soportaba el caso de "todos los usuarios del curso"; solo hacía falta exponerlo como público y llamarlo desde el lugar correcto.

Una revisión posterior, más allá de los 16 puntos originales, encontró un segundo caso del mismo tipo de bug: borrar un **foro puntual**, dejando el resto del curso intacto, tampoco purgaba nada —siempre, no solo en el caso excepcional que el equipo tenía anotado. La causa resultó ser distinta a la del curso: el observador del evento `course_module_deleted` de Moodle filtra a propósito cualquier actividad que no sea de tipo "Archivo", y aunque se hubiera manejado ahí, no habría funcionado: `forum_delete_instance()` —la función que borra las discusiones y los posts de un foro— se ejecuta **antes** de que Moodle dispare ese evento. Para cuando un observador llega a correr, los posts ya no existen en las tablas del foro y no hay nada que consultar. La solución usa en cambio `pre_course_module_delete($cm)`, un *callback* que Moodle descubre por convención de nombre de archivo y ejecuta **antes** de borrar el módulo, pensado exactamente para este tipo de caso —el mismo patrón que usan `tool_recyclebin` y otros complementos del núcleo de Moodle.

Ambos hallazgos se corrigieron, con pruebas automatizadas nuevas que reproducen cada caso, y la corrección quedó incluida en la versión `0.19.0` enviada de vuelta al revisor.

8.5. Sincronización automática y una lección operativa

Como el repositorio que revisa Moodle es un derivado del monorepo, cada corrección depende de que el workflow de sincronización (`sync-derived-repos.yml`) efectivamente la traslade. Al mergear las correcciones del último hallazgo, el workflow falló silenciosamente en las dos corridas siguientes: el token de GitHub (`SYNC_REPOS_TOKEN`) con el que el workflow empuja los cambios al repositorio público había vencido, así que el repositorio que vería el revisor seguía mostrando una versión vieja del plugin a pesar de que el monorepo ya tenía el fix. El incidente se detectó revisando el estado real de las corridas de CI —no asumiéndolo por el estado de los *pull requests* en el monorepo—, se resolvió generando un nuevo token de acceso de alcance limitado (permisos de escritura únicamente sobre los dos repositorios derivados) y quedó documentado como recordatorio de verificar la fecha de vencimiento del token la próxima vez que se renueve.

8.6. Estado actual

Al cierre de este informe, el plugin está en versión `0.19.0` (`MATURITY_BETA`), con las correcciones de los 16 puntos de MMR-301 y de los dos hallazgos adicionales ya sincronizadas al repositorio público (`nexusai-ucc/moodle-local_nexusai`), a la espera de la próxima devolución del revisor de Moodle HQ.

9. Beneficios post-implementación

Tras la implementación del proyecto se esperan los siguientes beneficios, tanto tangibles como intangibles:

- **Acceso a asistencia académica disponible de forma permanente (24/7)** sobre el material real del curso, sin necesidad de incorporar personal de tutoría adicional.
- **Reducción de la dispersión de la información**, al concentrar las consultas dentro del campus virtual donde reside el material validado.
- **Mejora en la toma de decisiones del docente**, mediante el reporte de vacíos de contenido que evidencia qué temas no quedan cubiertos por el material.
- **Mitigación del riesgo de respuestas incorrectas**, gracias a la trazabilidad de cada respuesta hacia su fragmento de origen.
- **Preservación de la soberanía de los datos académicos**, al mantenerlos en la infraestructura controlada por la institución.

10. Impacto económico (estudio de costos)

El análisis de costos contempla cuatro categorías: infraestructura, servicios de IA, personal y costos académicos. Se distingue el escenario actual del MVP del escenario de una eventual producción.

10.1. Costos de infraestructura y servicios de IA

En el escenario actual del MVP, el uso de niveles gratuitos de hosting y del modelo de IA permite un costo operativo prácticamente nulo. En un escenario de producción estimado para 500 estudiantes activos, el costo se mantiene reducido.

Concepto	Escenario MVP (actual)	Escenario producción (anual, 500 alumnos)
Infraestructura (hosting, base de datos, *cache*, dominio)	~$36 / año	~$170
Servicios de IA (LLM + *embeddings*)	$0 (nivel gratuito)	~$1.200
Mantenimiento (10 h/mes)	—	~$1.440
Total	**~$36 / año**	**~$2.810**

El costo de producción equivale a aproximadamente **$5,62 por estudiante por año**, un orden de magnitud por debajo de soluciones comerciales comparables.

10.2. Costos de personal (valoración teórica)

El equipo está compuesto por dos estudiantes de Ingeniería en Sistemas. Valorado a tarifa de mercado junior (~$12 por hora), el desarrollo del MVP representó aproximadamente **840 horas-persona**, equivalentes a una valoración teórica de ~**$10.080**. Este monto **no constituye un costo real** para la institución —el trabajo es académico— pero permite dimensionar el valor del proyecto.

10.3. Análisis costo-beneficio

El beneficio principal es la disponibilidad de asistencia académica permanente sin contratar personal de tutoría adicional. Si la institución ahorrara una hora de tutoría por estudiante por año, el retorno superaría ampliamente el costo del sistema. A ello se suma la condición autohospedada de la solución, que evita riesgos regulatorios de privacidad asociados a los servicios de IA de terceros.

11. Impacto social

El impacto social del proyecto se relaciona con la mejora del acceso al conocimiento y la equidad educativa, más allá de los aspectos técnicos o económicos.

- **Beneficio general:** el sistema democratiza el acceso a un acompañamiento académico permanente, históricamente limitado a quienes disponen de tiempo, recursos o redes de apoyo para resolver dudas fuera del aula.
- **Segmentos beneficiados:** estudiantes que cursan a distancia, que trabajan, o que por distintos motivos no pueden asistir a consultas presenciales, encuentran un canal de apoyo disponible en todo momento.
- **Inclusión y reducción de brechas:** al responder sobre el material validado por el docente y citar la fuente, el sistema ofrece una alternativa más confiable y equitativa que el uso desigual de herramientas de IA generales.
- **Apoyo al rol docente:** la solución amplifica la tarea del docente en lugar de reemplazarla, y le brinda información para mejorar su material en beneficio del conjunto del estudiantado.

El relevamiento propio del equipo (166 estudiantes, 17 docentes UCC; ver `investigacion/09-relevamiento/`) refuerza estos puntos con datos concretos: el 100 % de los estudiantes que respondieron ya recurre a herramientas de IA generalistas para estudiar, evidenciando una necesidad de acompañamiento académico ya instalada que hoy queda fuera del ámbito institucional y sin trazabilidad hacia el material real de la materia. Del lado docente, el 88,2 % delegaría tareas a una IA integrada al campus —la mayoría con la condición de revisar el resultado antes de publicarlo—, lo que indica una disposición amplia a que la tecnología amplifique su rol sin reemplazarlo, consistente con el diseño “asistir, no sustituir” adoptado por NexusAI.

12. Impacto medioambiental (opcional)

Si bien se trata de una solución de software, se consideran sus efectos sobre el consumo de recursos de cómputo:

- **Uso eficiente de la energía:** la arquitectura de un único servicio (monolito modular) y el uso de una sola base de datos reducen la huella de cómputo frente a arquitecturas distribuidas más complejas.
- **Aprovechamiento de niveles gratuitos y recursos compartidos:** el despliegue del MVP utiliza infraestructura compartida, evitando el aprovisionamiento de hardware dedicado.
- **Sostenibilidad a largo plazo:** la abstracción multi-proveedor permite migrar a modelos de IA más eficientes a medida que estén disponibles, sin rediseñar el sistema.

13. Conclusión

El proyecto cumplió con los objetivos planteados al inicio. Se desarrolló un plugin de Moodle funcional con un asistente de IA que aplica RAG auténtico sobre el material del curso, con citas trazables, despliegue autohospedado y respuesta en *streaming*. El MVP entregado en junio de 2026 alcanzó siete funcionalidades en producción con una cobertura de pruebas automatizadas en el backend cercana al 80 %, superando el objetivo planteado, y el desarrollo continuó después de esa entrega incorporando foros con asistencia de IA, analítica docente, generación de exámenes, un plan de estudio personalizado y soporte de más formatos de material.

Desde el punto de vista académico, el trabajo aporta respuestas concretas a tres cuestiones vigentes en la aplicación de IA a la educación: la mitigación de la alucinación mediante RAG con citas trazables; el cierre del circuito de retroalimentación entre estudiante y docente mediante la detección automática de vacíos de contenido; y la preservación de la privacidad y la soberanía de los datos académicos mediante una arquitectura autohospedada.

Entre las **limitaciones** actuales se reconocen la ausencia de un esquema multi-institución nativo, la dependencia de la calidad del modelo de lenguaje en el generador de cuestionarios, y la cobertura manual de pruebas en el frontend y el plugin.

Como **trabajo futuro** se plantean la publicación del plugin en el directorio oficial de Moodle, la incorporación de pruebas automatizadas de frontend, y el agrupamiento semántico (por embeddings, no solo por texto normalizado) de los vacíos de contenido detectados.

En síntesis, el proyecto demuestra que es posible integrar asistencia académica contextualizada y auditable dentro del LMS institucional, amplificando el rol del docente en lugar de sustituirlo.

> *(Espacio reservado para reflexiones personales del equipo, a incorporar si la cátedra lo solicita.)*

14. Bibliografía / Referencias

Las referencias siguen la norma APA v7. Toda fuente citada en el texto figura en esta sección, y toda referencia listada fue utilizada en el informe.

- ChromaDB. (s.f.). *Chroma documentation*. Recuperado 2026, de https://docs.trychroma.com/
- Coursera. (2023). *Coursera launches Coach, a personalized AI-powered coaching experience, and new applications of GenAI in the enterprise*. Coursera Blog. https://blog.coursera.org/coursera-launches-coach/
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, H., & Wang, H. (2023). *Retrieval-augmented generation for large language models: A survey*. arXiv. https://arxiv.org/abs/2312.10997
- Google. (s.f.-a). *Gemini API — OpenAI compatibility*. Recuperado 2026, de https://ai.google.dev/gemini-api/docs/openai
- Google. (s.f.-b). *NotebookLM*. Recuperado 2026, de https://notebooklm.google/
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys, 55*(12), 1–38. https://doi.org/10.1145/3571730
- Khan Academy. (s.f.). *Khan Labs — Khanmigo*. Recuperado 2026, de https://www.khanacademy.org/khan-labs
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474.
- Microsoft. (s.f.). *Microsoft Copilot for Education*. Recuperado 2026, de https://www.microsoft.com/en-us/education/products/copilot
- Moodle HQ. (2024). *Moodle Developer Documentation — Plugin types: local*. https://moodledev.io/docs/apis/plugintypes/local
- Moodle HQ. (s.f.). *Plugin contribution checklist*. Recuperado 2026, de https://moodledev.io/general/comm
- OpenAI. (s.f.-a). *ChatGPT Edu*. Recuperado 2026, de https://openai.com/chatgpt/education/
- OpenAI. (s.f.-b). *GPT-4o pricing*. Recuperado 2026, de https://openai.com/api/pricing/
- pdfplumber. (s.f.). *pdfplumber* [Software]. GitHub. https://github.com/jsvine/pdfplumber
- pgvector. (s.f.). *pgvector: Open-source vector similarity search for Postgres* [Software]. GitHub. https://github.com/pgvector/pgvector

15. Anexos

Los anexos reúnen material complementario que respalda el informe sin interrumpir su lectura principal.

15.1. Anexo A — Requerimientos detallados

Cada requerimiento tiene un ID único (RF-NN funcionales, RNF-NN no funcionales), una prioridad en el contexto del MVP y el sprint donde se implementó.

15.1.1. Requerimientos funcionales

Asistente conversacional RAG

ID	Requerimiento	Prioridad	Sprint
RF-01	Consulta en lenguaje natural sobre el material del curso desde un widget flotante.	Alta	1
RF-02	El asistente responde usando exclusivamente el material indexado, citando los archivos fuente.	Alta	2
RF-03	Si la pregunta no se puede responder con el material disponible, el sistema lo admite explícitamente.	Alta	2
RF-04	El alumno ve el fragmento exacto usado para responder, con su porcentaje de similitud.	Alta	4
RF-05	La respuesta aparece token por token (*streaming*) para reducir la latencia percibida.	Media	4

ID	Requerimiento	Prioridad	Sprint
RF-06	El alumno puede retomar conversaciones anteriores desde un historial.	Media	4
RF-07	Modo multi-curso opcional: el asistente consulta material de todos los cursos inscriptos.	Media	4

Buscador semántico

ID	Requerimiento	Prioridad	Sprint
RF-08	Búsqueda de fragmentos por similitud semántica, sin pasar por el LLM.	Media	4
RF-09	Cada resultado muestra archivo, fragmento y porcentaje de similitud.	Media	4

Generador de cuestionarios

ID	Requerimiento	Prioridad	Sprint
RF-10	Generación de un *quiz* de opción múltiple desde el material del curso.	Media	4
RF-11	El alumno elige un tema específico o deja el campo vacío para variedad de temas.	Media	4
RF-12	Si el tema pedido no está en el material, el sistema avisa (no genera un *quiz* engañoso).	Media	4

ID	Requerimiento	Prioridad	Sprint
RF-13	Cada pregunta tiene 4 opciones: una correcta y tres distractores plausibles.	Media	4
RF-14	Feedback inmediato tras cada respuesta, con explicación y archivo fuente.	Media	4

Gestión de material (rol docente)

ID	Requerimiento	Prioridad	Sprint
RF-15	El docente sube archivos PDF al curso para que el asistente los indexe.	Alta	2
RF-16	Extracción de texto, *chunking* y *embeddings* de cada archivo de forma asíncrona.	Alta	2
RF-17	El docente ve el estado de cada documento (`pending` / `indexing` / `indexed` / `error`).	Alta	2
RF-18	El docente puede borrar un documento; el borrado se propaga en cascada a sus *chunks*.	Alta	2
RF-19	Detección de *uploads* duplicados por hash SHA-256, evita reindexar el mismo archivo.	Media	4

Feedback al docente (detección de vacíos)

ID	Requerimiento	Prioridad	Sprint
RF-20	Registro automático de las preguntas que el material no pudo responder.	Media	4
RF-21	Reporte agregado de vacíos por curso, ordenado por frecuencia.	Media	4
RF-22	El reporte de vacíos se filtra por ventana temporal (7/30/90/365 días).	Baja	4

15.1.2. Requerimientos no funcionales

ID	Requerimiento	Categoría
RNF-01	La API key del LLM nunca llega al navegador del alumno.	Seguridad
RNF-02	Toda comunicación entre el plugin y el backend se firma con HMAC SHA-256 en 3 capas (Bearer + firma + *nonce*).	Seguridad
RNF-03	El backend rechaza firmas inválidas, timestamps vencidos (>5 min) o *nonces* reusados.	Seguridad
RNF-04	El plugin valida la *capability* `local/nexusai:use` antes de llamar al backend.	Seguridad
RNF-05	El backend valida que un usuario no pueda leer sesiones de chat ajenas.	Seguridad
RNF-06	Latencia al primer token de respuesta (streaming) < 2 s.	Performance
RNF-07	Latencia de respuesta completa del chat (sin streaming) < 8 s.	Performance

ID	Requerimiento	Categoría
RNF-08	Latencia del buscador semántico (retrieval puro) < 1 s.	Performance
RNF-09	Tiempo de indexación de un PDF de 50 páginas < 60 s.	Performance
RNF-10	Instalable en Moodle 4.1 LTS a 4.5 sin `composer install` ni dependencias externas.	Compatibilidad
RNF-11	El widget funciona en Chrome, Firefox, Safari y Edge en versiones actuales.	Compatibilidad
RNF-12	El backend corre sobre Python 3.11+, PostgreSQL 16+ y pgvector 0.3.5+.	Compatibilidad
RNF-13	Los datos académicos viven en una base de datos controlada por la institución.	Privacidad
RNF-14	El plugin declara su Privacy API según la versión de Moodle (`null_provider` en MVP).	Privacidad
RNF-15	El proveedor del LLM se cambia sin modificar código (variable de entorno).	Privacidad
RNF-16	Cobertura de tests automatizados del backend de al menos 70 %.	Mantenibilidad
RNF-17	CI/CD en GitHub Actions para backend, frontend y plugin PHP.	Mantenibilidad
RNF-18	Decisiones arquitectónicas documentadas como ADRs en `docs/adr/`.	Mantenibilidad
RNF-19	Cada *feature* documentada con ADR (si aplica), comentarios en código e issue con criterios de aceptación.	Mantenibilidad
RNF-20	El plugin se distribuye como ZIP instalable vía *Site administration* $\rightarrow$ *Plugins* $\rightarrow$ *Install plugins.*	Distribución

ID	Requerimiento	Categoría
RNF-21	Cada *release* etiquetada en GitHub con *changelog* y `version.php` actualizado.	Distribución

15.2. Anexo B — Modelo de datos

NexusAI usa una sola base de datos PostgreSQL con la extensión pgvector activada; los embeddings vectoriales y los datos relacionales viven en la misma instancia.

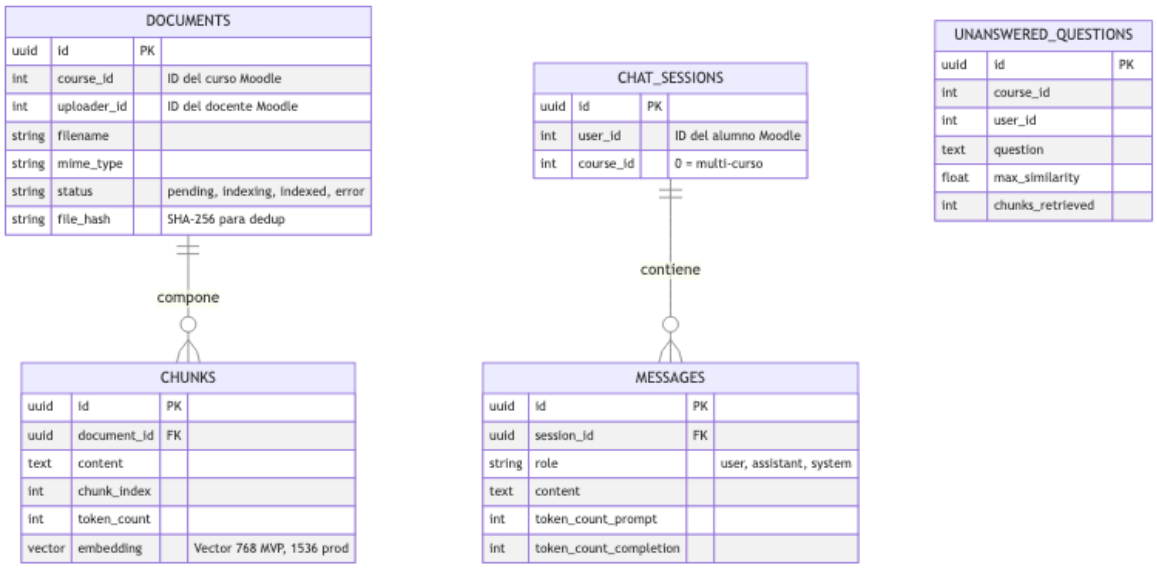


Figura 5. Diagrama entidad-relación de NexusAI. *Fuente:* elaboración propia (`entrega-final/15_modelo_datos.md`). *Texto alternativo:* cinco tablas — documents, chunks, chat_sessions, messages y unanswered_questions — con `documents` componiendo `chunks` y `chat_sessions` conteniendo `messages`.

Notas de implementación: `chunks.embedding` usa un índice **HNSW** con distancia coseno (`m=16`, `ef_construction=200`) para búsqueda aproximada en tiempo casi constante. `documents` tiene un índice único parcial sobre `(course_id, filename, file_hash)` que evita reindexar el mismo archivo dos veces. El esquema evolucionó en 5 migraciones Alembic (001 a 004, con dos migraciones `004_*` desarrolladas en paralelo por integrantes distintos y luego encadenadas). Del lado del plugin Moodle, hoy solo existe `local_nexusai_placeholder` (vacía); las tablas `local_nexusai_usage`, `local_nexusai_cache` y `local_nexusai_course_settings` quedan planificadas para post-MVP.

15.3. Anexo C — Métricas del proyecto

Velocidad por sprint

Sprint	SP comprometidos	SP completados	Velocity
Sprint 0 — Setup	60	60	100 %
Sprint 1 — Core chat	50	45	90 %
Sprint 2 — RAG	60	55	92 %
Sprint 3 — Calidad	25	25	100 %
Sprint 4 — MVP	70	70	100 %
Promedio			**96 %**

Métricas de desarrollo

Métrica	Valor
Commits al repositorio	~290
Issues cerradas	160+
Pull requests mergeados	85+
Líneas de código backend Python	~3.500
Líneas de código plugin PHP	~2.500
Líneas de código React	~3.200
Migraciones de base de datos	5
ADRs documentadas	6
Tests automatizados del backend	37
Cobertura de tests del backend	~80 %

Calidad del LLM (*golden set*)

Métrica	Resultado en el MVP
Preguntas con respuesta correcta y citación adecuada	8/10
Preguntas donde el LLM admitió no poder responder (correcto)	2/2
Falsos positivos (respuesta segura pero incorrecta)	0
Falsos negativos (no responde teniendo material disponible)	0

15.4. Anexo D — Repositorio y evidencias

- **Repositorio:** github.com/nexusai-ucc/nexusAI
- **Issues:** github.com/nexusai-ucc/nexusAI/issues
- **Integración continua (GitHub Actions):** github.com/nexusai-ucc/nexusAI/actions
- **Release del MVP:** `v0.8.0-mvp` (github.com/nexusai-ucc/nexusAI/releases/tag/v0.8.0-mvp). El plugin siguió evolucionando después del MVP (versión actual `0.14.2` según `plugin/local/nexusai/version.php`) sin un *tag* formal más reciente en el repositorio — pendiente etiquetar el próximo *release* (RNF-21).

  Nota: el backend está desplegado de forma permanente en dos ambientes sobre Oracle Cloud (*Always Free*): *staging*, para pruebas del día a día

(`https://api-staging.146.181.62.67.nip.io`), y producción, solo para funcionalidad ya validada (`https://api.159.112.139.166.nip.io`). Moodle no se despliega junto al backend — cada integrante lo sigue corriendo localmente, apuntando el plugin al ambiente correspondiente. El deploy a ambas VMs es manual; para reducir el riesgo de acumular cambios sin probar, el equipo concentra los merges a `main` al cierre de cada sprint, trabajando el resto del tiempo contra `development` y *staging*.